Statistique en grande dimension - partie non supervisée

Laurent Rouvière

9 novembre 2022

Présentation

Définition

Action de répartir en classes, en catégories, des choses, des objets, ayant des caractères communs afin notamment d'en faciliter l'étude.

Nombreuses applications

- Astronomie : classification d'étoiles
- Médecine : diagnostic de maladies à partir d'observation cliniques
- Géographie : délimitation de zones homogènes
- Marketing : détermination de segments de marchés (groupes de consommateurs ayant les mêmes habitudes)
- Réseaux sociaux : extraction de communautés
- ...

Documents/supports

MOOC de François Husson

- disponible ici https://husson.github.io/MOOC_AnaDo/classif.html
- vidéos - Quiz - Supports

Objectifs divers

- Beaucoup de groupes avec peu d'individus à l'intérieur (réduire n)

Objectifs divers

- Beaucoup de groupes avec peu d'individus à l'intérieur (réduire n)
- Peu de groupes avec beaucoup d'individus à l'intérieur (extraire des profils que l'on interprète par la suite).

Objectifs divers

- Beaucoup de groupes avec peu d'individus à l'intérieur (réduire n)
- Peu de groupes avec beaucoup d'individus à l'intérieur (extraire des profils que l'on interprète par la suite).

Conséquence

Les algorithmes seront proches mais pas calibrés de la même façon.

Modélisation statistique

- n observations $x_1, \dots, x_n$ à valeurs dans $\mathbb{R}^d$.

Le problème

Trouver une partition de $\{x_1, \dots, x_n\}$: on cherche donc $\mathcal{C}_1, \dots, \mathcal{C}_K$ tels que

$$\bigcup_{k=1}^{K} \mathcal{C}_k = \{x_1, \dots, x_n\} \quad \text{et} \quad \mathcal{C}_k \cap \mathcal{C}_{k'} = \emptyset \quad \text{si} \quad k \neq k'.$$

Chaque élément de la partition $\mathcal{C}_k$ est appelé cluster.

Modélisation statistique

- n observations $x_1, \dots, x_n$ à valeurs dans $\mathbb{R}^d$.

Le problème

Trouver une partition de $\{x_1, \dots, x_n\}$: on cherche donc $\mathcal{C}_1, \dots, \mathcal{C}_K$ tels que

$$\bigcup_{k=1}^{K} \mathcal{C}_k = \{x_1, \dots, x_n\} \quad \text{et} \quad \mathcal{C}_k \cap \mathcal{C}_{k'} = \emptyset \quad \text{si} \quad k \neq k'.$$

Chaque élément de la partition $\mathcal{C}_k$ est appelé cluster.

- Notions de ressemblance, similarité, hiérarchie.
- Choix du nombre de classes K.

Un exemple jouet

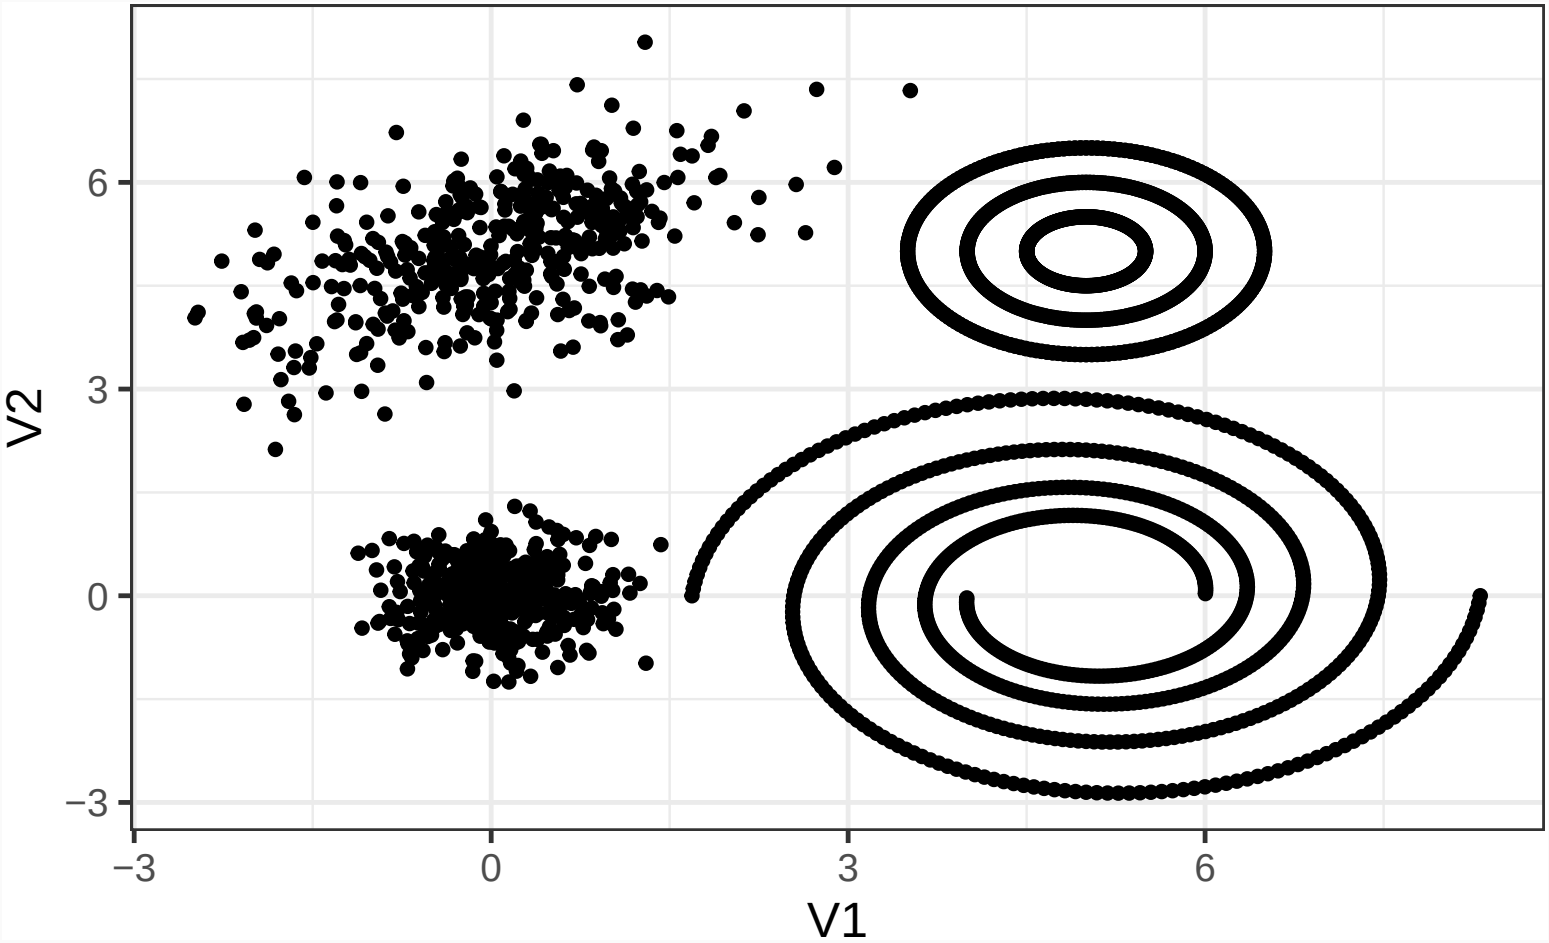

4 types d'algorithmes

1. Méthodes de partitionnement (k-means)

4 types d'algorithmes

1. Méthodes de partitionnement (k-means)
2. Méthodes hiérarchiques (CAH)

4 types d'algorithmes

1. Méthodes de partitionnement (k-means)
2. Méthodes hiérarchiques (CAH)
3. Algorithmes basés sur les densités (DBSCAN)

4 types d'algorithmes

1. Méthodes de partitionnement (k-means)
2. Méthodes hiérarchiques (CAH)
3. Algorithmes basés sur les densités (DBSCAN)
4. Approches basées sur les graphes (clustering spectral)

Partitionnement : les k-means

Le critère des k-means

- Idée : Définir les clusters $\mathcal{C}_k$ à partir de représentants c_k.
- Nombre de groupes K fixé.

Le critère des k-means

- Idée : Définir les clusters $\mathcal{C}_k$ à partir de représentants c_k.
- Nombre de groupes K fixé.

Le critère des k-means

On cherche la partition $\mathcal{C}$ et les représentants c qui minimise le critère

$$g(\mathcal{C}, c) = \sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} \|x_i - c_k\|^2.$$

Le critère des k-means

- Idée : Définir les clusters $\mathcal{C}_k$ à partir de représentants c_k.
- Nombre de groupes K fixé.

Le critère des k-means

On cherche la partition $\mathcal{C}$ et les représentants c qui minimise le critère

$$g(\mathcal{C}, c) = \sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} \|x_i - c_k\|^2.$$

- **Impossible** de trouver $(\mathcal{C}^\star, c^\star)$ qui minimise $g(\mathcal{C}, c)$.

Équivalences, (Bock 2008)

1. Quand on fixe une partition $\mathcal{C}^*$, les meilleurs représentants sont les moyennes $\hat{c} = (\bar{x}_{\mathcal{C}_1}, \dots, \bar{x}_{\mathcal{C}_K})$

$$\forall c \quad g(\mathcal{C}^*, c) \geq g(\mathcal{C}^*, \hat{c})$$

Équivalences, (Bock 2008)

1. Quand on fixe une partition $\mathcal{C}^*$, les meilleurs représentants sont les moyennes $\hat{c} = (\bar{x}_{\mathcal{C}_1}, \dots, \bar{x}_{\mathcal{C}_K})$

$$\forall c \quad g(\mathcal{C}^*, c) \geq g(\mathcal{C}^*, \hat{c})$$

2. Quand on fixe des représentants c, la meilleure partition $\widehat{\mathcal{C}} = \{\widehat{\mathcal{C}}_1, \dots, \widehat{\mathcal{C}}_K\}$ est celle de la distance minimale (partition de Voronoi) définie par

$$\widehat{\mathcal{C}}_k = \{i \in \{1, \dots, n\} \text{ tels que } \|x_i - c_k\|^2 = \min_j \|x_i - c_j\|^2\}$$

Elle réalise le minimum à représentants fixés:

$$\forall \mathcal{C} \quad g(\mathcal{C}, c) \geq g(\widehat{\mathcal{C}}, c)$$

Idée

Construire les centres et la partition de manière récursive.

Idée

Construire les centres et la partition de manière récursive.

Comment ?

En utilisant un algorithme :

- Lloyd (1982)
- Forgy (1965)
- MacQueen (1967)
- Hartigan et Wong (1979)

on pourra consulter https://towardsdatascience.com/three-versions-of-k-means-cf939b65f4ea.

Lloyd (1982)

1. **Initialisation** : choix de k points au hasard comme centroïde.
2. **Affectation** de chaque observation au centroïde le plus proche.
3. **Mise à jour** des centroïdes.

Exemple

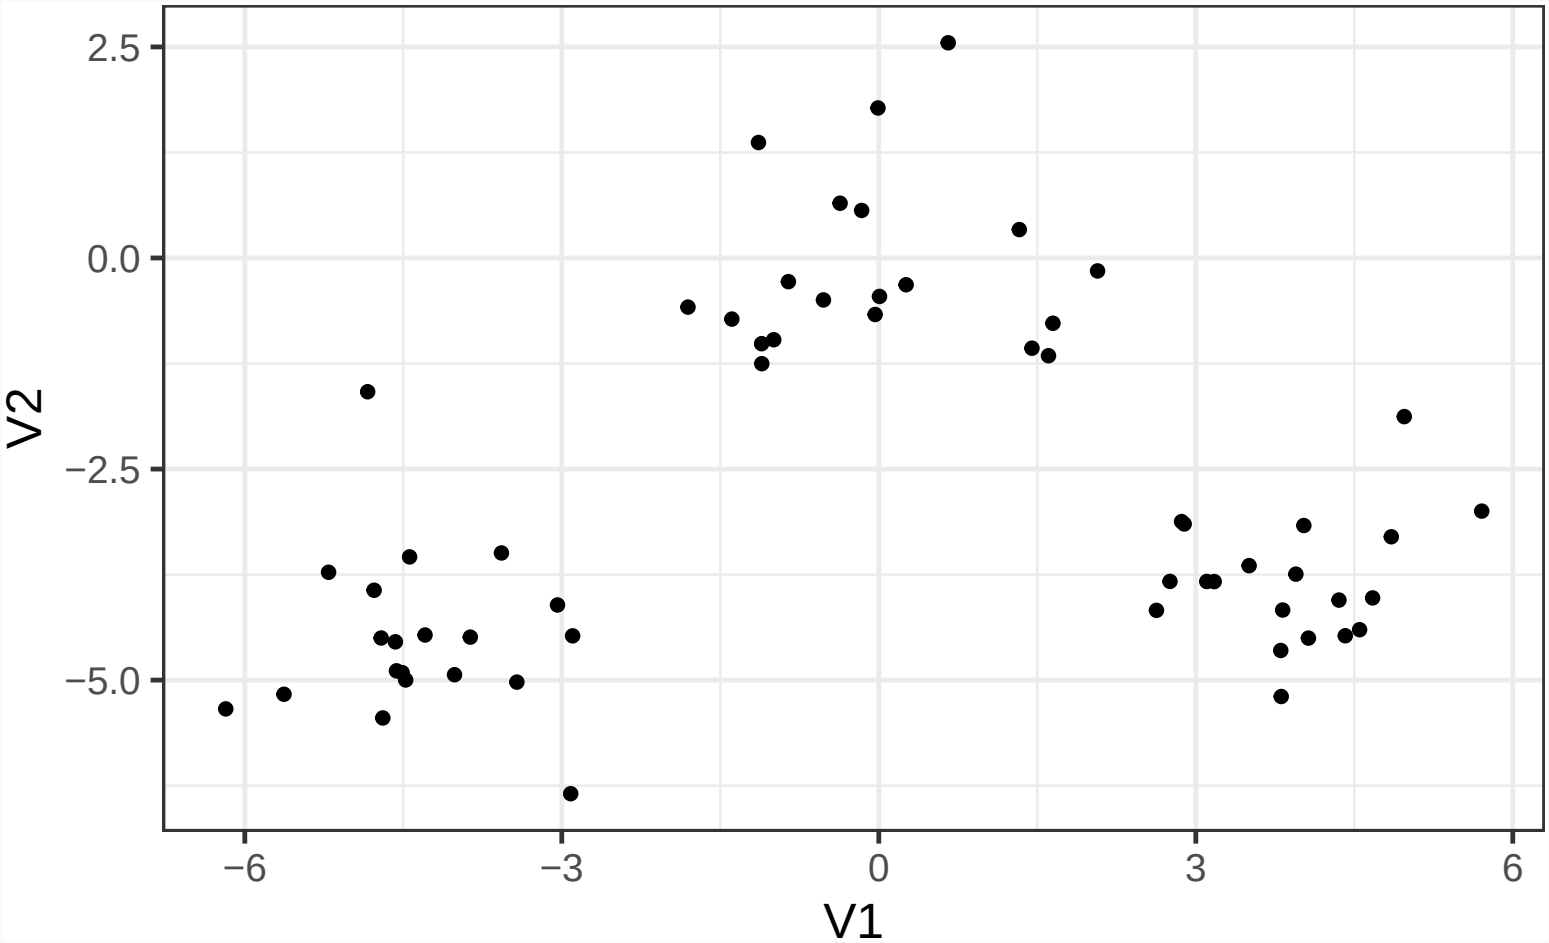

Exemple

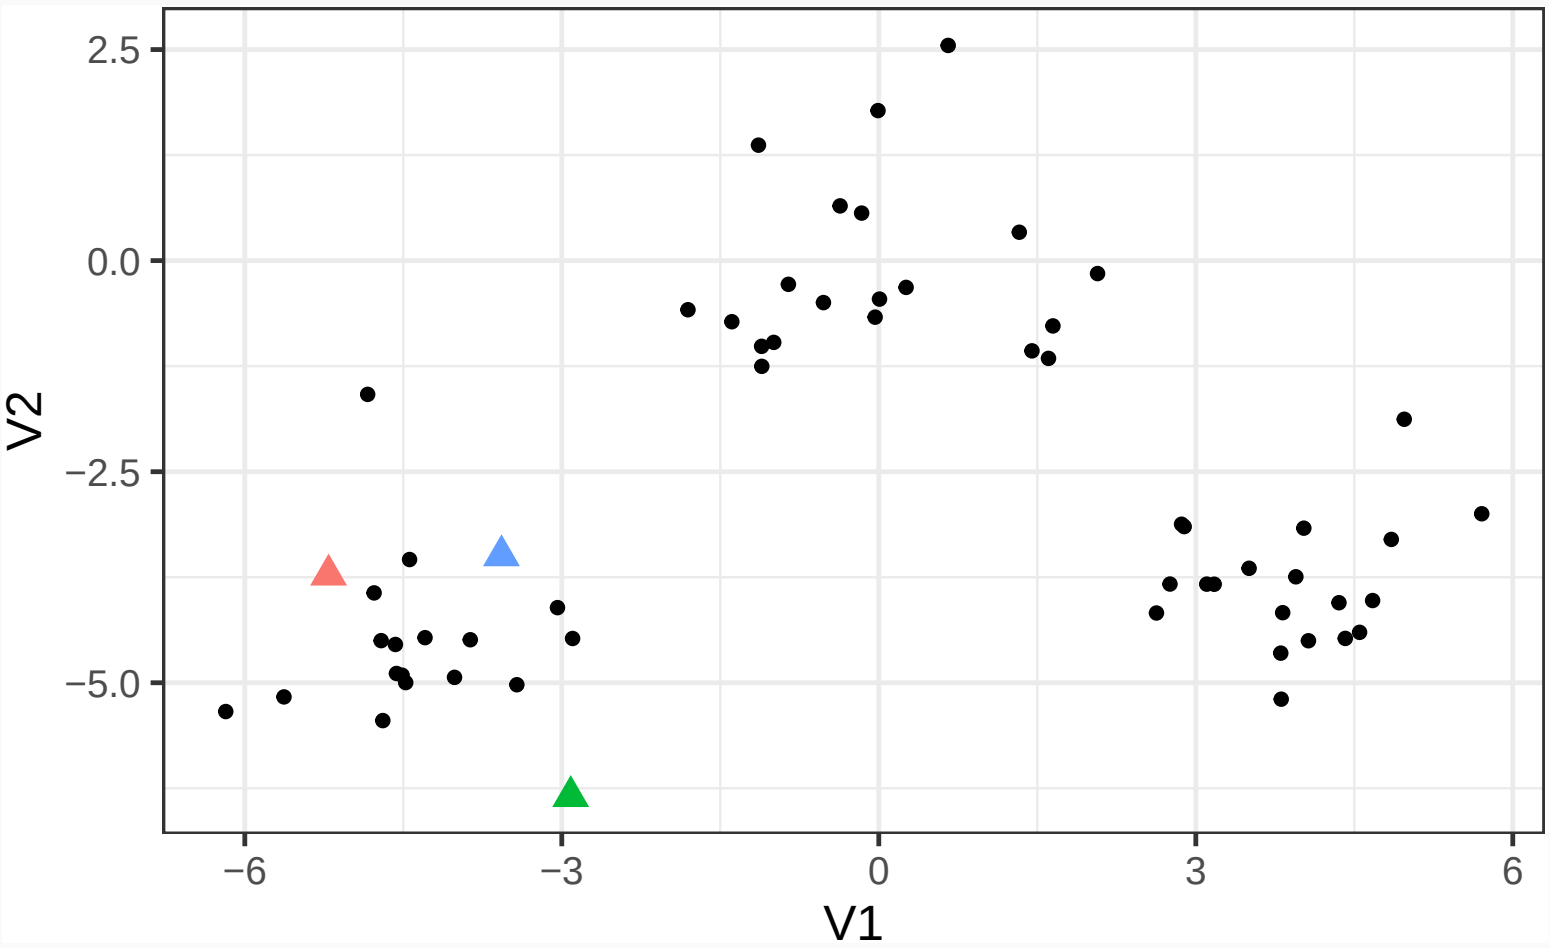

Exemple

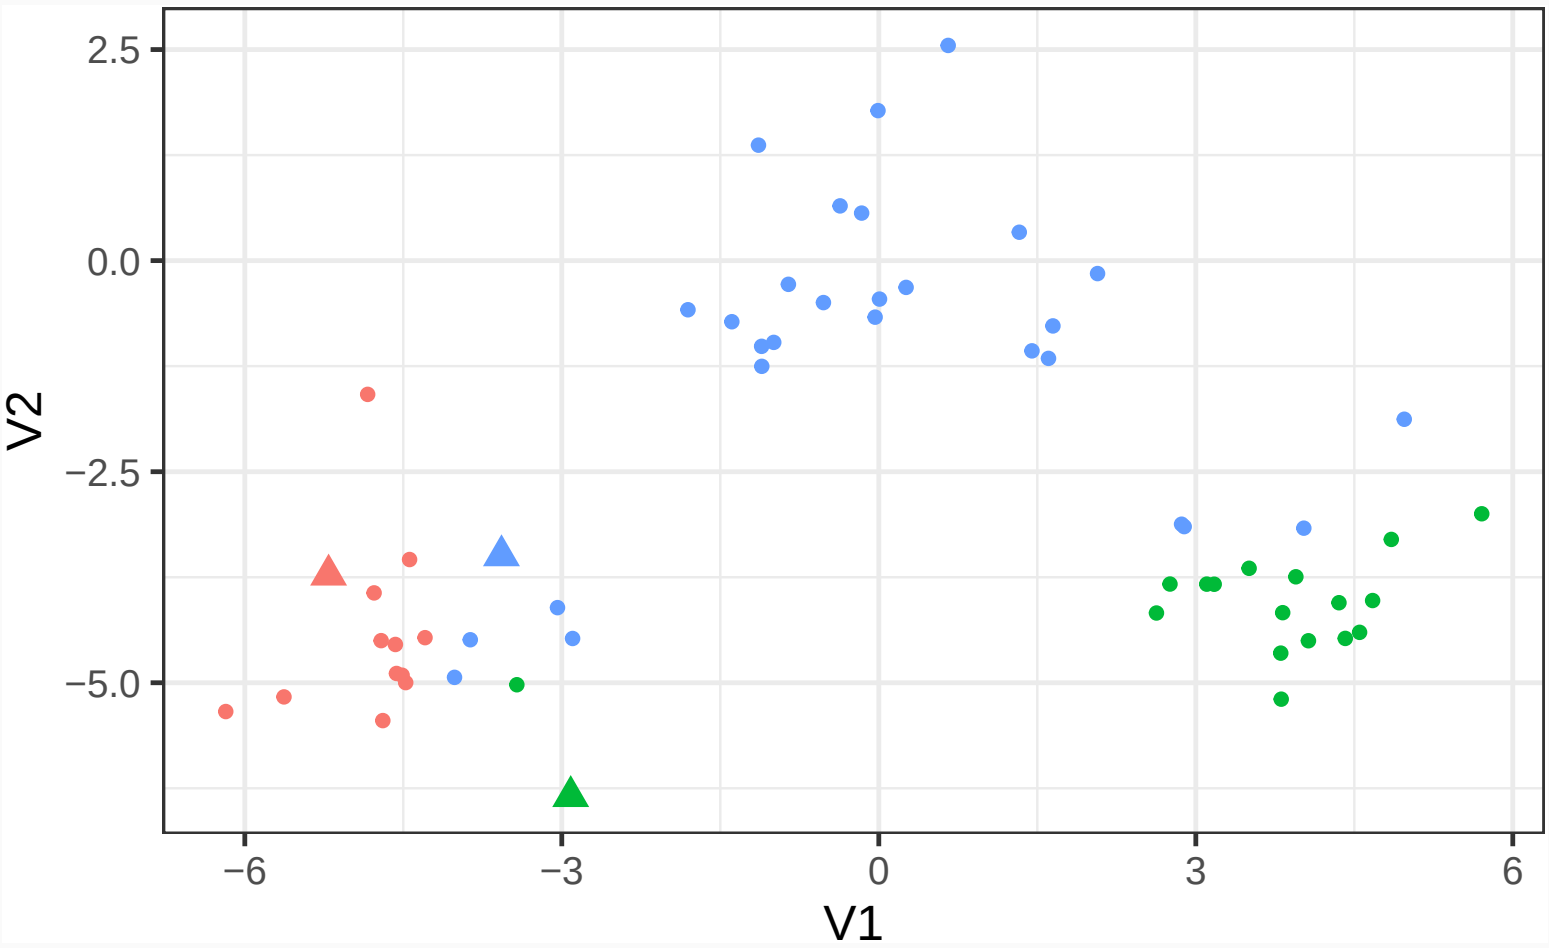

Exemple

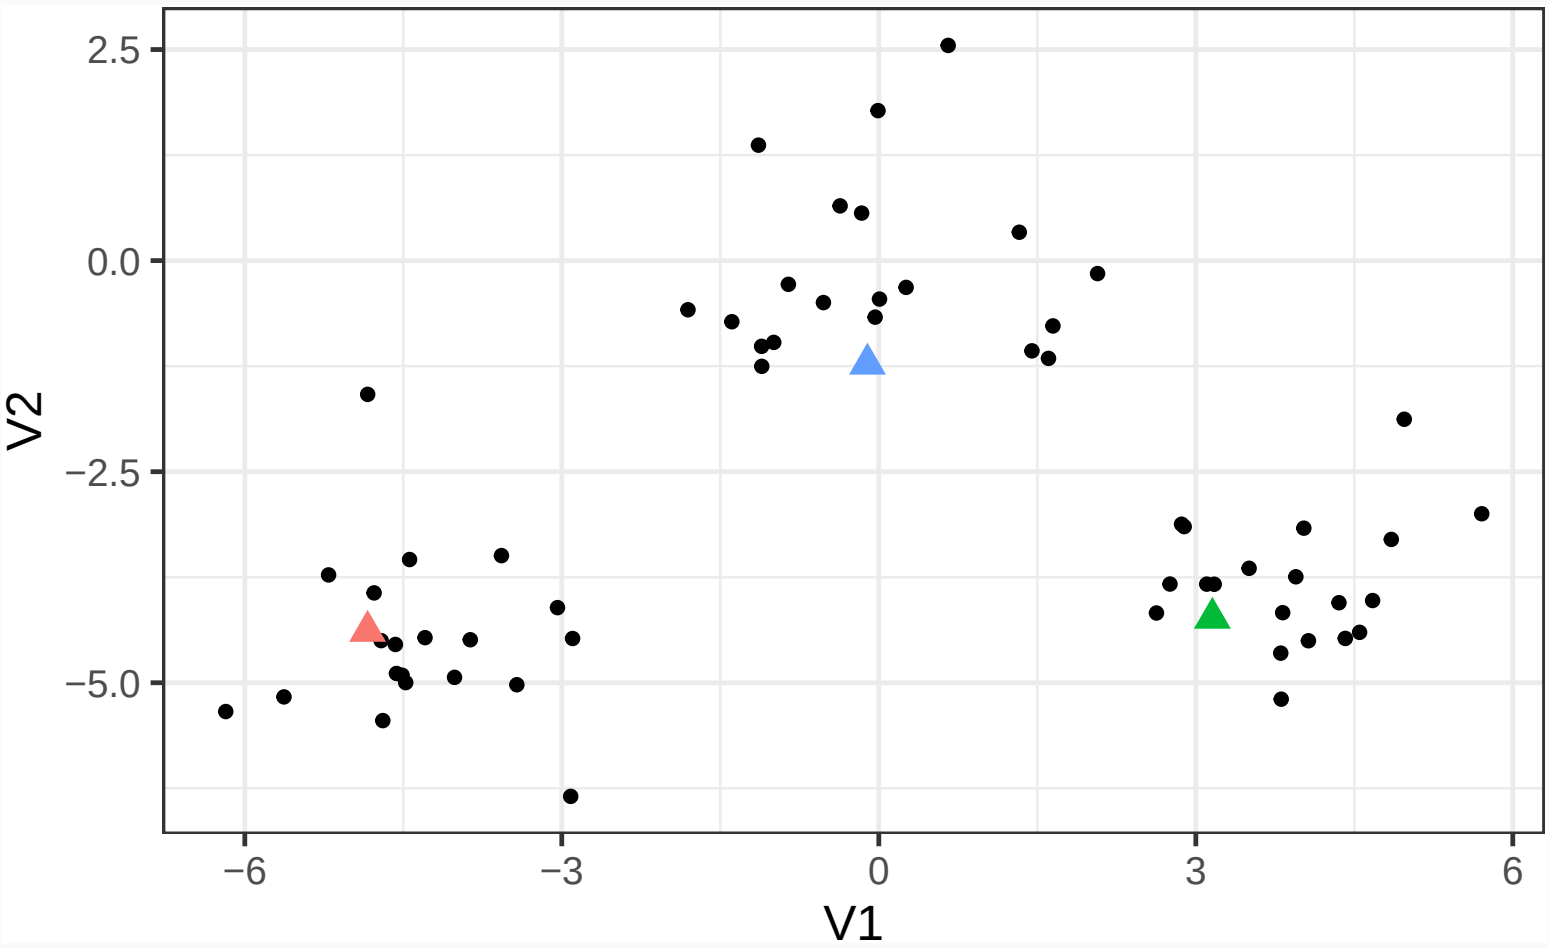

Exemple

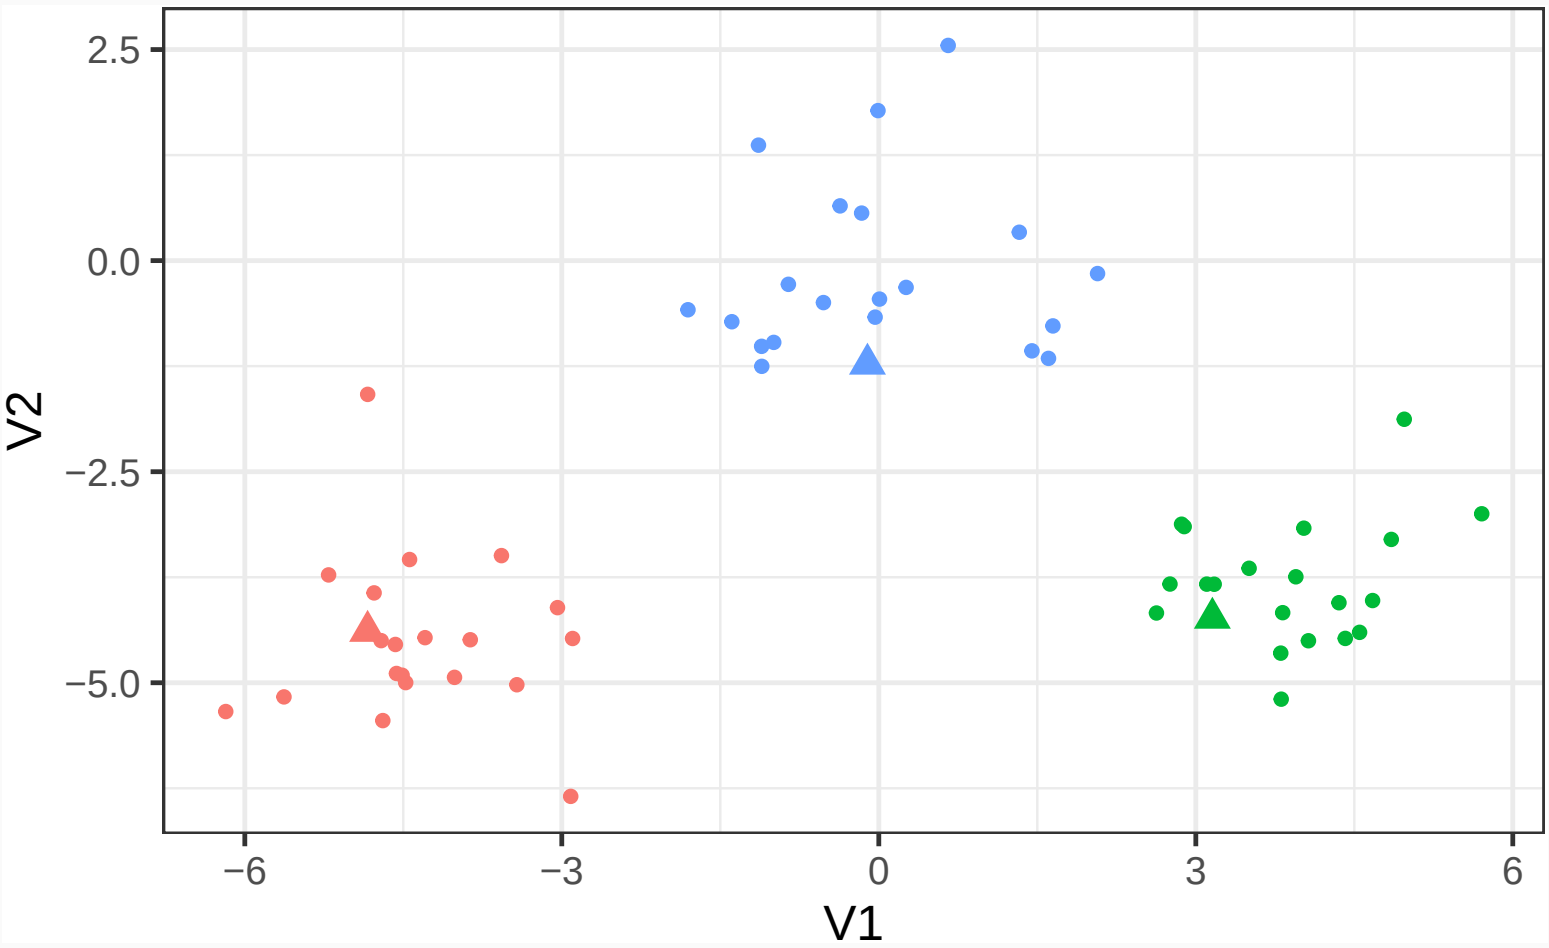

Hartigan et Wong (1979)

1. **Initialisation** : choix de K points au hasard comme centroïde
2. Pour $i = 1, \dots, n$
   a. Pour $k = 1, \dots, K$
      - Affecter x_i à c_k
      - calculer $\alpha_k = \sum_{i=1}^{n} \|x_i - c_{k,i}\|^2$
   b. Affecter x_i au centroïde qui minimise α_k
   c. Mettre à jour les centroïdes
3. Répéter 2 jusqu'à convergence

Hartigan et Wong (1979)

1. **Initialisation** : choix de K points au hasard comme centroïde
2. Pour $i = 1, \dots, n$
   a. Pour $k = 1, \dots, K$
      - Affecter x_i à c_k
      - calculer $\alpha_k = \sum_{i=1}^{n} \|x_i - c_{k,i}\|^2$
   b. Affecter x_i au centroïde qui minimise α_k
   c. Mettre à jour les centroïdes
3. Répéter 2 jusqu'à convergence

Remarque

Généralement recommandé avec plusieurs initialisations.

Le coin R

```
> res <- kmeans(tbl[,2:3],centers = 3,
+               algorithm = "Hartigan-Wong",nstart=100)
> centres <- res$centers |> as_tibble() |> mutate(groupes=as.factor(1:3))
> tbl |> mutate(groupes=as.factor(res$cluster)) |> ggplot()+
+   aes(x=V1,y=V2,color=groupes)+geom_point() +
+   geom_point(data=centres,shape=17,size=2)
```

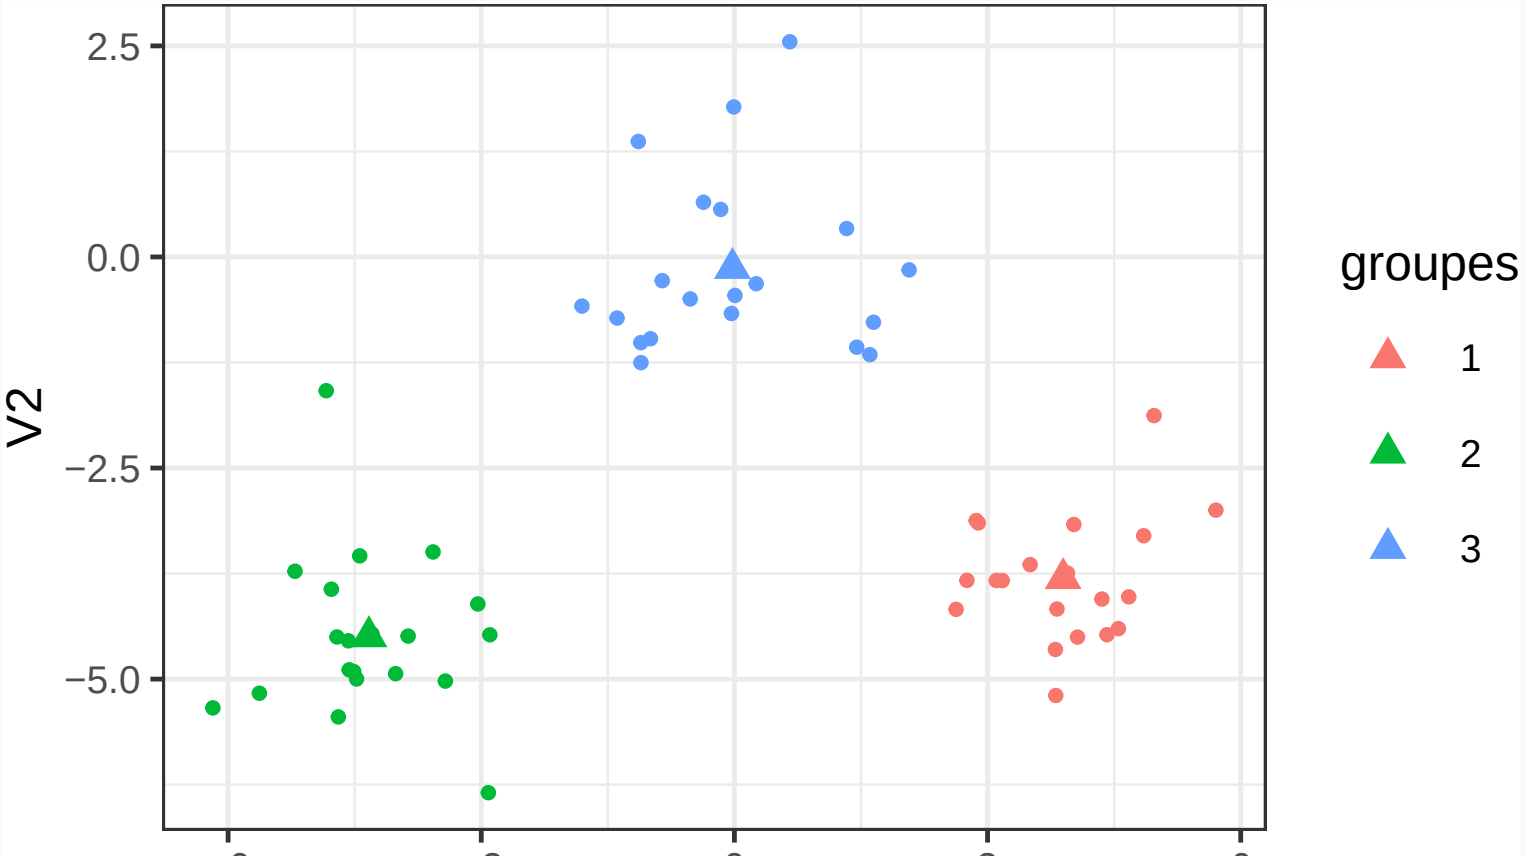

Bilan

Avantages

- Facile à mettre en œuvre
- Faible complexité $O(n)$

Bilan

Avantages

- Facile à mettre en œuvre
- Faible complexité $O(n)$

Inconvénients

- Clusters “sphériques”.
- Choix de k.
- Choix de la distance (grande dimension ?).

Méthodes hiérarchiques

Méthodes hiérarchiques

Objectif

Créer une suite de partitions emboitées en partant de la partition la plus fine (n classes) jusqu'à obtenir une seule classe.

Le processus hiérarchique

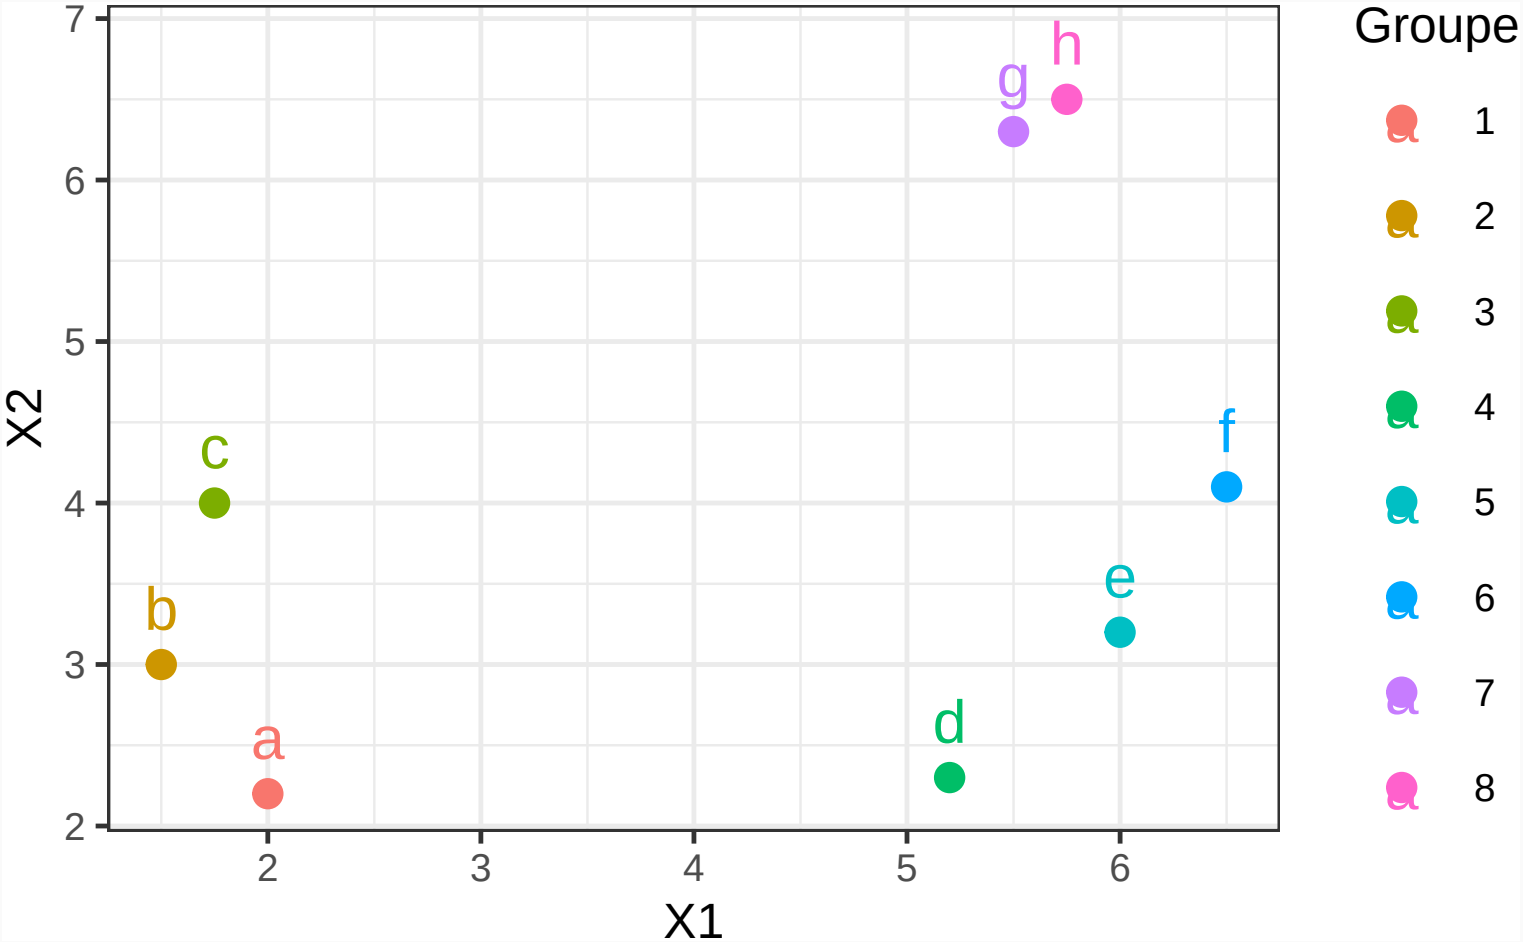

Le processus hiérarchique

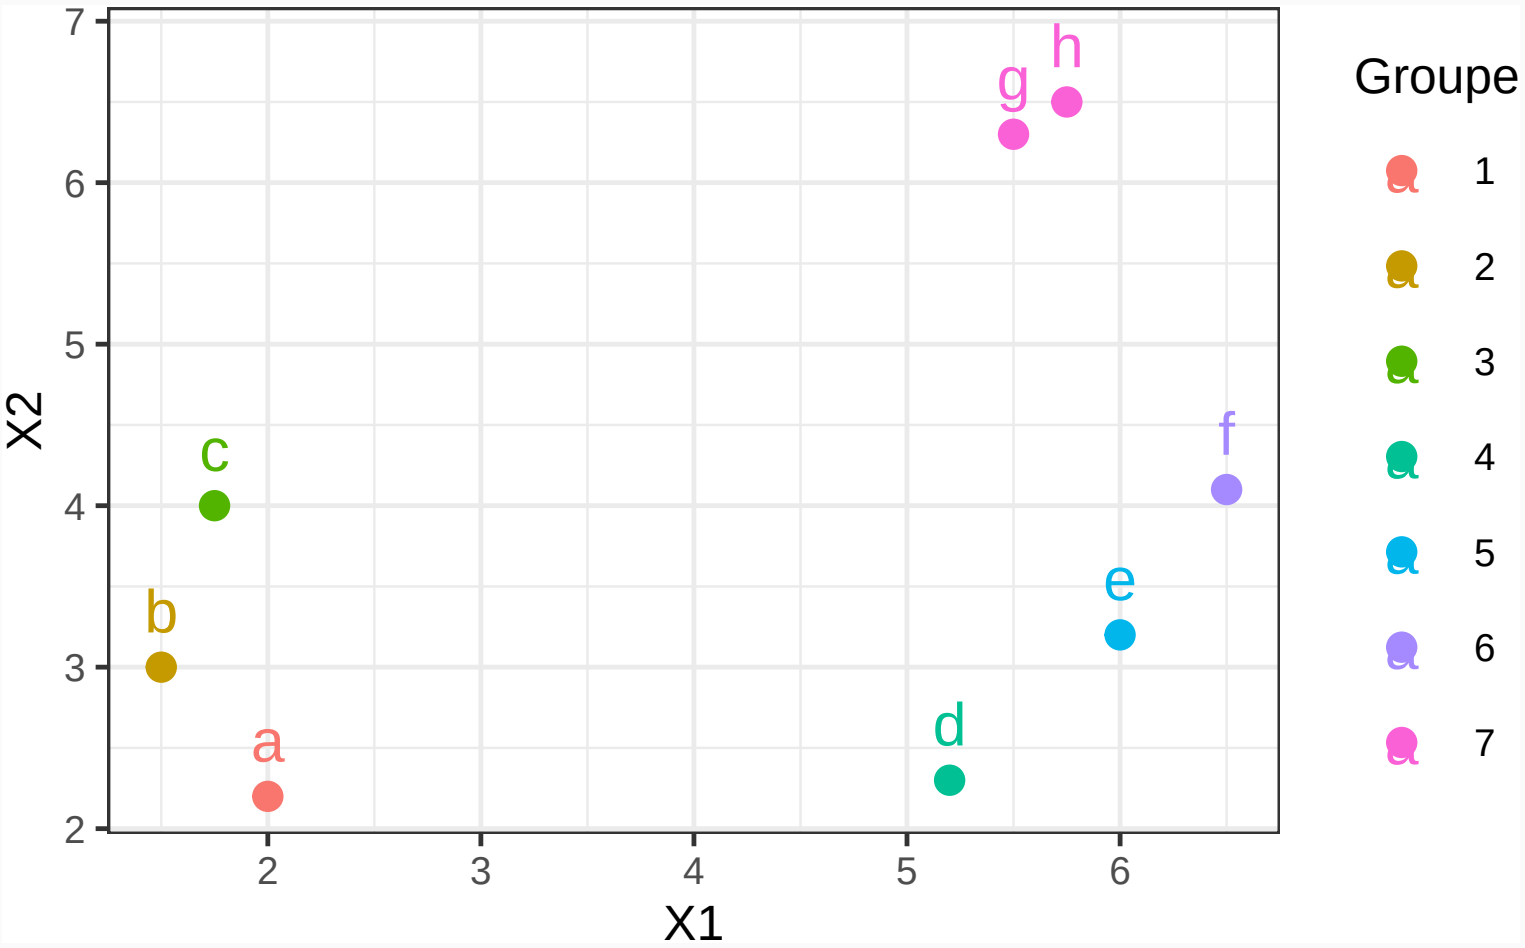

Le processus hiérarchique

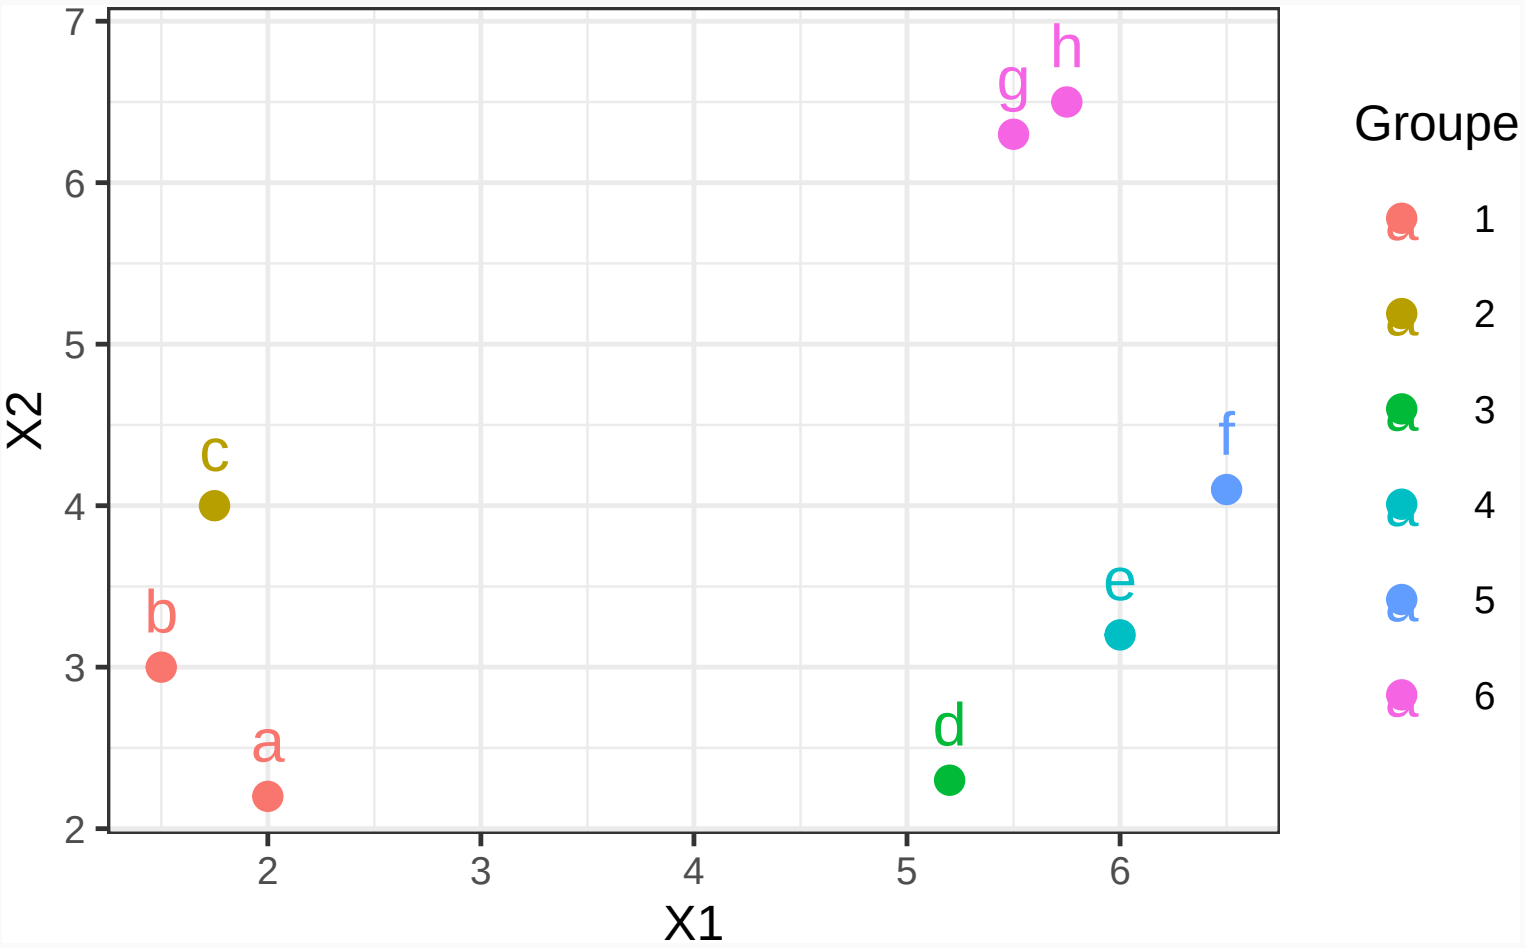

Le processus hiérarchique

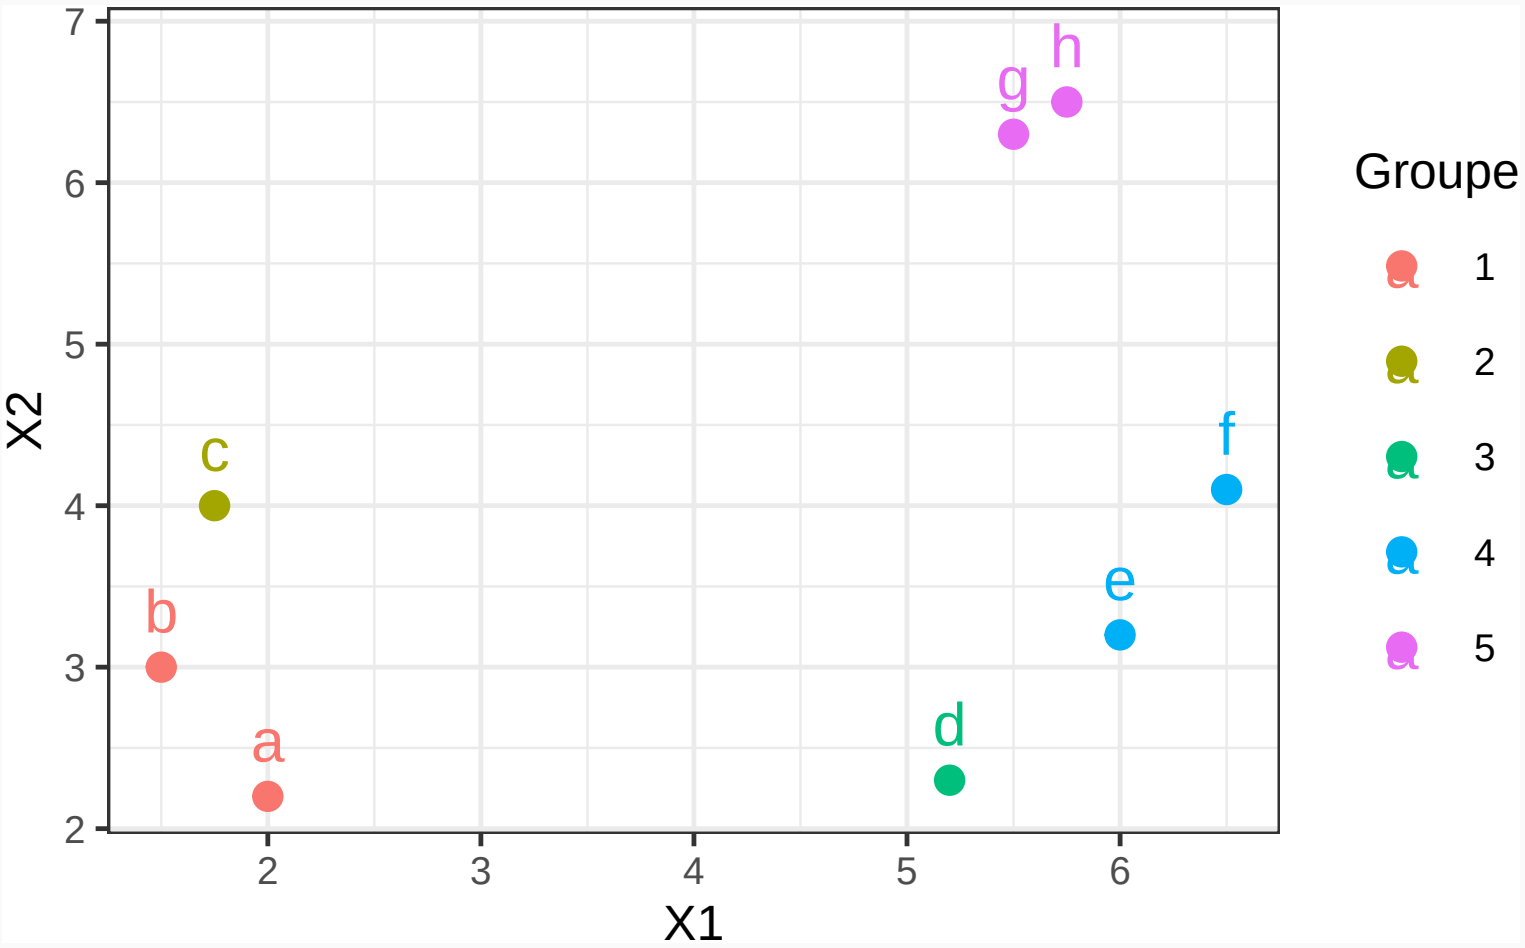

Le processus hiérarchique

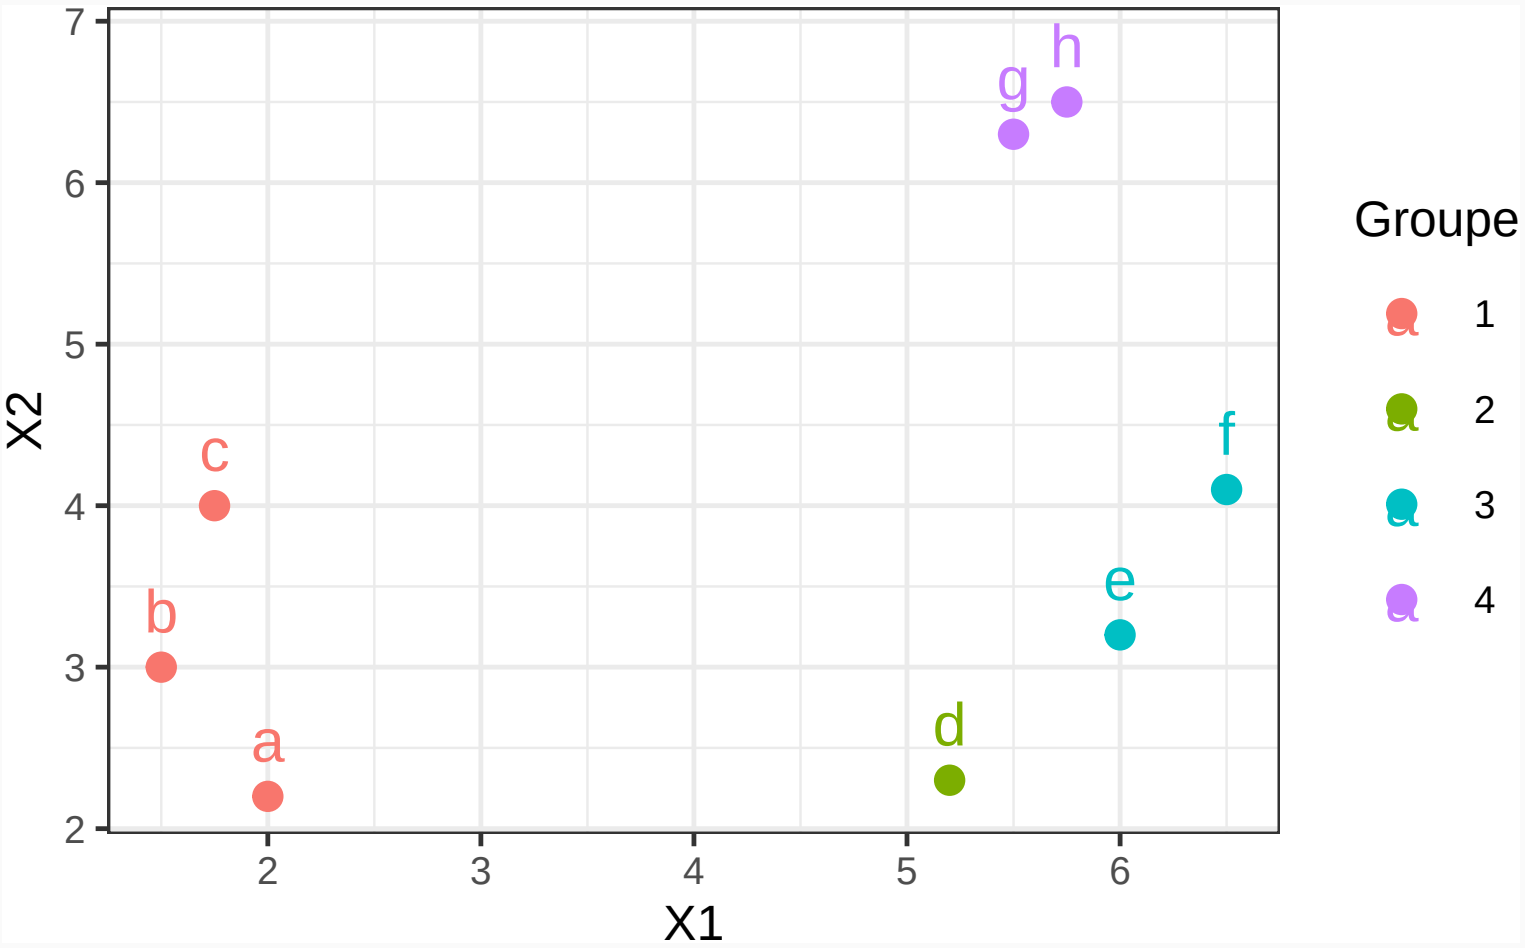

Le processus hiérarchique

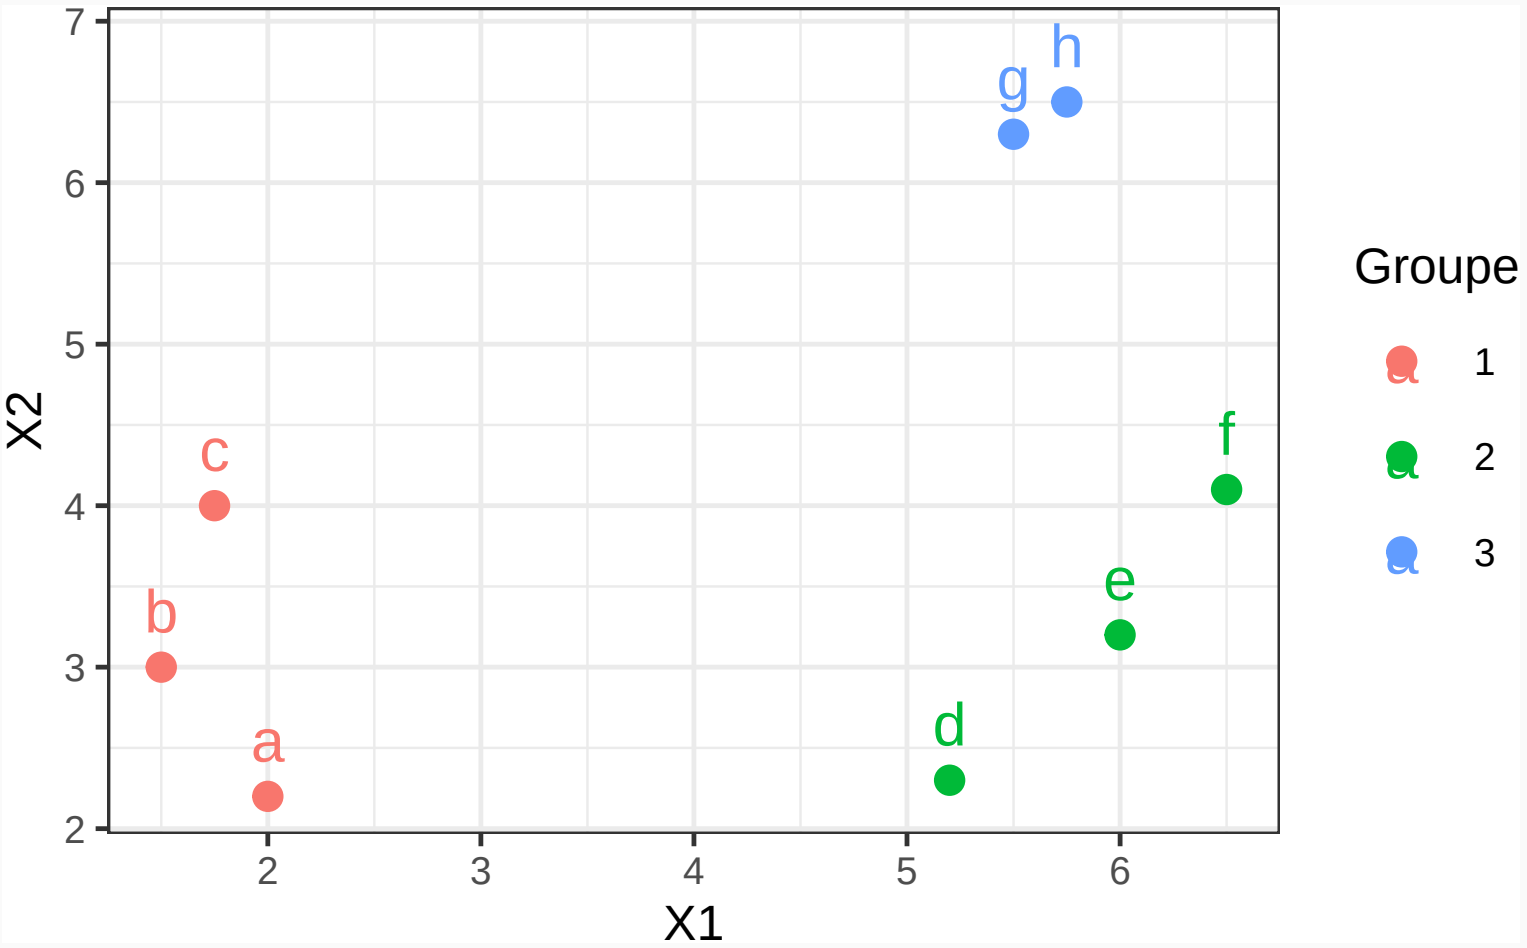

Le processus hiérarchique

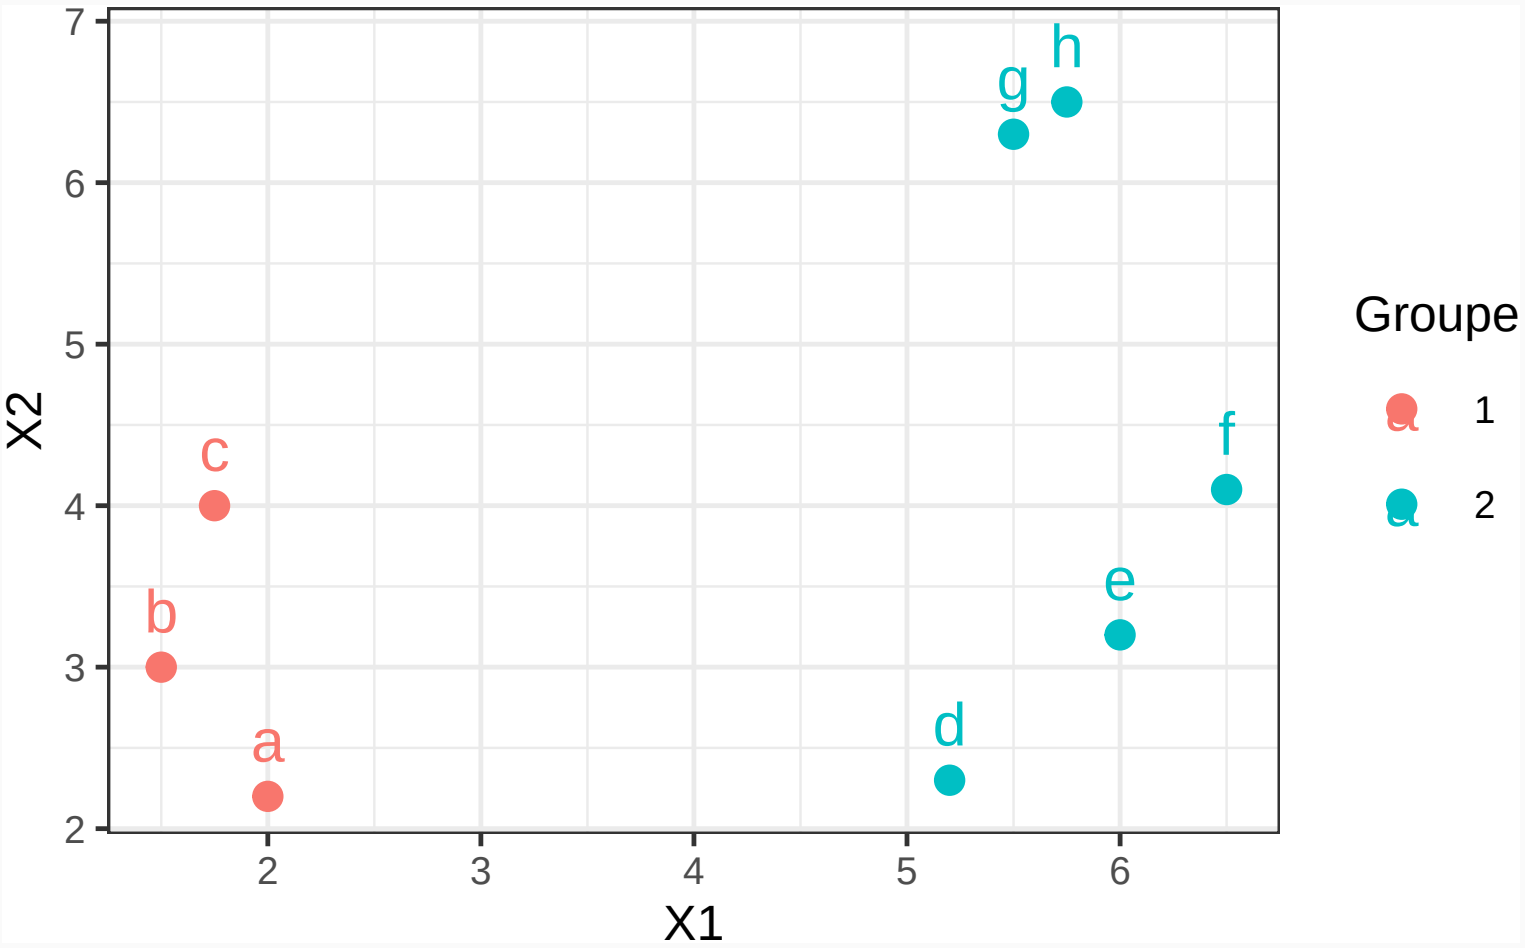

Le processus hiérarchique

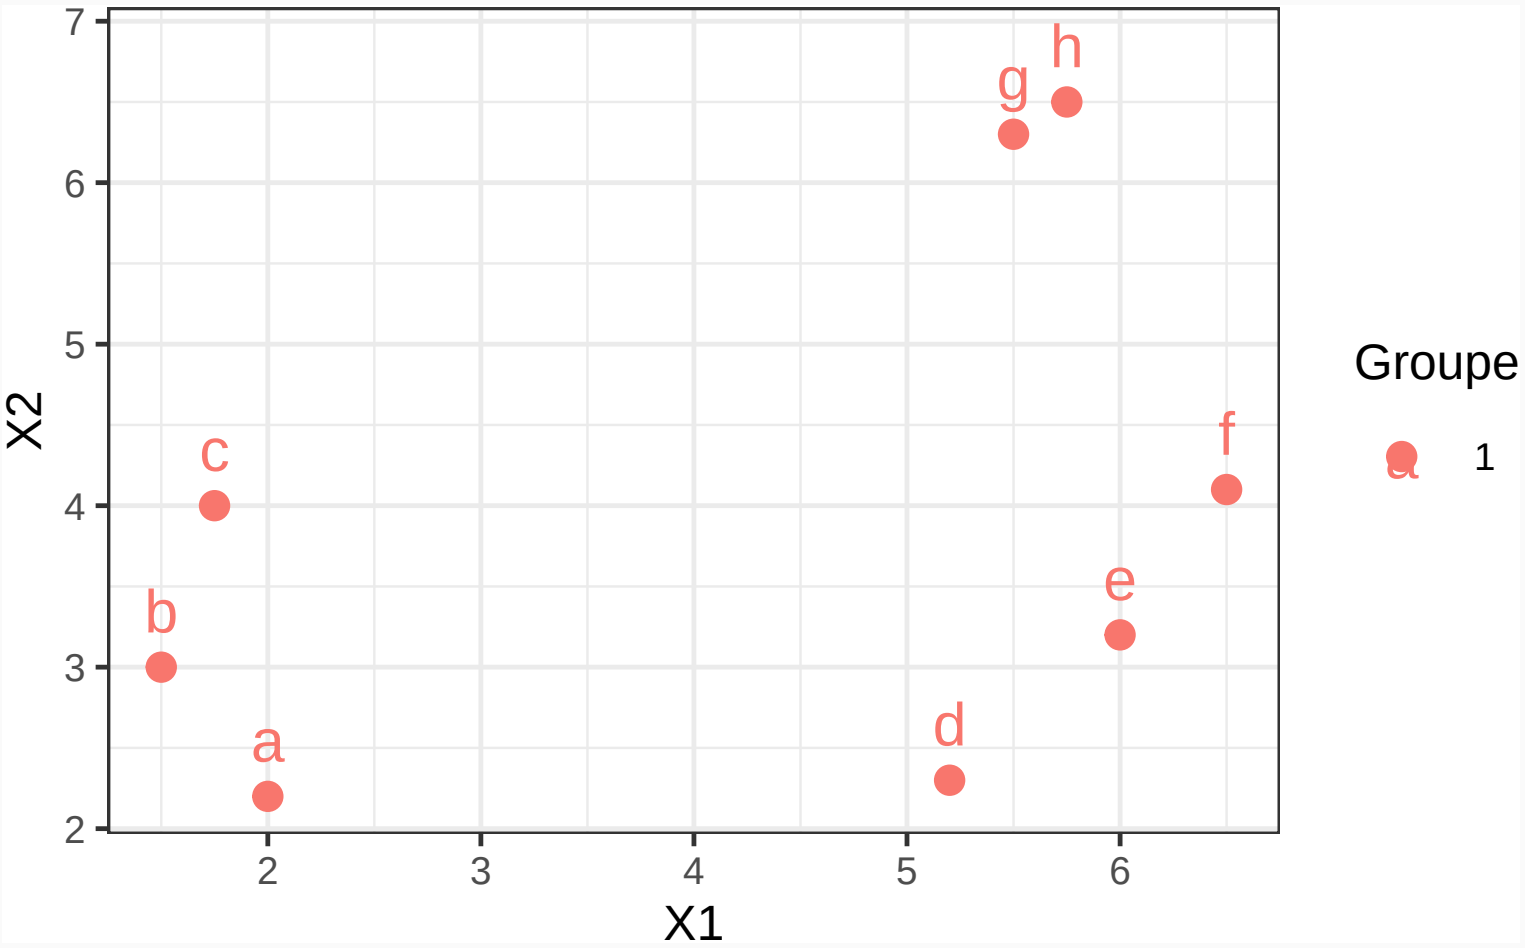

Visualisation

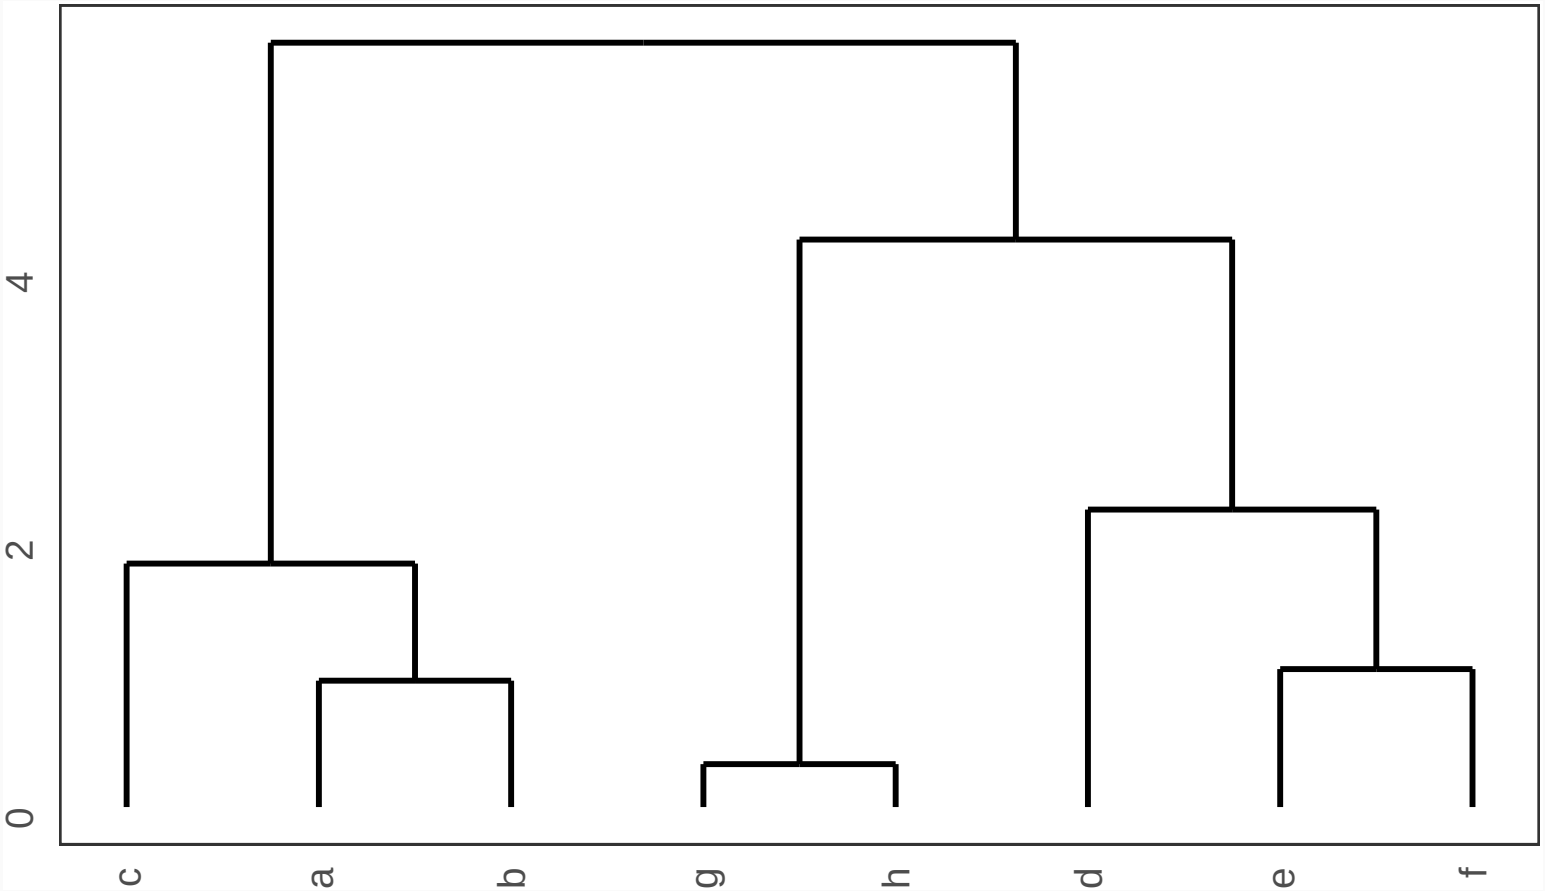

Méthodes hiérarchiques

La Classification Ascendante Hiérarchique

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de distances entre individus.

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de distances entre individus.
2. Chaque observation forme 1 singleton.

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de distances entre individus.
2. Chaque observation forme 1 singleton.
3. Agréger les deux objets les plus proches.

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de distances entre individus.
2. Chaque observation forme 1 singleton.
3. Agréger les deux objets les plus proches.
4. Mettre à jour la matrice de distances.

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de distances entre individus.
2. Chaque observation forme 1 singleton.
3. Agréger les deux objets les plus proches.
4. Mettre à jour la matrice de distances.
5. Itérer jusqu'à obtenir un seul groupe.

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de distances entre individus.
2. Chaque observation forme 1 singleton.
3. Agréger les deux objets les plus proches.
4. Mettre à jour la matrice de distances.
5. Itérer jusqu'à obtenir un seul groupe.

Sorties : une suite de partitions emboîtées.

De quoi a t-on besoin ?

Pas grand chose...

De quoi a t-on besoin ?

Pas grand chose... il suffit de savoir calculer des distances et/ou indicateurs de similarités entre

- des observations. On notera d une telle distance
- des groupes d'observations, *i.e.* entre clusters. On notera Δ une telle distance.

Méthodes hiérarchiques

Mesures de dissemblances

Saut minimum

- Également appelé minimu linkage ou single linkage.

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \min_{x_i \in \mathcal{C}_i, x_j \in \mathcal{C}_j} d(x_i, x_j)$$

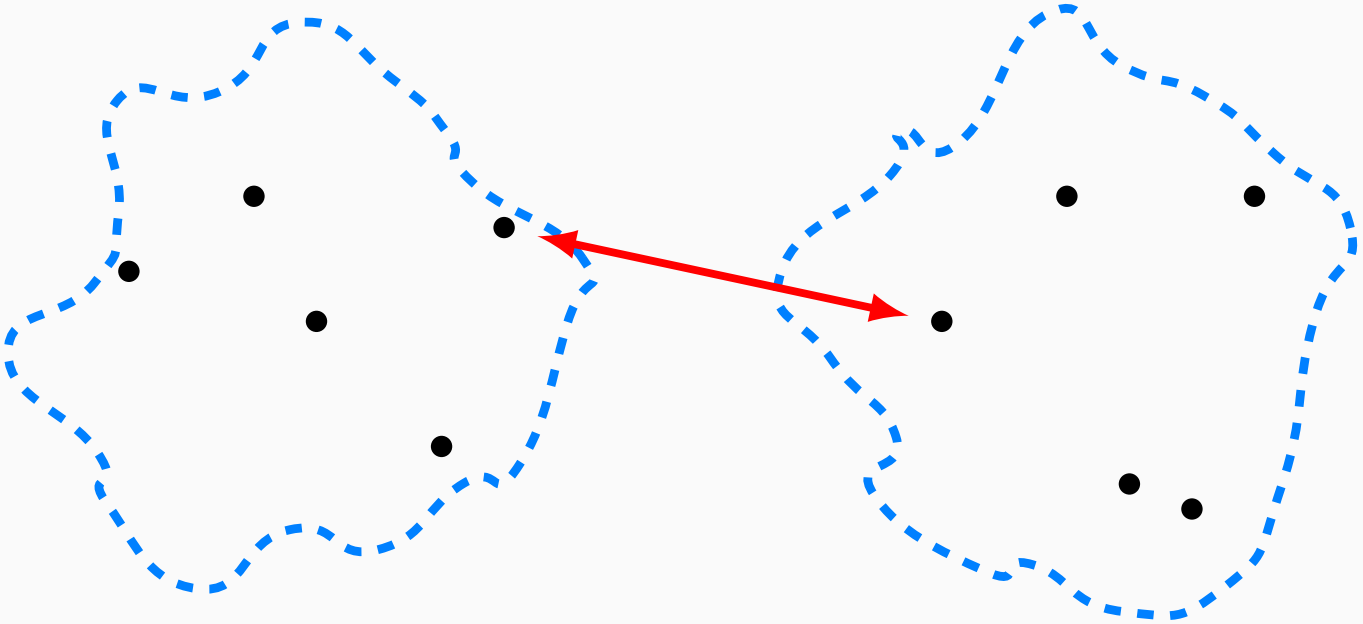

Commentaires

- Groupes généralement "étirés".
- "Le voisin de mon voisin est mon voisin".

Saut maximum

- Également appelé complete linkage.

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \max_{x_i \in \mathcal{C}_i, x_j \in \mathcal{C}_j} d(x_i, x_j)$$

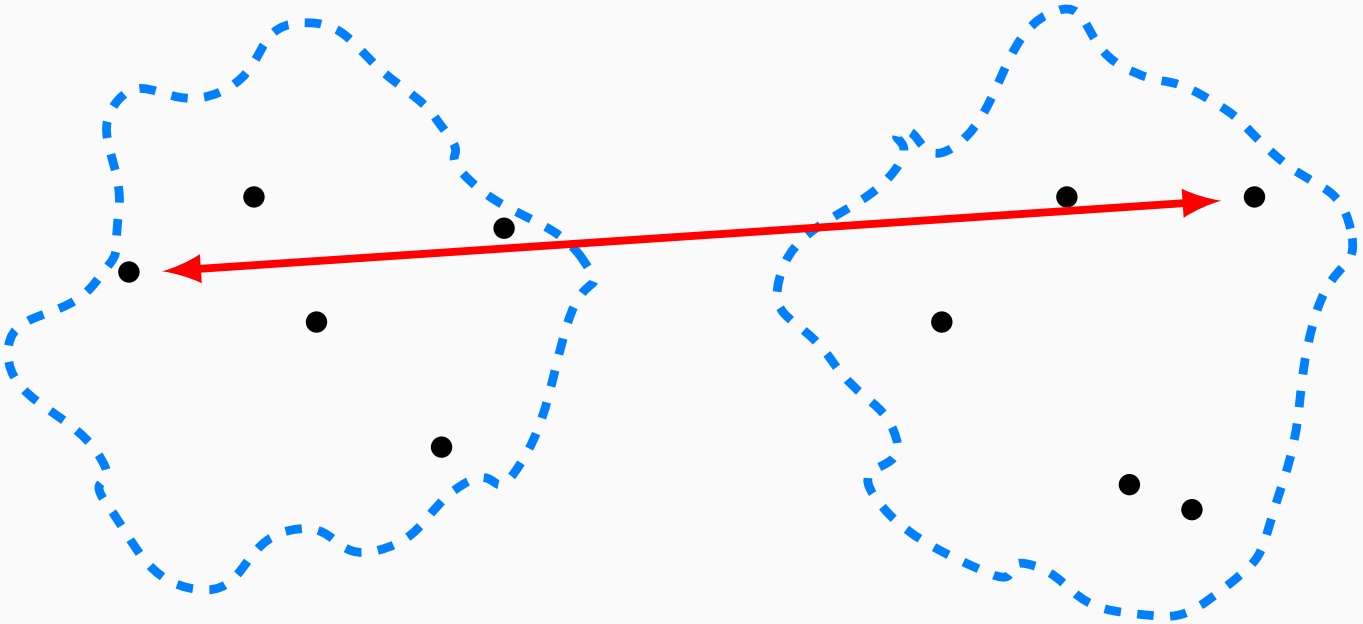

Commentaires

Groupes généralement "compacts".

Saut moyen (average linkage)

Moyenne de toutes les distances entre deux objets des deux groupes :

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum_{x_i \in \mathcal{C}_i, x_j \in \mathcal{C}_j} d(x_i, x_j)$$

Commentaires

Intermédiaires entre le min et le max...

Lien de Ward

Idée

Se baser sur l'inertie :

$$\begin{aligned}\mathcal{J}_{\text{tot}} =& \frac{1}{n}\sum_{i=1}^{n} d^2(x_i - \bar{x}) \\ =& \frac{1}{n}\sum_{k=1}^{K}\sum_{i\in\mathcal{C}_k} d^2(x_i, \bar{x}_{\mathcal{C}_k}) + \frac{1}{n}\sum_{k=1}^{K} n_k d^2(\bar{x}_{\mathcal{C}_k}, \bar{x}) \\ =& \mathcal{J}_{\text{intra}} + \mathcal{J}_{\text{inter}}\end{aligned}$$

en minimisant $\mathcal{J}_{\text{intra}}$ et/ou maximisant $\mathcal{J}_{\text{inter}}$.

Cas extrêmes

- $K = n \Longrightarrow \mathcal{J}_{\text{intra}} = 0$ et $\mathcal{J}_{\text{inter}} = \mathcal{J}_{\text{tot}}$.
- $K = 1 \Longrightarrow \mathcal{J}_{\text{intra}} = \mathcal{J}_{\text{tot}}$ et $\mathcal{J}_{\text{inter}} = 0$.

Lien de Ward

Assembler les clusters de manière à minimiser la perte de $\mathcal{J}_{\text{inter}}$

Lien de Ward

Assembler les clusters de manière à minimiser la perte de $\mathcal{J}_{\text{inter}} \iff$ minimiser le lien de Ward :

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \frac{|\mathcal{C}_i|\,|\mathcal{C}_j|}{|\mathcal{C}_i| + |\mathcal{C}_j|} d^2(\bar{x}_{\mathcal{C}_i}, \bar{x}_{\mathcal{C}_j})$$

Lien de Ward

Assembler les clusters de manière à minimiser la perte de $\mathcal{J}_{\text{inter}} \iff$ minimiser le lien de Ward :

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \frac{|\mathcal{C}_i|\,|\mathcal{C}_j|}{|\mathcal{C}_i| + |\mathcal{C}_j|} d^2(\bar{x}_{\mathcal{C}_i}, \bar{x}_{\mathcal{C}_j})$$

Commentaires

- Bien adapté à la distance euclidienne
- liens forts avec l'ACP.

Exemple

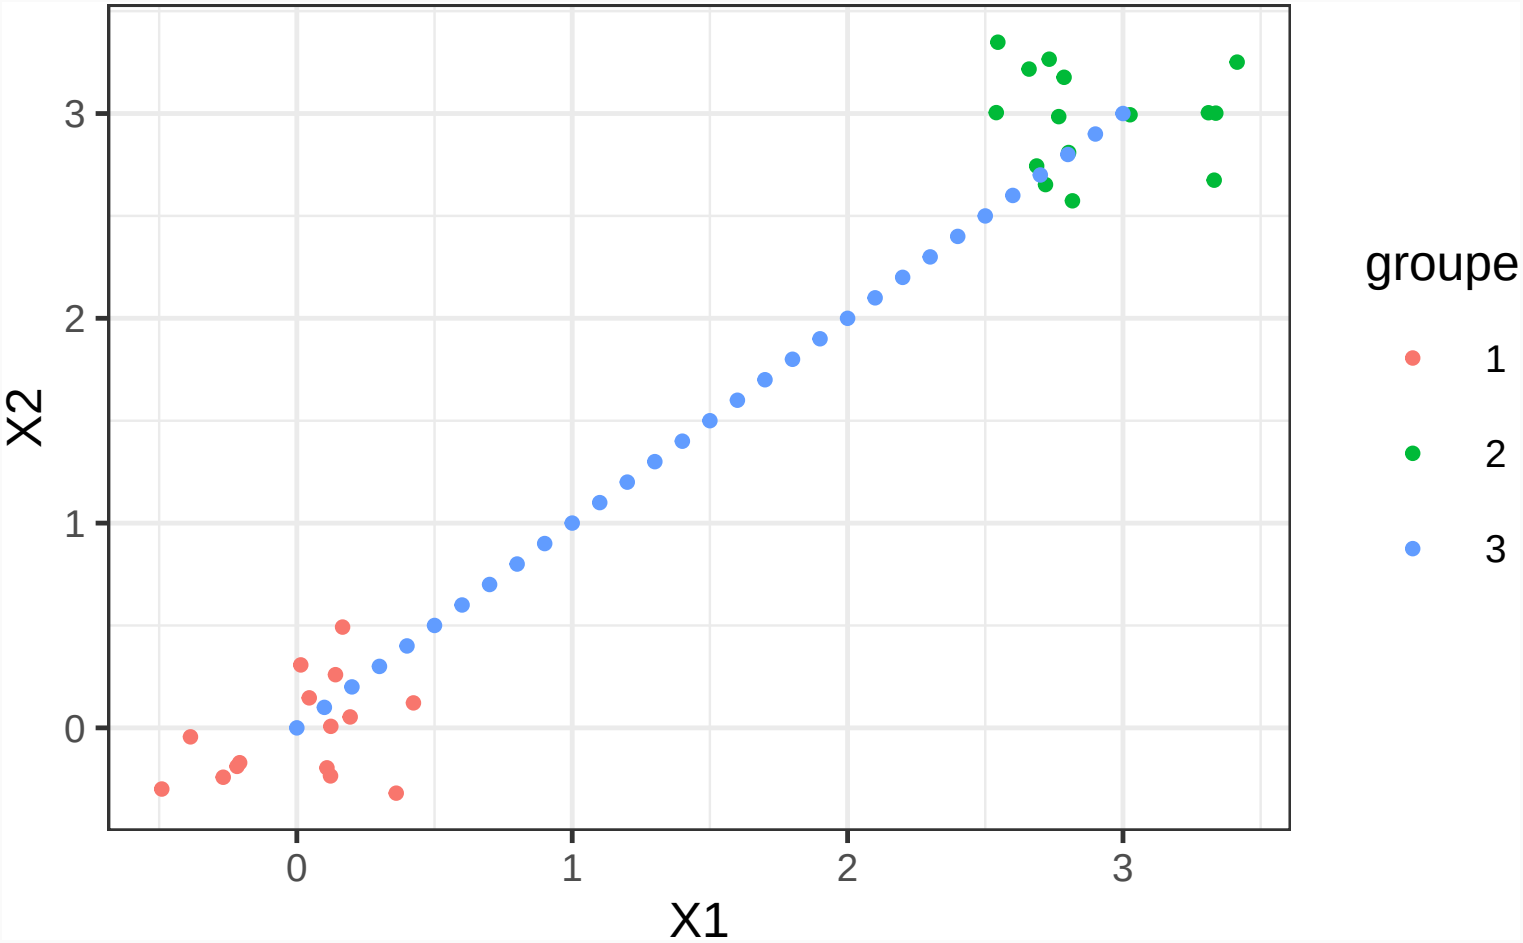

```
> class1 <- hclust(D,method = "single
> ggdendrogram(class1)
```

```
> class2 <- hclust(D,method = "ward")
> ggdendrogram(class2)
```

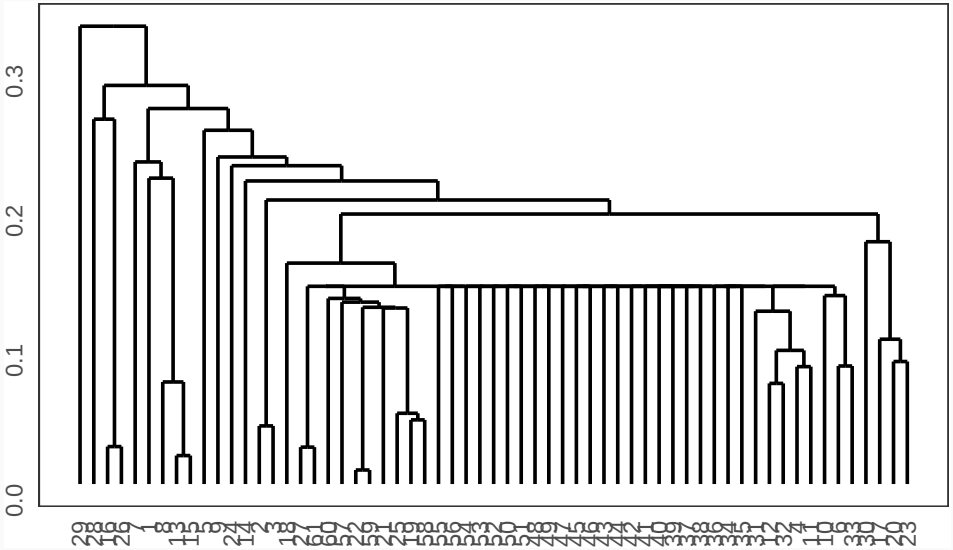

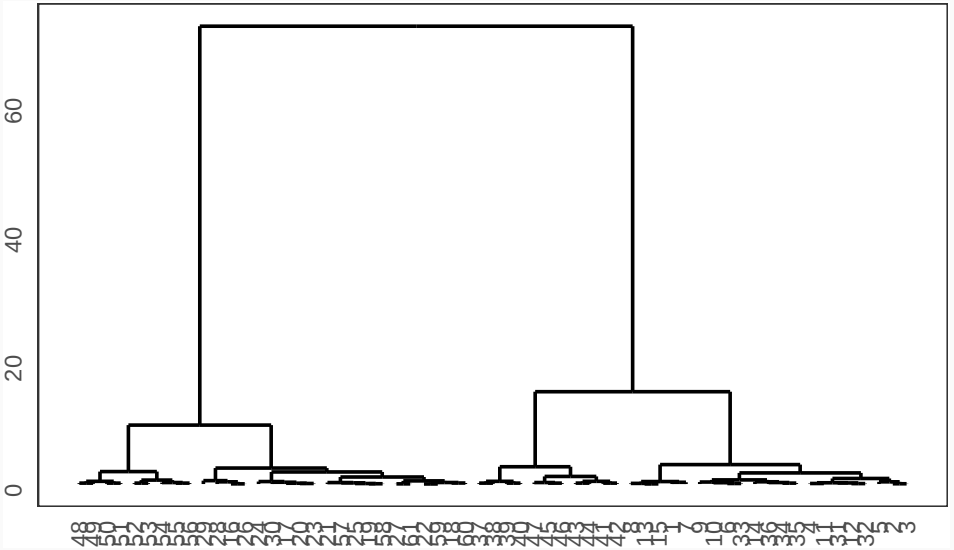

```r
> G1 <- cutree(class1,k = 2)
```

```r
> G2 <- cutree(class2,k =2)
```

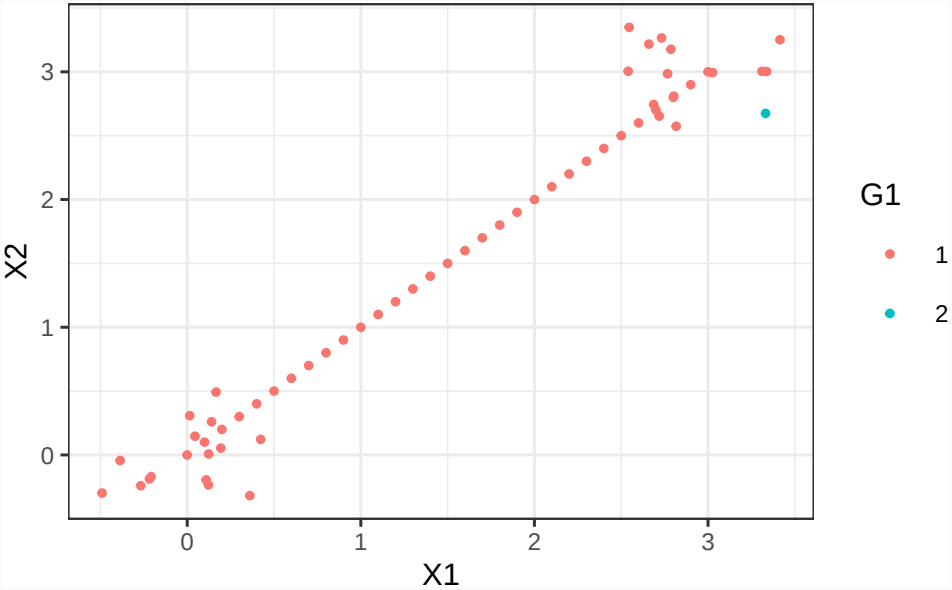

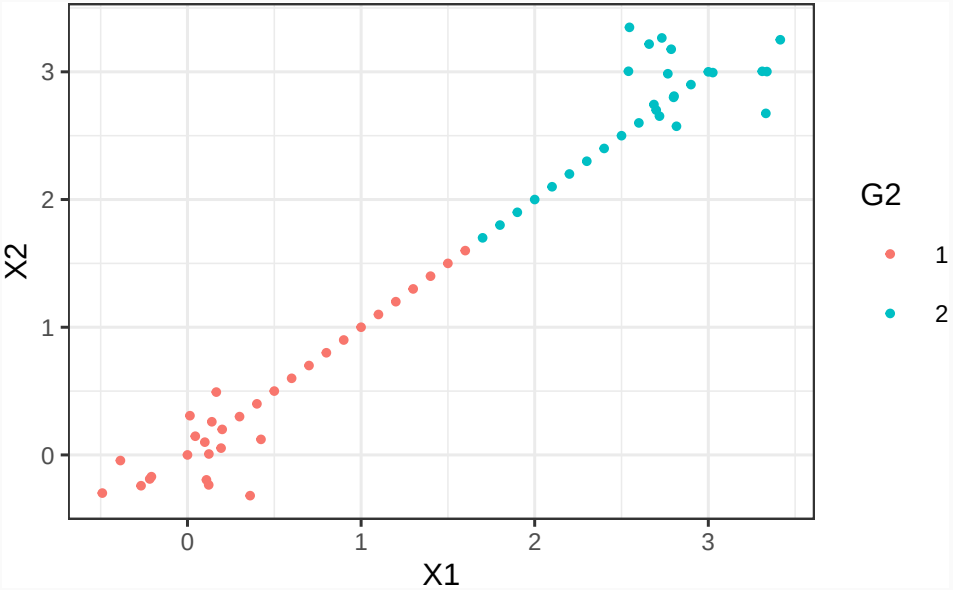

Choix du nombre de classes

- Toujours difficile...

Choix du nombre de classes

- Toujours difficile… On se base généralement sur la perte d'inertie inter obtenue en agrégeant les clusters :

```
> tibble(perte=rev(class2$height),x=1:60,
+        col=as.factor(c(1:3,rep(4,57)))) |>
+   ggplot()+aes(x=x,y=perte,fill=col)+
+   geom_bar(stat = "identity",show.legend = FALSE)
```

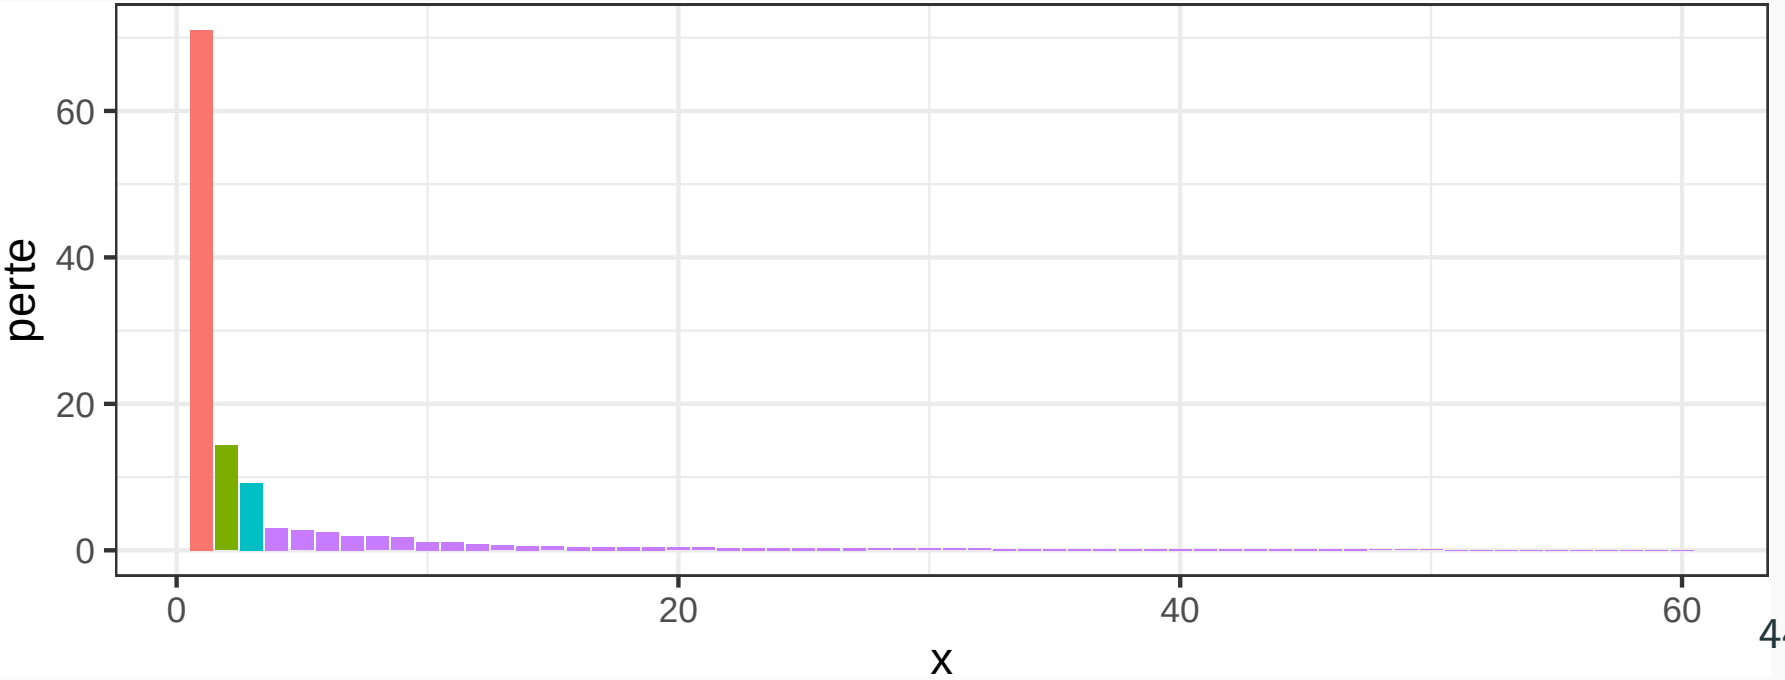

Le coin R : hclust

```
> DD <- dist(tbl)
> classif <- hclust(DD,method = "ward.D2")
> library(ggdendro)
> ggdendrogram(classif,labels = FALSE)
```

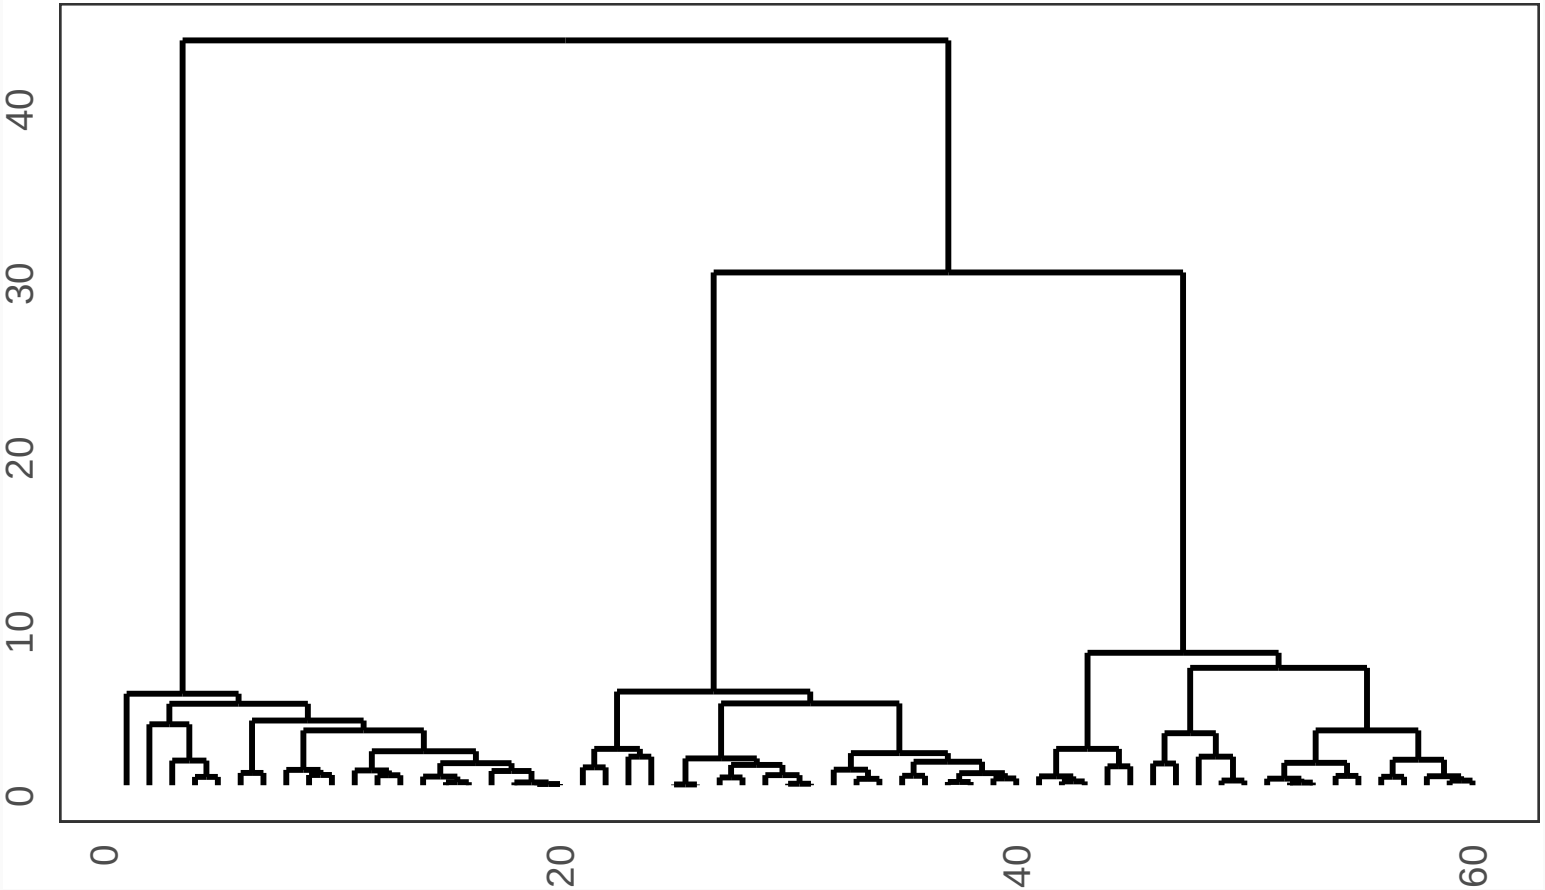

Le coin R : agnes de cluster

```
> library(cluster)
> classif1 <- agnes(DD,method = "ward")
> plot(classif1,which.plots=2)
```

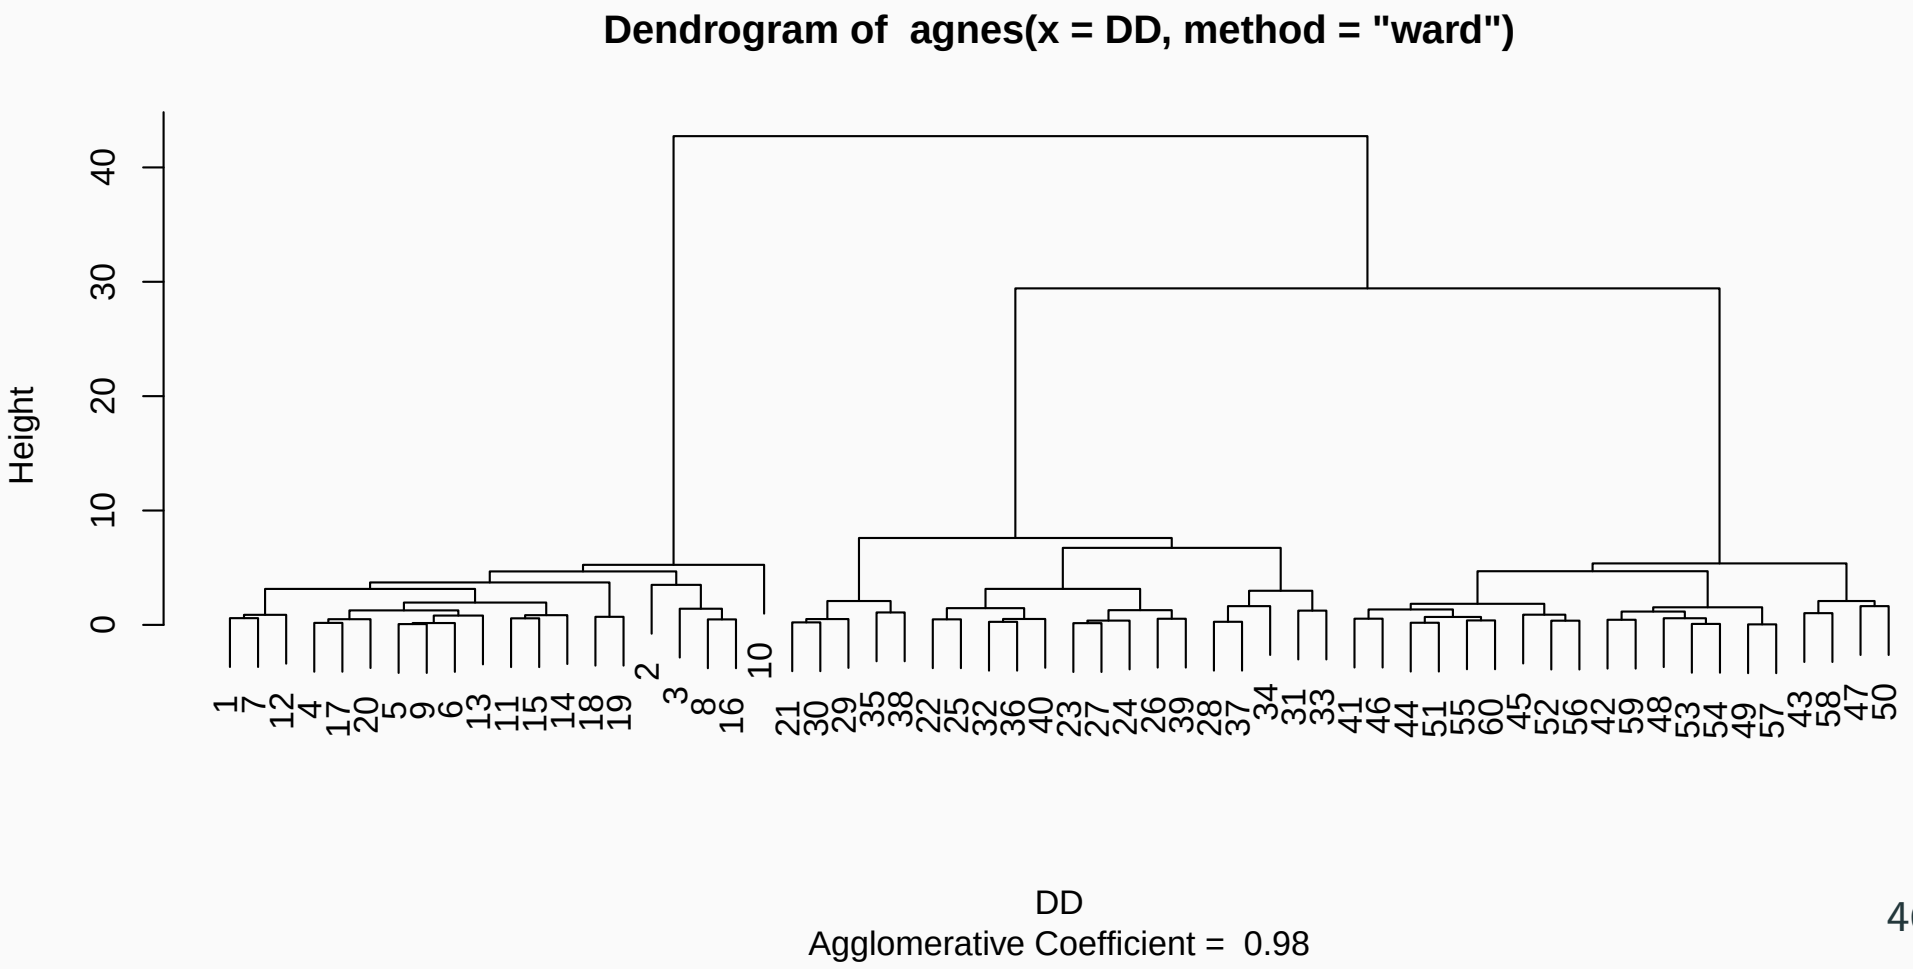

Bilan

Avantages

- Pas besoin de connaître le nombre de classes a priori
- Visualisation dendrogramme

Bilan

Avantages

- Pas besoin de connaître le nombre de classes a priori
- Visualisation dendrogramme

Inconvénients

- Coupure du dendrogramme pas toujours simple
- Complexité algorithmique élevée lorsque n est grand $\Longrightarrow O(n^3)$.

Méthodes hiérarchiques

Compléments

n grand $\Longrightarrow$ Classification mixte

- La CAH est souvent trop couteuse en temps de calcule lorsque n est grand.

n grand $\Longrightarrow$ Classification mixte

- La CAH est souvent trop couteuse en temps de calcule lorsque n est grand.

Classification Mixte

1. Faire un k-means sur les données avec k grand (par exemple $k = 1000$)
2. Lancer la CAH sur les centroïdes obtenus dans le k-means (en prenant en considération les effectifs des clusters)

n grand $\Longrightarrow$ Classification mixte

- La CAH est souvent trop couteuse en temps de calcule lorsque n est grand.

Classification Mixte

1. Faire un k-means sur les données avec k grand (par exemple $k = 1000$)
2. Lancer la CAH sur les centroïdes obtenus dans le k-means (en prenant en considération les effectifs des clusters)

- Sur **R** on peut utiliser la fonction `HCPC` du package **FactoMineR**.

Exemple

```
> dim(tbl)
[1] 70000     2
> aa <- dist(tbl)
Error: vecteurs de mémoire épuisés (limite atteinte ?)
```

```
> library(FactoMineR)
> classif <- HCPC(tbl,kk=100,nb.clust = 5,
+                 description = FALSE,graph = FALSE)
> summary(classif$data.clust)
       V1                 V2           clust
 Min.   :-3.8960   Min.   :-2.9089   1: 9968
 1st Qu.: 0.7978   1st Qu.: 0.2049   2: 8851
 Median : 4.4625   Median : 4.0371   3:11027
 Mean   : 3.5691   Mean   : 2.8530   4: 9986
 3rd Qu.: 5.4406   3rd Qu.: 5.1447   5:30168
 Max.   : 8.3466   Max.   : 8.6905
```

d grand

- CAH et k-means reposent sur des distances entre individus.

d grand

- CAH et k-means reposent sur des distances entre individus.
- Les distances standards ne sont pas forcément pertinentes en grande dimension.

d grand

- CAH et k-means reposent sur des distances entre individus.
- Les distances standards ne sont pas forcément pertinentes en grande dimension.

Réduction de dimension

- Souvent pertinent d'effectuer une analyse factorielle au préalable(ACP-ACM...) pour réduire la dimension.
- On fait ensuite le k-means et/ou la CAH sur les premiers axes de l'analyse factorielle.
- Sur R : fonction `HCPC` de **FactoMineR**.

Fastcluster et flashClust

Packages qui proposent d'autres algorithmes pour le calcul de la CAH.

```
> tbl1 <- tbl |> slice(sample(70000,10000));D <- dist(tbl1)
> system.time(aa <- stats::hclust(D,method = "ward.D2"))
   user  system elapsed
  2.555   0.163   2.732
> system.time(bb <- fastcluster::hclust(D,method="ward.D2"))
   user  system elapsed
  1.087   0.097   1.188
> system.time(cc <- flashClust::flashClust(D,method="ward"))
   user  system elapsed
  3.653   0.169   3.856
```

Références

Références

Bock, Hans-Hermann. 2008. « Origins and extensions of the k-means algorithm in cluster analysis ». *Electronic journal for history of probability and statistics* 4: 1-18.

Forgy, E. W. 1965. « Cluster analysis of multivariate data: efficiency vs interpretability of classifications ». *Biometrics* 21: 768-69.

Hartigan, J. A., et M. A. Wong. 1979. « Algorithm AS 136: A K-means clustering algorithm ». *Applied Statistics* 28: 100-108.

Lloyd, S. P. 1982. « Least squares quantization in PCM ». *IEEE Transactions on Information Theory* 28: 128-37.

MacQueen, J. 1967. « Some methods for classification and analysis of multivariate observations ». In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, édité par L. M. Le Cam & J. Neyman, 28:281-97. Berkeley.