Graph Mining

L. Rouvière
laurent.rouviere@univ-rennes2.fr

octobre 2022

Présentation

- Objectifs : comprendre, décrire, interpréter les problèmes associés à des graphes.
- Pré-requis : théorie des probabilités, modélisation statistique, R (niveau avancé).
- Enseignant : Laurent Rouvière laurent.rouviere@univ-rennes2.fr
  - MCF à l'Université Rennes 2, PCC à l'Ecole Polytechnique.
  - Recherche : statistique non paramétrique, apprentissage statistique
  - Enseignements : statistique et probabilités (Université, école d'ingénieur et de commerce, formation continue).
  - Consulting : energie, finance, marketing, sport.

Programme

- Matériel : slides + tutoriel R (compléments de cours et exercices). Disponible à l'url :
  https://lrouviere.github.io/page_perso/graphes.html

- 4 parties :
  1. Définitions - vocabulaire sur les graphes
  2. Statistiques descriptives sur les graphes
  3. Construction de graphes - modèles de graphes
  4. Détection de communautés

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
- Caractéristiques générales
- Importance des nœuds
Modèles et construction de graphes
- Quelques modèles de graphes
- Construire un graphe
Détection de communautés
- L'edge betweeness
- La modularité
- Clustering spectral
Bibliographie

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

- Le graph mining ou fouille de graphes correspond à la fouille de données spécifiques aux graphes.

- Le graph mining ou fouille de graphes correspond à la fouille de données spécifiques aux graphes.

Graphe

Objet mathématique utilisé pour modéliser des connexions ou interactions entre individus ou entités :

- les entités sont appelées nœuds ou sommets ;
- une relation entre deux entités est modélisée par une arête.

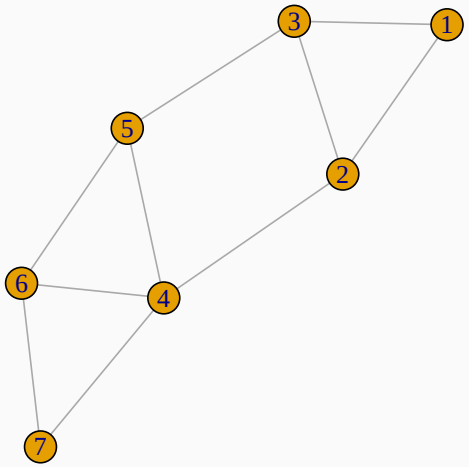

Nombreuses applications

- Réseaux routiers entre villes, réseaux aériens entre aéroports...
- Réseaux électriques (cables reliant des prises)
- Internet (routeurs et ordinateurs connectés par ethernet ou wifi)
- Réseaux d'amis Facebook
- Communication : personnes avec qui on communique (téléphone par exemple)
- World wide web (les nœuds sont les pages internets et les arêtes sont les hyperliens)
- Réseaux de régulation entre gènes
- Systèmes de recommandation...

Métro parisien

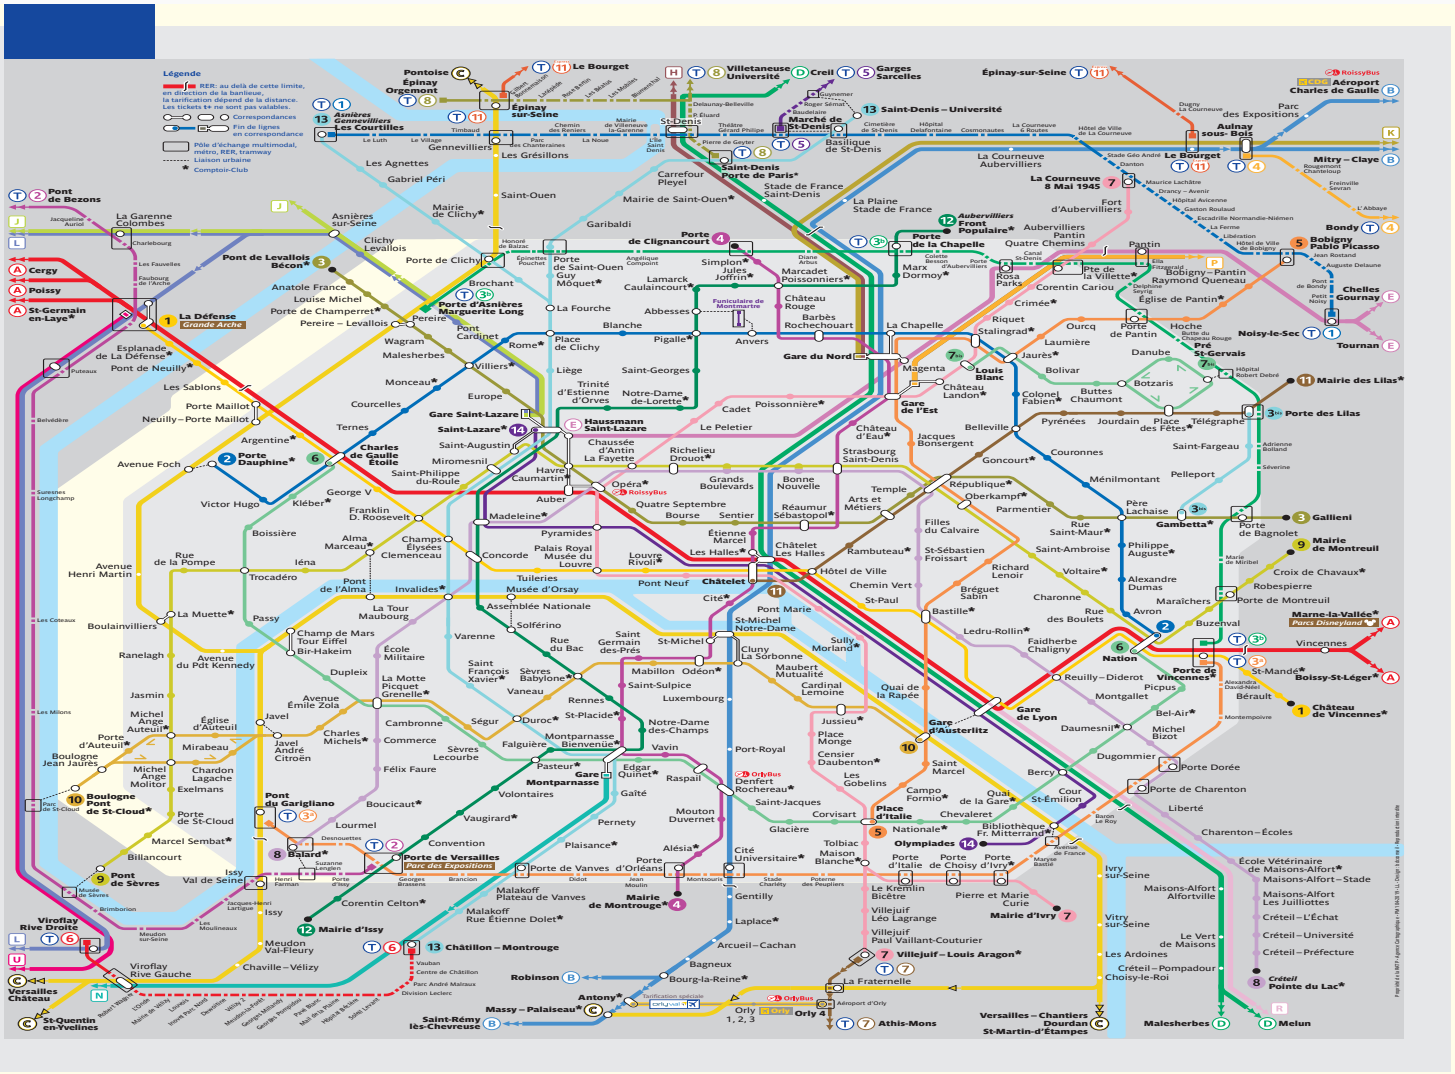
Légende
RER: au delà de cette limite, en direction de la banlieue, la tarification dépend de la distance. Les tickets T+ ne sont pas valables.
Correspondances
Fin de lignes en correspondance
Pôle d'échange multimodal, métro, RER, tramway
Liaison urbaine
Comptoir-Club
Pontoise Épinay Orgemont
Le Bourget
Villetaneuse Université
Creil
Sarcelles
Épinay-sur-Seine
Aéroport Charles de Gaulle
Asnières Gennevilliers Les Courtilles
Épinay sur-Seine
Saint-Denis – Université
Aulnay sous-Bois
Mitry – Claye
Pont de Bezons
La Garenne Colombes
Asnières sur-Seine
Pont de Levallois Bécon
Cergy
Poissy
St-Germain en-Laye
La Défense Grande Arche
Porte d'Asnières Marguerite Long
Porte de Clichy
Porte de Saint-Ouen
Porte de Clignancourt
Porte de la Chapelle
Bobigny Pablo Picasso
Bondy
Chelles Gournay
Noisy-le-Sec
Tournan
Mairie des Lilas
Porte des Lilas
Gallieni
Mairie de Montreuil
Marne-la-Vallée Parcs Disneyland
Vincennes
Boissy-St-Léger
Château de Vincennes
Porte de Vincennes
Nation
Porte de Bagnolet
Gambetta
Porte de Pantin
Bobigny–Pantin Raymond Queneau
Église de Pantin
Pré St-Gervais
Porte de Clichy
Gare du Nord
Gare de l'Est
Gare de Lyon
Gare d'Austerlitz
Bastille
Opéra
Châtelet
Saint-Lazare
Haussmann Saint-Lazare
Charles de Gaulle Étoile
Porte Dauphine
Pont de Neuilly
Les Sablons
Porte Maillot
Neuilly–Porte Maillot
Pont de Sèvres
Boulogne Pont de St-Cloud
Pont du Garigliano
Balard
Porte de Versailles Parc des Expositions
Mairie d'Issy
Châtillon – Montrouge
Viroflay Rive Droite
Versailles Château
St-Quentin en-Yvelines
Robinson
Massy – Palaiseau
Saint-Rémy lès-Chevreuse
Antony
Orly 1, 2, 3
Orly 4
Athis-Mons
Versailles – Chantiers
Dourdan
St-Martin-d'Étampes
Malesherbes
Melun
Mairie de Montrouge
Porte d'Italie
Olympiades
Place d'Italie
Bibliothèque Fr. Mitterrand
Porte d'Ivry
Mairie d'Ivry
Villejuif – Louis Aragon
Porte de Choisy
Porte de Vanves
Porte d'Orléans
Alésia
Denfert Rochereau
Montparnasse Bienvenüe
Gare Montparnasse
Duroc
Ségur
Sèvres Babylone
Mabillon
Odéon
St-Michel
Cluny La Sorbonne
Saint-Germain-des-Prés
Pont Neuf
Louvre Rivoli
Palais Royal Musée du Louvre
Concorde
Madeleine
Pyramides
Auber
Havre Caumartin
Chaussée d'Antin La Fayette
Richelieu Drouot
Grands Boulevards
Bonne Nouvelle
Strasbourg Saint-Denis
Réaumur Sébastopol
Arts et Métiers
Temple
République
Oberkampf
Parmentier
Rue Saint-Maur
Père Lachaise
Philippe Auguste
Alexandre Dumas
Avron
Buzenval
Maraîchers
Porte de Montreuil
Croix de Chavaux
Robespierre
Bérault
Bel-Air
Picpus
Montgallet
Reuilly–Diderot
Daumesnil
Michel Bizot
Porte Dorée
Porte de Charenton
Liberté
Charenton–Écoles
École Vétérinaire de Maisons-Alfort
Maisons-Alfort–Stade
Maisons-Alfort Les Juilliottes
Créteil–L'Échat
Créteil–Université
Créteil–Préfecture
Créteil Pointe du Lac
Créteil–Pompadour
Choisy-le-Roi
Ivry sur-Seine
Vitry sur-Seine
Le Vert de Maisons
Les Ardoines
Villejuif Paul Vaillant-Couturier
Villejuif Léo Lagrange
Le Kremlin Bicêtre
Pierre et Marie Curie
Maison Blanche
Tolbiac
Bibliothèque Fr. Mitterrand
Cour St-Émilion
Bercy
Quai de la Gare
Chevaleret
Corvisart
Glacière
Saint-Jacques
Cité Universitaire
Gentilly
Laplace
Arcueil–Cachan
Bagneux
Bourg-la-Reine
La Fraternelle
Orly Aéroport d'Orly
Notification spéciale
Orly-Ouest
Orly-Sud
Vauban
Centre de Châtillon
Parc André Malraux
Division Leclerc
Malakoff Plateau de Vanves
Malakoff Rue Étienne Dolet
Meudon Val-Fleury
Chaville–Vélizy
Viroflay Rive Gauche
Issy
Val de Seine
Corentin Celton
Meudon sur-Seine
Les Moulineaux
Boulogne Jean Jaurès
Michel Ange Molitor
Michel Ange Auteuil
Porte d'Auteuil
Église d'Auteuil
Mirabeau
Chardon Lagache
Exelmans
Porte de St-Cloud
Javel André Citroën
Avenue Émile Zola
Charles Michels
Cambronne
Commerce
Sèvres Lecourbe
Félix Faure
Boucicaut
Lourmel
Convention
Vaugirard
Volontaires
Pasteur
Edgar Quinet
Gaîté
Raspail
Montparnasse Bienvenüe
Vavin
Port-Royal
Saint-Marcel
Campo Formio
Les Gobelins
Censier Daubenton
Place Monge
Jussieu
Cardinal Lemoine
Maubert Mutualité
Quai de la Rapée
Luxembourg
Rennes
St-Placide
Notre-Dame des-Champs
Montparnasse Bienvenüe
Saint-Sulpice
Saint François Xavier
Vaneau
Sèvres Babylone
Rue du Bac
Solférino
Varenne
Assemblée Nationale
Tuileries
Musée d'Orsay
Pont Neuf
Pont Marie
St-Michel Notre-Dame
Cité
Chatelet
Hôtel de Ville
Chemin Vert
St-Paul
Bastille
Ledru-Rollin
Faidherbe Chaligny
Charonne
Rue des Boulets
Alexandre Dumas
Philippe Auguste
Voltaire
Richard Lenoir
Bréguet Sabin
Rue Saint-Ambroise
Saint-Sébastien Froissart
Filles du Calvaire
Rambuteau
Étienne Marcel
Les Halles
Châtelet Les Halles
Opéra
Quatre Septembre
Bourse
Sentier
Madeleine
Pyramides
Palais Royal Musée du Louvre
Concorde
Tuileries
Invalides
Pont de l'Alma
Iéna
Trocadéro
Kléber
Victor Hugo
Avenue Foch
Porte Maillot
Neuilly–Porte Maillot
Argentine
Ternes
Courcelles
Monceau
Malesherbes
Villiers
Wagram
Pereire
Porte Maillot
Porte Dauphine
Charles de Gaulle Étoile
Ternes
Courcelles
Monceau
Villiers
Malesherbes
Wagram
Pereire
Porte Maillot
Porte Dauphine
Porte d'Asnières Marguerite Long
Porte de Clichy
Porte de Saint-Ouen
Porte de Clignancourt
Porte de la Chapelle
Porte de Pantin
Porte de la Villette
Porte de Bagnolet
Porte de Vincennes
Porte de Montreuil
Porte des Lilas
Porte de Bagnolet
Porte de Vincennes
Porte de Versailles
Porte de Vanves
Porte d'Orléans
Porte d'Italie
Porte de Choisy
Porte d'Ivry
Porte de Bercy
Porte de Charenton
Porte Dorée
Porte de Pantin
Porte de Clichy
Porte de Versailles
Porte de Vincennes
Porte de Bagnolet
Porte de Montreuil
Porte des Lilas
Porte de Pantin
Porte de la Villette
Porte de Clignancourt
Porte de Saint-Ouen
Porte de Clichy
Porte d'Asnières Marguerite Long
Porte Dauphine
Porte Maillot
Porte d'Auteuil
Porte de St-Cloud
Porte de Versailles
Porte de Vanves
Porte d'Orléans
Porte d'Italie
Porte de Choisy
Porte d'Ivry
Porte de Bercy
Porte de Charenton
Porte Dorée

Réseaux sociaux

Réseaux moléculaires

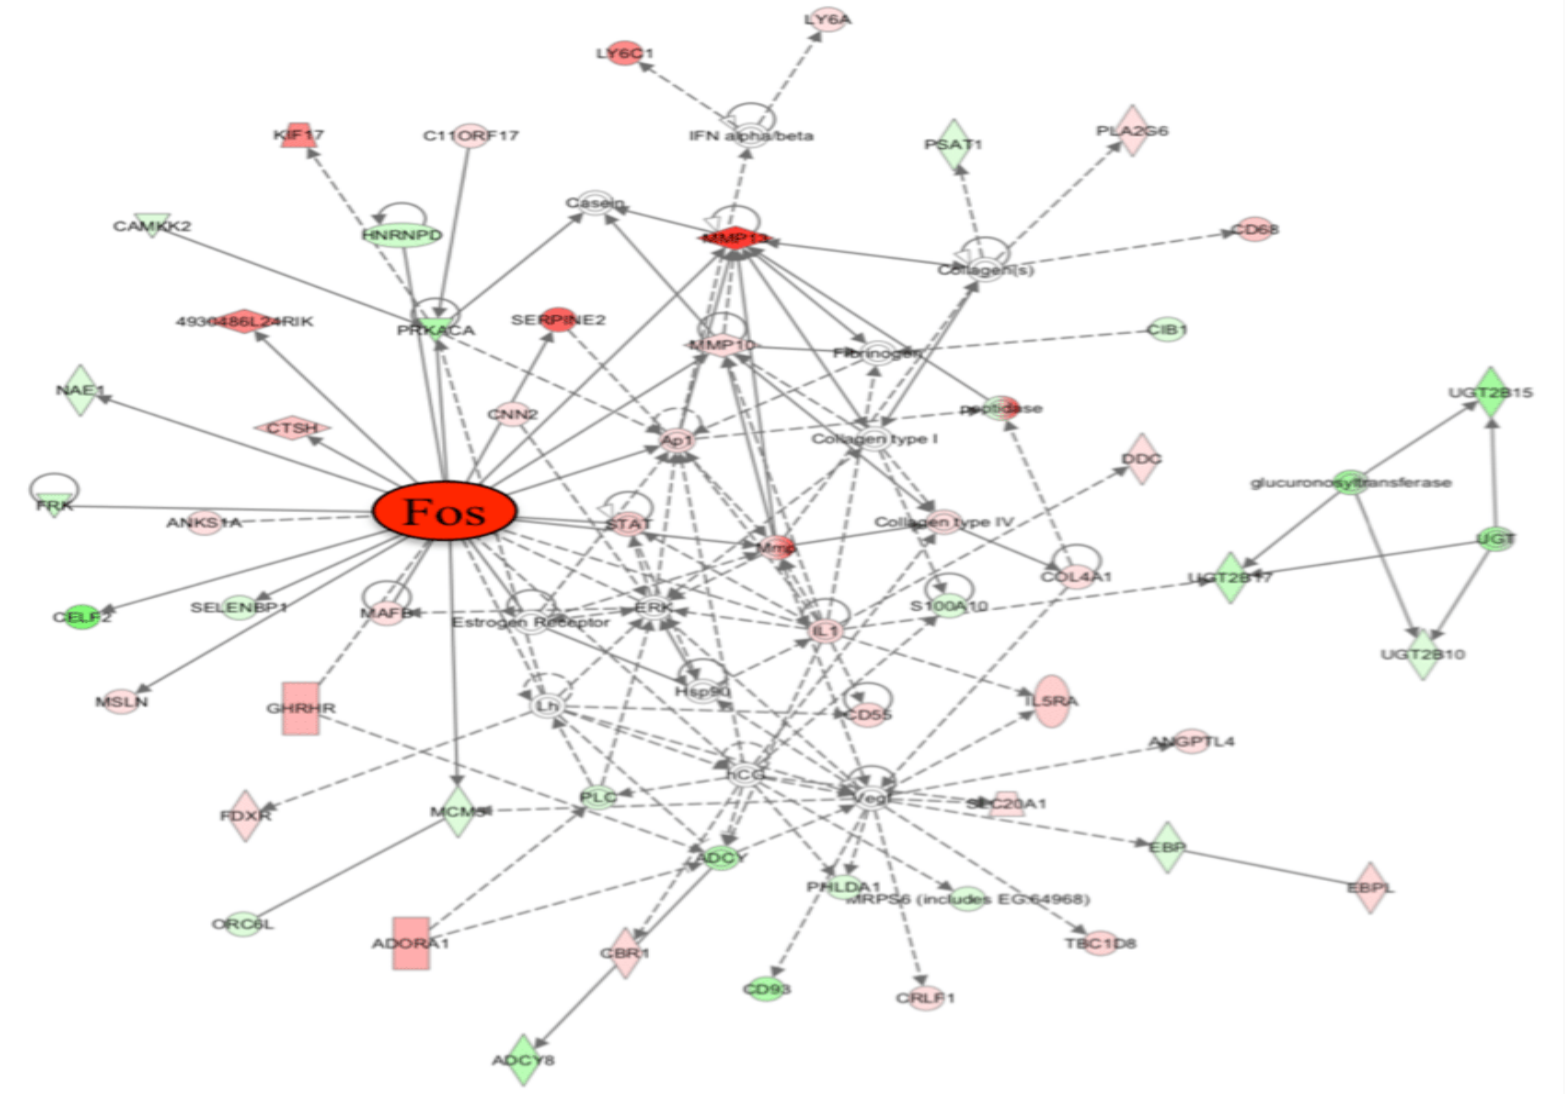

Communications

- Objectif : visualiser les communications d'un individu sur une période donnée.

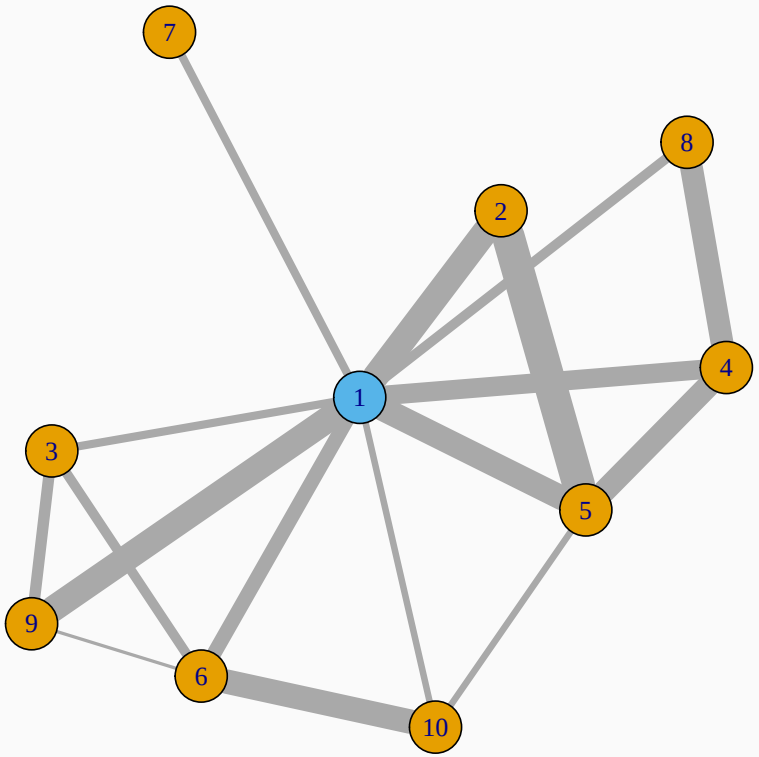

Karate

- Nœuds : membres d'un club de karaté universitaire ;
- Arêtes : lien d'amitié calculé en fonction du nombre d'activités communes.

Karate

- Nœuds : membres d'un club de karaté universitaire ;
- Arêtes : lien d'amitié calculé en fonction du nombre d'activités communes.

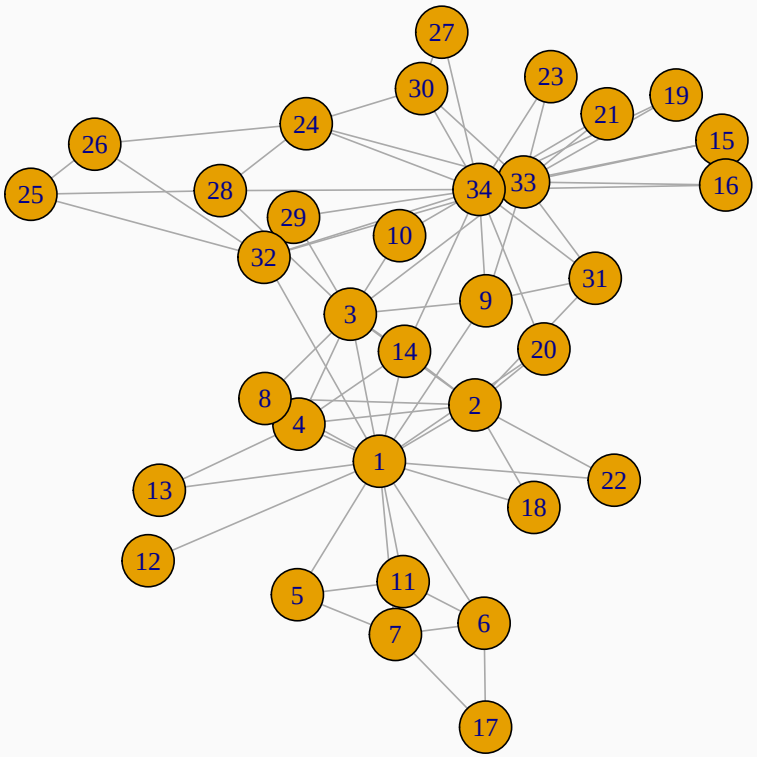

Karate

- Nœuds : membres d'un club de karaté universitaire ;
- Arêtes : lien d'amitié calculé en fonction du nombre d'activités communes.

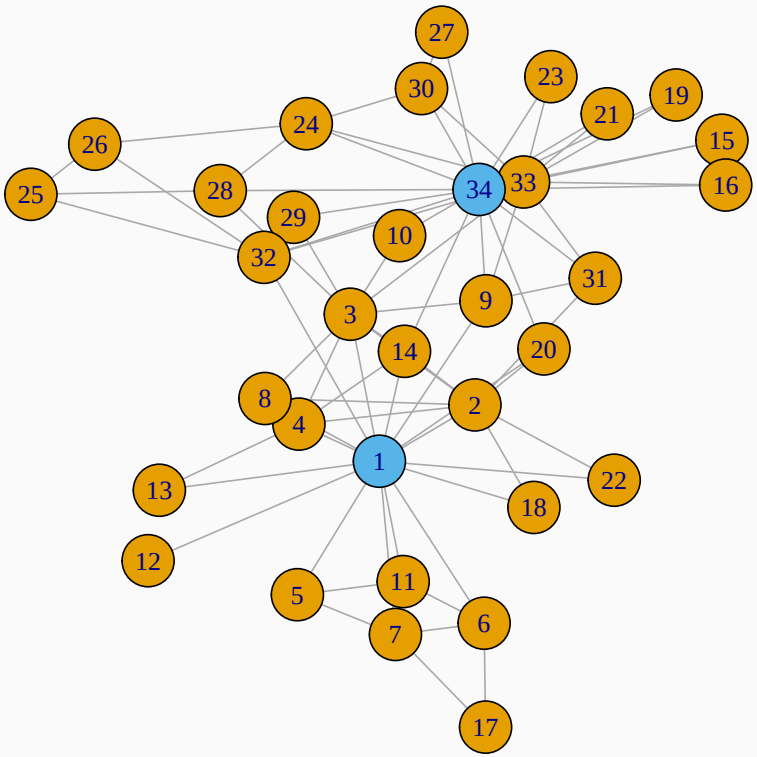

Plusieurs problématiques

Analyse exploratoire

Comprendre la structure d'interaction entre entités en analysant la topologie du graphe.

1. Construction d'un graphe : définition des nœuds et des arêtes.
2. Visualisation : comment représenter et dessiner un graphe ?
3. Détection de communautés : identifier des sous-groupes de nœuds très connectés.

Plusieurs problématiques

Analyse exploratoire

Comprendre la structure d'interaction entre entités en analysant la topologie du graphe.

1. Construction d'un graphe : définition des nœuds et des arêtes.
2. Visualisation : comment représenter et dessiner un graphe ?
3. Détection de communautés : identifier des sous-groupes de nœuds très connectés.

Inférence sur les graphes

Mettre des lois de probabilités sur la structure du graphe.

1. Modèles de graphes aléatoires.
2. Prédiction de connexions pour des nouveaux nœuds.

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Graphe

Un graphe $G = (V, E)$ est composé :

- d'un ensemble V de nœuds ou sommets (vertices) qui représentent les individus ou entités qui interagissent entre eux,

Graphe

Un graphe $G = (V, E)$ est composé :

- d'un ensemble V de nœuds ou sommets (vertices) qui représentent les individus ou entités qui interagissent entre eux,
- et d'un ensemble E d'arêtes (edges) qui indiquent la présence d'une interaction ou connexion entre deux noeuds :

$$\{i, j\} \in E \text{ si il y a une arête entre } i \text{ et } j \text{ dans } G.$$

Définitions

- Le nombre de nœuds $|V|$ est l'ordre du graphe. Le nombre d'arêtes $|E|$ est la taille du graphe.
- Un graphe est dirigé (ou orienté) lorsque ses arêtes le sont. Il est non dirigé sinon.

Définitions

- Le nombre de nœuds $|V|$ est l'ordre du graphe. Le nombre d'arêtes $|E|$ est la taille du graphe.
- Un graphe est dirigé (ou orienté) lorsque ses arêtes le sont. Il est non dirigé sinon.
- Les graphes peuvent être binaires (arête présente ou absente), ou valués (arêtes munies d'un poids positif).

Définitions

- Le nombre de nœuds $|V|$ est l'ordre du graphe. Le nombre d'arêtes $|E|$ est la taille du graphe.
- Un graphe est dirigé (ou orienté) lorsque ses arêtes le sont. Il est non dirigé sinon.
- Les graphes peuvent être binaires (arête présente ou absente), ou valués (arêtes munies d'un poids positif).
- Un graphe est dit simple s'il n'y a pas de boucles : (i, i) n'est jamais une arête.

Définitions

- Le nombre de nœuds $|V|$ est l'ordre du graphe. Le nombre d'arêtes $|E|$ est la taille du graphe.
- Un graphe est dirigé (ou orienté) lorsque ses arêtes le sont. Il est non dirigé sinon.
- Les graphes peuvent être binaires (arête présente ou absente), ou valués (arêtes munies d'un poids positif).
- Un graphe est dit simple s'il n'y a pas de boucles : (i, i) n'est jamais une arête.
- Le graphe complet ou clique est le graphe (non dirigé) qui contient toutes les arêtes possibles entre les sommets ($C^2_{|V|}$ arêtes).

Définitions

- Le nombre de nœuds $|V|$ est l'ordre du graphe. Le nombre d'arêtes $|E|$ est la taille du graphe.
- Un graphe est dirigé (ou orienté) lorsque ses arêtes le sont. Il est non dirigé sinon.
- Les graphes peuvent être binaires (arête présente ou absente), ou valués (arêtes munies d'un poids positif).
- Un graphe est dit simple s'il n'y a pas de boucles : (i, i) n'est jamais une arête.
- Le graphe complet ou clique est le graphe (non dirigé) qui contient toutes les arêtes possibles entre les sommets ($C^2_{|V|}$ arêtes).

Question

Comment stocker un graphe ?

Matrice d'adjacence

Définition

La matrice d'adjacence d'un graphe $G = (V, E)$ binaire est la matrice $|V| \times |V|$ de terme général

$$A_{ij} = \begin{cases} 1 & \text{si } \{i, j\} \in E \\ 0 & \text{sinon.} \end{cases}$$

Matrice d'adjacence

Définition

La matrice d'adjacence d'un graphe $G = (V, E)$ binaire est la matrice $|V| \times |V|$ de terme général

$$A_{ij} = \begin{cases} 1 & \text{si } \{i, j\} \in E \\ 0 & \text{sinon.} \end{cases}$$

Remarques

- Graphe non dirigé $\Longrightarrow$ A symétrique.
- Graphe simple $\Longrightarrow$ $A_{ii} = 0 \ \forall i$.
- Graphe valué $\Longrightarrow$ $A_{ij} = w_{ij} \in \mathbb{R}^+$.

Exemple : graphe non dirigé

```
> A
##      [,1] [,2] [,3] [,4]
## [1,]    0    1    1    0
## [2,]    1    0    1    0
## [3,]    1    1    0    1
## [4,]    0    0    1    0
> set.seed(1234)
> G <- graph_from_adjacency_matrix(A,
+                                  mode='undirected')
> plot(G)
```

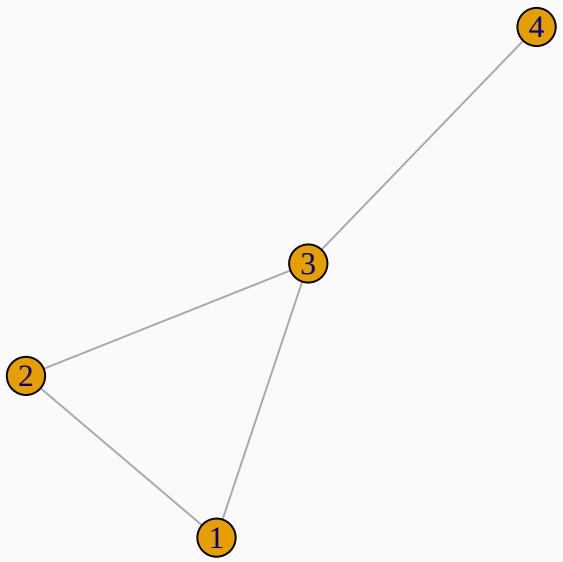

Exemple : graphe dirigé

```
> A
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    0    4    3    2    0
## [2,]    4    0    3    0    0
## [3,]    1    0    0    0    0
## [4,]    4    3    1    0    0
## [5,]    4    4    0    0    0
> G <- graph_from_adjacency_matrix(A,
+     mode='directed',weighted = TRUE)
> E(G)$width <- E(G)$weight
> plot(G)
```

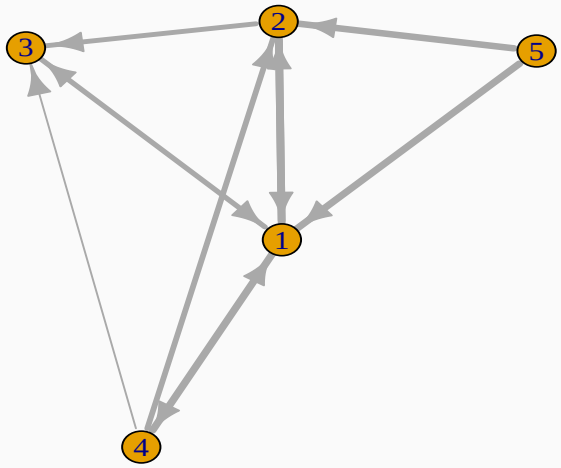

Exemple : graphe dirigé

```
> A
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    0    4    3    2    0
## [2,]    4    0    3    0    0
## [3,]    1    0    0    0    0
## [4,]    4    3    1    0    0
## [5,]    4    4    0    0    0
> G <- graph_from_adjacency_matrix(A,
+     mode='directed',weighted = TRUE)
> E(G)$width <- E(G)$weight
> plot(G)
```

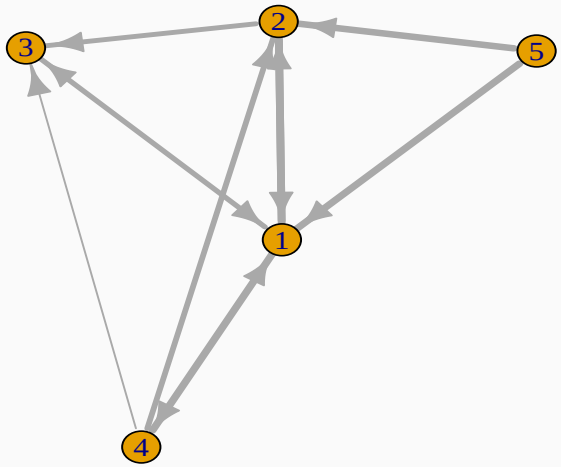

Remarque

- Pas toujours efficace en terme de stockage : $\mathrm{O}(|V|^2)$.
- Utiliser des matrices sparses si le graphe est très creux.

Liste d'arêtes

- Il est souvent plus efficace de définir le graphe en donnant une liste d'arêtes.
- Attention : penser à donner le nombre total de nœuds du graphe pour éviter d'oublier les nœuds isolés.

Liste d'arêtes

- Il est souvent plus efficace de définir le graphe en donnant une liste d'arêtes.
- Attention : penser à donner le nombre total de nœuds du graphe pour éviter d'oublier les nœuds isolés.

```
> G <- graph(edges=c(1,2,1,3,3,4,4,4,2,3),n=5)
> plot(G)
```

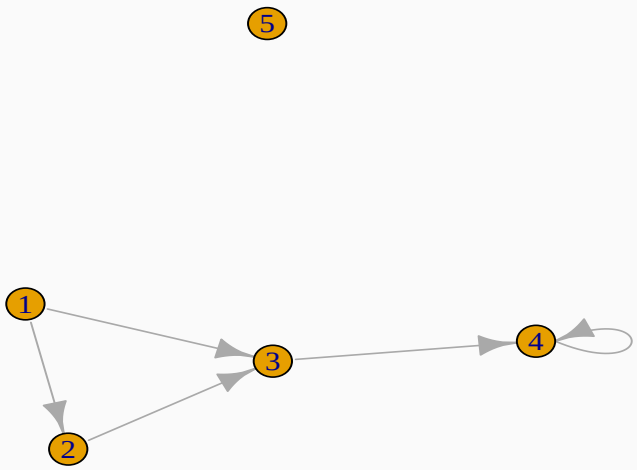

Visualisation d'un graphe

- Etape importante : elle permet de comprendre la structure du graphe : identification de nœuds importants, très connectés...
- Différentes représentations :
  1. en cercle, en étoile...
  2. selon différents algorithmes (voir [Bahoken et al., 2013])

mais attention : certaines peuvent être trompeuses :

```
> plot(kar)
```

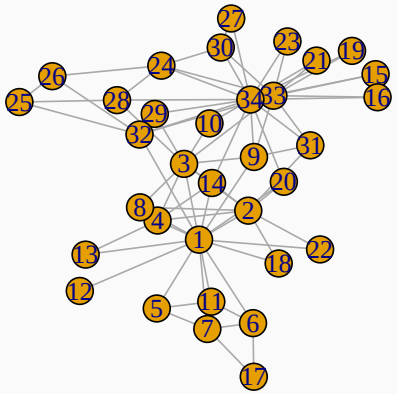

Autres représentations

```
> plot(kar,layout=layout_as_star(kar))
> plot(kar,layout=layout.circle(kar))
> plot(kar,layout=layout_randomly(kar))
```

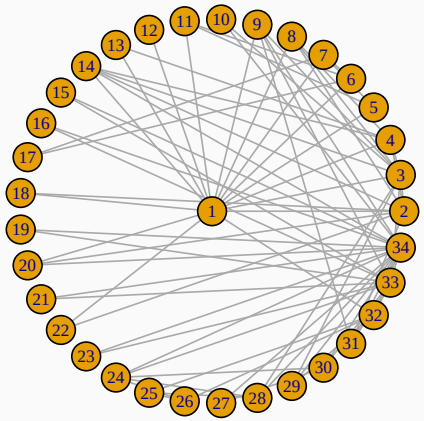

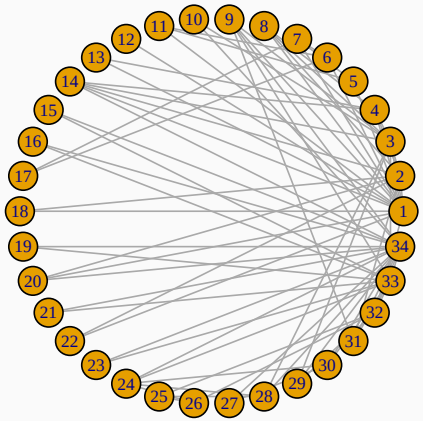

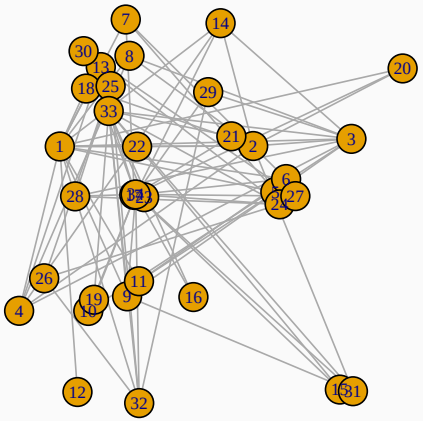

Autres représentations

```
> plot(kar,layout=layout_as_star(kar))
> plot(kar,layout=layout.circle(kar))
> plot(kar,layout=layout_randomly(kar))
```

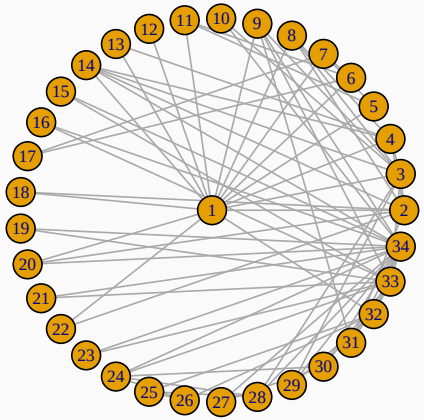

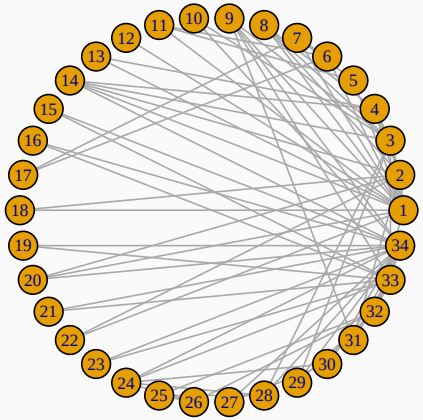

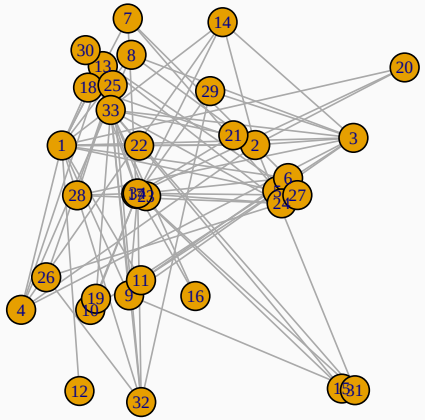

Packages

- R : igraph, visNetwork, GGally.
- Python : NetworkX.

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Caractéristiques d'un graphe

- De nombreux indicateurs permettent de décrire un graphe.

Objectifs

Caractéristiques d'un graphe

- De nombreux indicateurs permettent de décrire un graphe.

Objectifs

- Donner une version résumée du graphe.

Caractéristiques d'un graphe

- De nombreux indicateurs permettent de décrire un graphe.

Objectifs

- Donner une version résumée du graphe.
- Décrire et comprendre les interactions entre entités :
  - transfert d'information entre deux sommets.
  - importance de certains sommets.
  - sous-structure particulière dans le graphe.

Caractéristiques d'un graphe

- De nombreux indicateurs permettent de décrire un graphe.

Objectifs

- Donner une version résumée du graphe.
- Décrire et comprendre les interactions entre entités :
  - transfert d'information entre deux sommets.
  - importance de certains sommets.
  - sous-structure particulière dans le graphe.
- Comparer deux graphes.
- Comparer un graphe avec un modèle de graphe aléatoire.

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Distance - diamètre

- Un chemin entre $i \in V$ et $j \in V$ est une suite de nœuds et d'arêtes permettant de relier i et j.
- Longueur d'un chemin entre i et j : nombre d'arêtes qui composent ce chemin.
- Distance ℓ_{ij} entre i et j : longueur du plus court chemin qui les relie. Si les deux nœuds ne sont pas connectés : $\ell_{ij} = +\infty$.

Distance - diamètre

- Un chemin entre $i \in V$ et $j \in V$ est une suite de nœuds et d'arêtes permettant de relier i et j.
- Longueur d'un chemin entre i et j : nombre d'arêtes qui composent ce chemin.
- Distance ℓ_{ij} entre i et j : longueur du plus court chemin qui les relie. Si les deux nœuds ne sont pas connectés : $\ell_{ij} = +\infty$.
- Diamètre d'un graphe : plus grande distance entre deux nœuds (quantité définie uniquement pour les graphes connexes).

Distance - diamètre

- Un chemin entre $i \in V$ et $j \in V$ est une suite de nœuds et d'arêtes permettant de relier i et j.
- Longueur d'un chemin entre i et j : nombre d'arêtes qui composent ce chemin.
- Distance ℓ_{ij} entre i et j : longueur du plus court chemin qui les relie. Si les deux nœuds ne sont pas connectés : $\ell_{ij} = +\infty$.
- Diamètre d'un graphe : plus grande distance entre deux nœuds (quantité définie uniquement pour les graphes connexes).

Transfert d'information

Un petit diamètre indique que l'information circule rapidement dans le graphe entier.

Connexité

- Une composante connexe est un sous-ensemble $C = \{v_1, \ldots, v_k\} \subset V$ tel que, pour tout $v_i, v_j \in C$, il existe un chemin dans G de v_i à v_j.

Connexité

- Une composante connexe est un sous-ensemble $C = \{v_1, \ldots, v_k\} \subset V$ tel que, pour tout $v_i, v_j \in C$, il existe un chemin dans G de v_i à v_j.

- Un nœud qui n'est connecté à aucun autre est dit isolé $\Longrightarrow$ il forme une composante connexe à lui tout seul.

Connexité

- Une composante connexe est un sous-ensemble $C = \{v_1, \ldots, v_k\} \subset V$ tel que, pour tout $v_i, v_j \in C$, il existe un chemin dans G de v_i à v_j.
- Un nœud qui n'est connecté à aucun autre est dit isolé $\Longrightarrow$ il forme une composante connexe à lui tout seul.
- Un graphe est dit connexe s'il possède une unique composante connexe.

Exemple

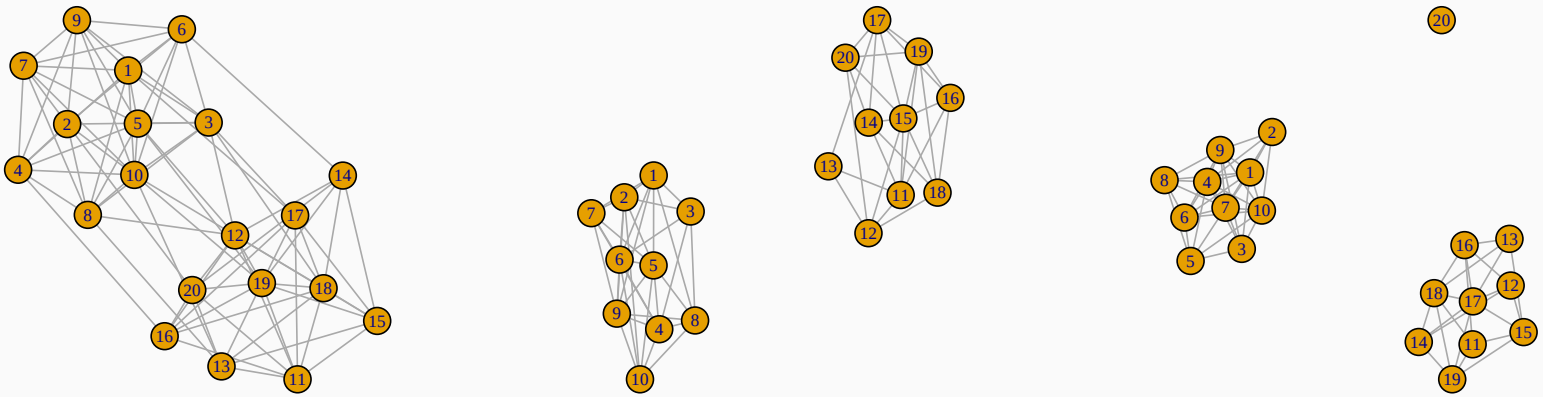
9 6 7 1 2 5 3 4 10 14 8 17 12 20 19 18 15 16 13 11
1 2 7 3 6 5 9 4 8 10
17 20 19 16 14 15 13 11 18 12
20
2 9 8 4 1 7 10 6 5 3
16 13 18 12 17 14 11 15 19

Exemple

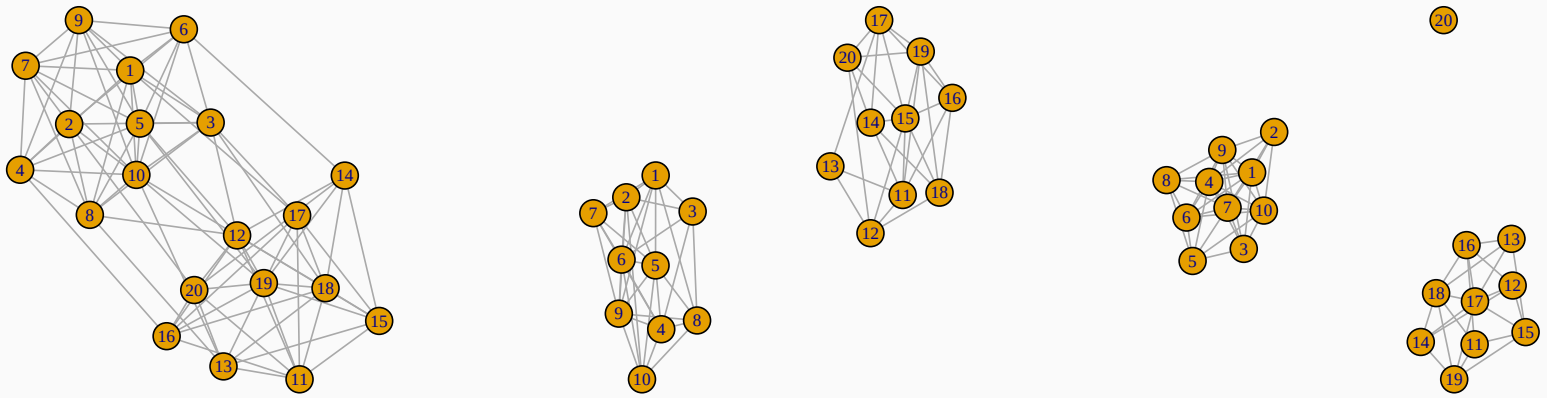

Commentaires

- Gauche : graphe connexe.
- Centre : 2 composantes connexes.
- Droite : 3 composantes connexes, 1 nœud isolé.

Questions liées à la connexité

1. Plusieurs composantes connexes dans le graphe ?
   - présence de nœuds isolés (participant inactif) ?
   - 1 composante connexe = 1 groupe d'individus (ou 1 cluster) ?

Questions liées à la connexité

1. Plusieurs composantes connexes dans le graphe ?
   - présence de nœuds isolés (participant inactif) ?
   - 1 composante connexe = 1 groupe d'individus (ou 1 cluster) ?

2. Si non, est-ce "presque" le cas ? $\Longrightarrow$ Création de nouvelles composantes connexes en supprimant quelques nœuds ou arêtes, voir section 2 .

Questions liées à la connexité

1. Plusieurs composantes connexes dans le graphe ?
   - présence de nœuds isolés (participant inactif) ?
   - 1 composante connexe = 1 groupe d'individus (ou 1 cluster) ?

2. Si non, est-ce "presque" le cas ? $\Longrightarrow$ Création de nouvelles composantes connexes en supprimant quelques nœuds ou arêtes, voir section 2.

3. Recherche de communautés dans les graphes connexes : groupes de sommets très connectés entre eux et peu connectés avec les autres groupes, voir section 5.

Densité

- Un graphe simple possède au plus $|V|(|V|-1)/2$ arêtes si il est non dirigé et $|V|(|V|-1)$ si il est dirigé.

Densité

- Un graphe simple possède au plus $|V|(|V|-1)/2$ arêtes si il est non dirigé et $|V|(|V|-1)$ si il est dirigé.

Densité

- Graphe non dirigé :

$$\mathrm{den}(G) = \frac{|E|}{|V|(|V|-1)/2}.$$

- Graphe dirigé :

$$\mathrm{den}(G) = \frac{|E|}{|V|(|V|-1)}.$$

Densité

- Un graphe simple possède au plus $|V|(|V|-1)/2$ arêtes si il est non dirigé et $|V|(|V|-1)$ si il est dirigé.

Densité

- Graphe non dirigé :

$$\mathrm{den}(G) = \frac{|E|}{|V|(|V|-1)/2}.$$

- Graphe dirigé :

$$\mathrm{den}(G) = \frac{|E|}{|V|(|V|-1)}.$$

Remarque

Varie entre 0 (graphe vide) et 1 (graphe complet ou clique).

Densité locale

Recherche de motifs particuliers dans le graphe.

- Nombre de triangles dans un graphe : traduit des relations de transitivité

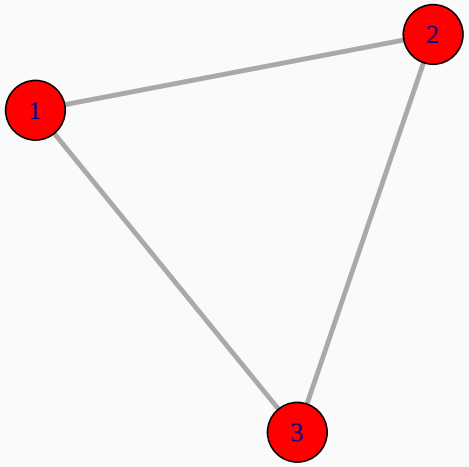

Densité locale

Recherche de motifs particuliers dans le graphe.

- Nombre de triangles dans un graphe : traduit des relations de transitivité

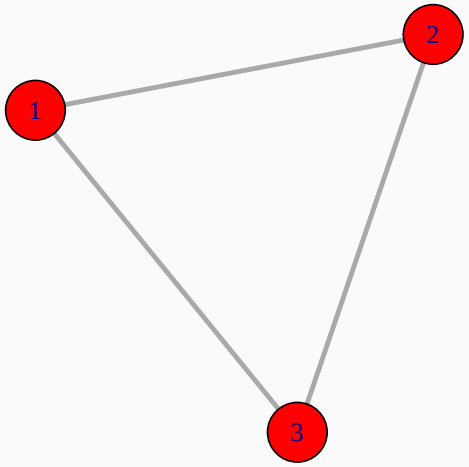

Intérêt

Réseaux sociaux : mes amis sont-ils amis ?

Autres motifs

1. Cliques de taille k donnée.
2. Cycles de longueur k donnée.
3. k stars...

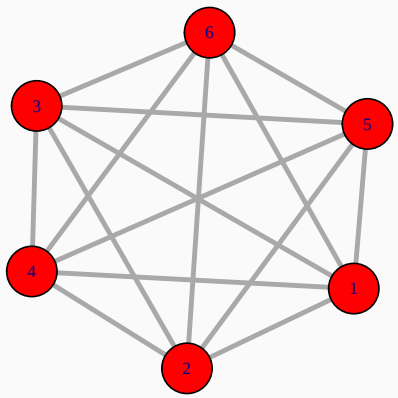

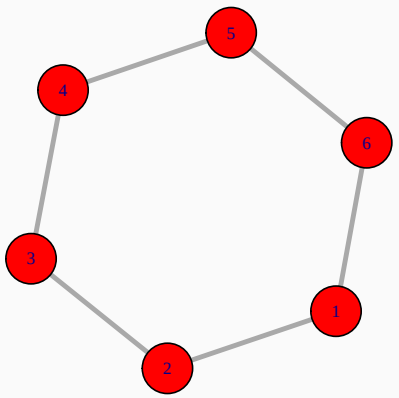

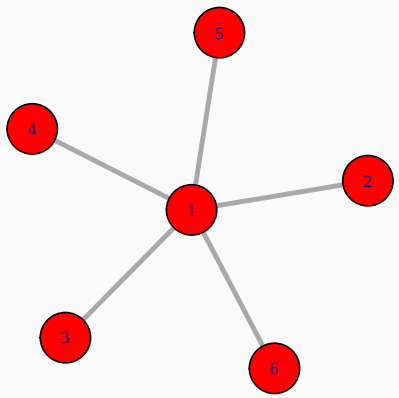

Exemple

Comparer le nombre d'occurrences d'un motif à un nombre attendu ou observé.

Le coin R

La plupart des indicateurs s'obtiennent directement avec R

- Nombre de nœuds, d'arêtes, composantes connexes, diamètre, densité :

```
> vcount(kar)
## [1] 34
> ecount(kar)
## [1] 78
> count_components(kar)
## [1] 1
> diameter(kar)
## [1] 5
> edge_density(kar)
## [1] 0.1390374
```

- Nombre de triangles :

```
> head(count_triangles(kar))
## [1] 18 12 11 10  2  3
> length(triangles(kar))/3
## [1] 45
```

- Nombre de triangles :

```
> head(count_triangles(kar))
## [1] 18 12 11 10  2  3
> length(triangles(kar))/3
## [1] 45
```

- Nombre de cliques de taille 3 à 5 :

```
> count_max_cliques(kar,min=3,max=5)
## [1] 25
```

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Objectif

- Identifier les nœuds centraux d'un réseau.
- Rechercher les nœuds influents, clés d'un réseau.

Objectif

- Identifier les nœuds centraux d'un réseau.
- Rechercher les nœuds influents, clés d'un réseau.

Comment ?

En définissant des indicateurs de centralité pour les nœuds d'un graphe.

Voisins, degré

- Les voisins de $i \in V$ sont les nœuds $j \in V$ tels que $i, j \in E$. On note

$$\mathcal{V}(i) = \{j \in V : \{i, j\} \in E\}.$$

Voisins, degré

- Les voisins de $i \in V$ sont les nœuds $j \in V$ tels que $i, j \in E$. On note

$$\mathcal{V}(i) = \{j \in V : \{i, j\} \in E\}.$$

Degré

- Le degré d_i d'un nœud i est le nombre de voisins de i : $d_i = |\mathcal{V}(i)|$.
- Calcul à partir de la matrice d'adjacence A :
  - Graphe non dirigé : $d_i = \sum_{j, j \neq i} A_{ij}$.
  - Graphe dirigé : degrés sortant et entrant

$$d_i^{\text{out}} = \sum_{j, j \neq i} A_{ij} \quad \text{et} \quad d_i^{\text{in}} = \sum_{j, j \neq i} A_{ji}.$$

Voisins, degré

- Les voisins de $i \in V$ sont les nœuds $j \in V$ tels que $i, j \in E$. On note

$$\mathcal{V}(i) = \{j \in V : \{i, j\} \in E\}.$$

Degré

- Le degré d_i d'un nœud i est le nombre de voisins de i : $d_i = |\mathcal{V}(i)|$.
- Calcul à partir de la matrice d'adjacence A :
  - Graphe non dirigé : $d_i = \sum_{j, j \neq i} A_{ij}$.
  - Graphe dirigé : degrés sortant et entrant

$$d_i^{\text{out}} = \sum_{j, j \neq i} A_{ij} \quad \text{et} \quad d_i^{\text{in}} = \sum_{j, j \neq i} A_{ji}.$$

Remarque

Notion la plus simple mais qui ne prend pas nécessairement en compte la structure du graphe.

Degré moyen

- Graphe non dirigé : $\bar{d} = \frac{1}{|\mathcal{V}|} \sum_{i \in V} d_i$.
- Graphe dirigé :

$$\bar{d}^{\text{out}} = \frac{1}{|\mathcal{V}|} \sum_{i \in V} d_i^{\text{out}} \quad \text{et} \quad \bar{d}^{\text{in}} = \frac{1}{|\mathcal{V}|} \sum_{i \in V} d_i^{\text{in}}.$$

Degré moyen

- Graphe non dirigé : $\bar{d} = \frac{1}{|\mathcal{V}|} \sum_{i \in V} d_i$.
- Graphe dirigé :

$$\bar{d}^{\text{out}} = \frac{1}{|\mathcal{V}|} \sum_{i \in V} d_i^{\text{out}} \quad \text{et} \quad \bar{d}^{\text{in}} = \frac{1}{|\mathcal{V}|} \sum_{i \in V} d_i^{\text{in}}.$$

Remarque

- Pas toujours très informatif car souvent grande variabilité.
- plus intéressant : distribution des degrés (avec un histogramme par exemple).

Centralité de proximité

- Objectif : étudier si le sommet est à proximité des autres sommets et si il peut interagir rapidement avec eux.

Centralité de proximité

- Objectif : étudier si le sommet est à proximité des autres sommets et si il peut interagir rapidement avec eux.
- Idée : regarder la distance entre le sommet et les autres sommets.

Centralité de proximité

- Objectif : étudier si le sommet est à proximité des autres sommets et si il peut interagir rapidement avec eux.
- Idée : regarder la distance entre le sommet et les autres sommets.

Définition

Le degré de centratilité de proximité (closeness centrality) du nœud i est défini par

$$C_c(i) = \frac{1}{\sum_{j \neq i} \ell_{ij}}$$

où ℓ_{ij} distance = longueur du plus court chemin entre i et j.

Centralité de proximité

- Objectif : étudier si le sommet est à proximité des autres sommets et si il peut interagir rapidement avec eux.
- Idée : regarder la distance entre le sommet et les autres sommets.

Définition

Le degré de centratilité de proximité (closeness centrality) du nœud i est défini par

$$C_c(i) = \frac{1}{\sum_{j \neq i} \ell_{ij}}$$

où ℓ_{ij} distance = longueur du plus court chemin entre i et j.

Commentaire

$C_c(i) \nearrow$ si sa distance aux autres nœuds est faible.

Exemple

nœud j	ℓ_{1j}	ℓ_{2j}
1		
2		
3		
4		
5		
6		

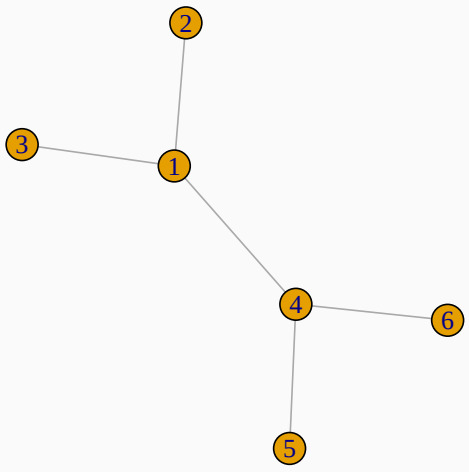

Exemple

nœud j	ℓ_{1j}	ℓ_{2j}
1		
2	1	
3	1	
4	1	
5	2	
6	2	

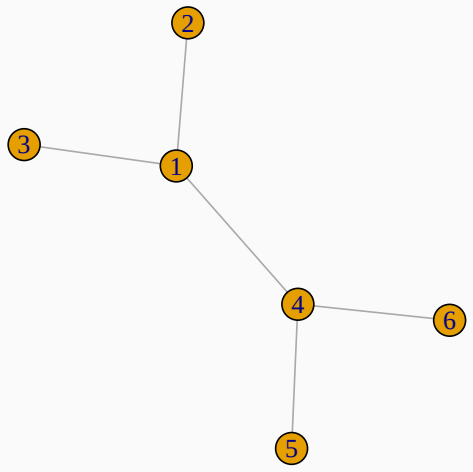

Exemple

nœud j	ℓ_{1j}	ℓ_{2j}
1		1
2	1	
3	1	2
4	1	2
5	2	3
6	2	3

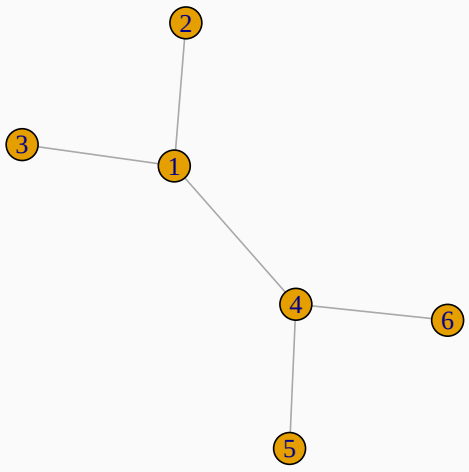

Exemple

nœud j	ℓ_{1j}	ℓ_{2j}
1		1
2	1	
3	1	2
4	1	2
5	2	3
6	2	3

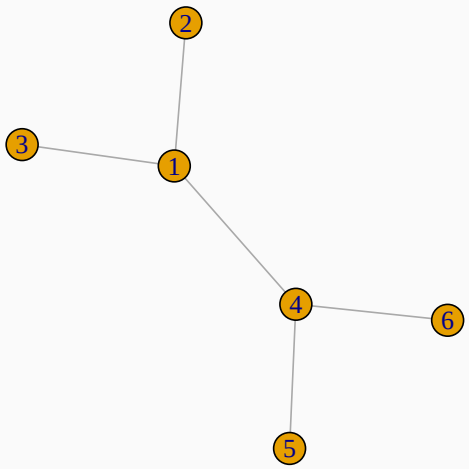

- Conclusion : $C_c(1) = 1/7$, $C_c(2) = 1/11$.

```
> closeness(G)
## [1] 0.14285714 0.09090909 0.09090909 0.14285714 0.09090909 0.09090909
```

Centralité d'intermédiarité

Objectif : mesurer à quel point

- un nœud est important pour connecter deux autres nœuds dans le graphe.
- un nœud sert d'intermédiaire.

Centralité d'intermédiarité

Objectif : mesurer à quel point

- un nœud est important pour connecter deux autres nœuds dans le graphe.
- un nœud sert d'intermédiaire.

Définition

Le degré de centratilité d'intermédiarité (betweeness centrality) du nœud i est défini par

$$C_B(i) = \sum_{j \neq i, k \neq i, j \neq k} \frac{g_{jk}(i)}{g_{jk}}$$

où

- g_{jk} est le nombre de plus courts chemins entre j et k.
- $g_{jk}(i)$ est le nombre de plus courts chemins entre j et k qui passent par i.

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(2,3)$		
$(2,4)$		
$(3,4)$		

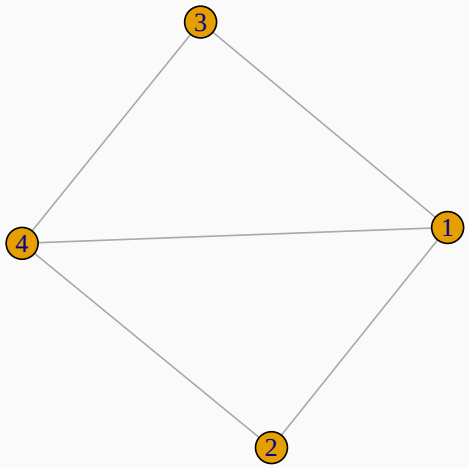

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(2,3)$	2	
$(2,4)$	1	
$(3,4)$	1	

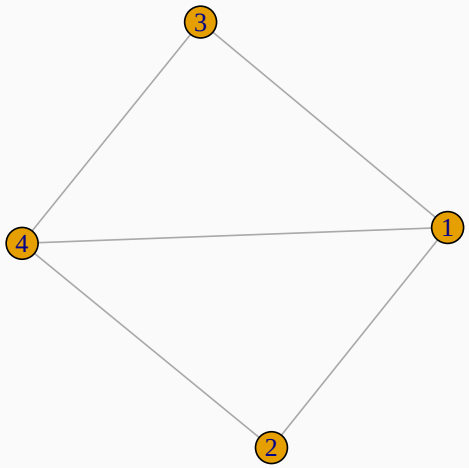

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(2,3)$	2	1
$(2,4)$	1	0
$(3,4)$	0	0

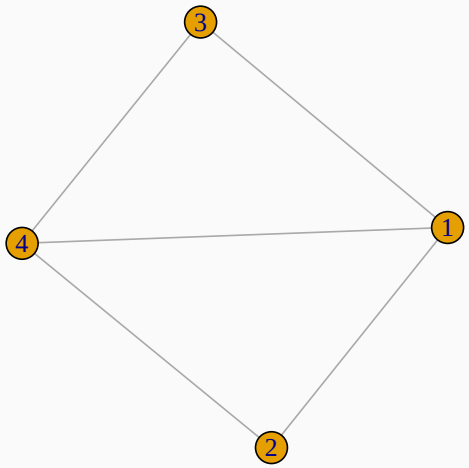

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(2,3)$	2	1
$(2,4)$	1	0
$(3,4)$	0	0

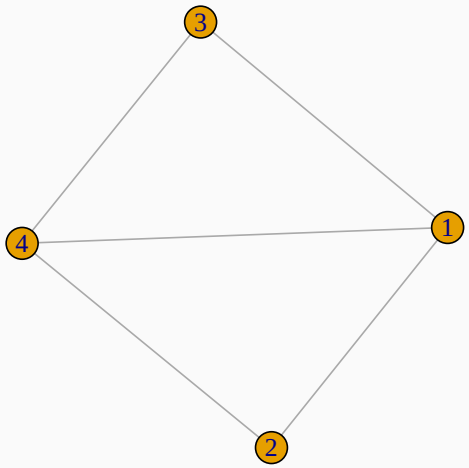

- Conclusion : $C_B(1) = 1/2$.

```
> betweenness(G1)
## [1] 0.5 0.0 0.0 0.5
```

Autre exemple : graphe étoilé

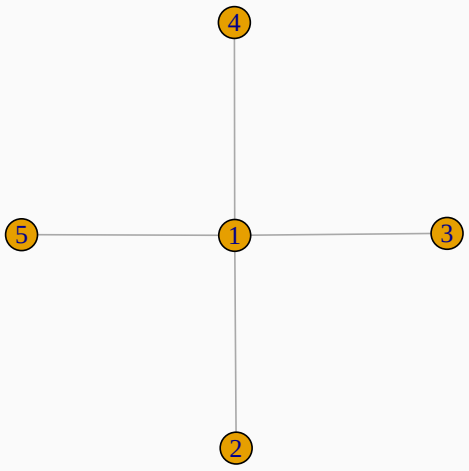

Autre exemple : graphe étoilé

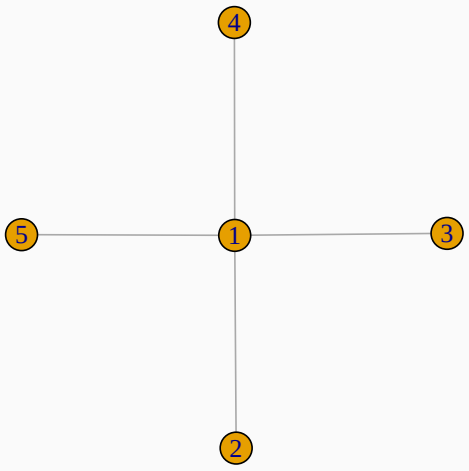


```
> betweenness(G2)
## [1] 6 0 0 0 0
```

Autre exemple : graphe étoilé

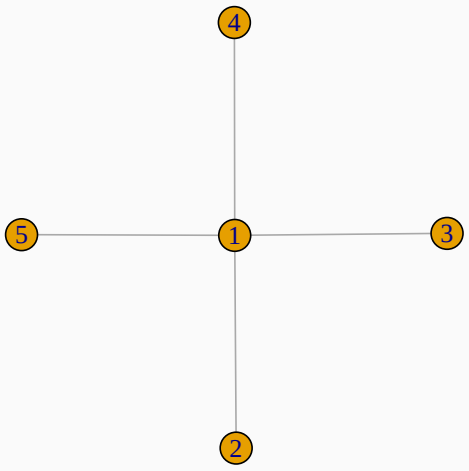


```
> betweenness(G2)
## [1] 6 0 0 0 0
```

Conclusion

On retrouve bien que seul le nœud 1 sert d'intermédiaire.

Commentaires

- Un des concepts les plus importants.
- $C_b(i) \nearrow$ s'il est point de passage sur un grand nombre de chemins entre deux nœuds.
- Mesure de l'utilité du nœud dans la communication et le transfert d'information dans le graphe.

Le coin R

Là encore les différents degrés d'importance des nœuds s'obtiennent directement avec R :

- Degrés et degré moyen :

```
> degree(kar) %>% head()
## [1] 16  9 10  6  3  4
> degree(kar) %>% mean()
## [1] 4.588235
```

- Degrés de proximité et d'intermédiarité :

```
> closeness(kar) %>% head() %>% round(3)
## [1] 0.017 0.015 0.017 0.014 0.011 0.012
> betweenness(kar) %>% head() %>% round(3)
## [1] 231.071  28.479  75.851   6.288   0.333  15.833
```

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Pourquoi des modèles sur les graphes ?

- Rappel : un graphe $G = (V, E)$.

Pourquoi des modèles sur les graphes ?

- Rappel : un graphe $G = (V, E)$.
- Modéliser : trouver des lois de probabilités sur la distribution des nœuds et/ou sur celle des arêtes.

Pourquoi des modèles sur les graphes ?

- Rappel : un graphe $G = (V, E)$.
- Modéliser : trouver des lois de probabilités sur la distribution des nœuds et/ou sur celle des arêtes.

But

1. Générer des graphes "réalistes".

Pourquoi des modèles sur les graphes ?

- Rappel : un graphe $G = (V, E)$.
- Modéliser : trouver des lois de probabilités sur la distribution des nœuds et/ou sur celle des arêtes.

But

1. Générer des graphes "réalistes".
2. Comprendre un graphe réel en ajustant un (bon) modèle dessus.

Pourquoi des modèles sur les graphes ?

- Rappel : un graphe $G = (V, E)$.
- Modéliser : trouver des lois de probabilités sur la distribution des nœuds et/ou sur celle des arêtes.

But

1. Générer des graphes "réalistes".
2. Comprendre un graphe réel en ajustant un (bon) modèle dessus.
3. Détecter des communautés ou clusters de nœuds.

Pourquoi des modèles sur les graphes ?

- Rappel : un graphe $G = (V, E)$.
- Modéliser : trouver des lois de probabilités sur la distribution des nœuds et/ou sur celle des arêtes.

But

1. Générer des graphes "réalistes".
2. Comprendre un graphe réel en ajustant un (bon) modèle dessus.
3. Détecter des communautés ou clusters de nœuds.
4. Faire de la prévision...

Modèle d'Erdös et Rényi

- Modèle le plus simple, introduit dans les années 1950.
- En général pour des graphes non dirigés.

Modèle d'Erdös et Rényi

- Modèle le plus simple, introduit dans les années 1950.
- En général pour des graphes non dirigés.
- Modèle à deux paramètres :
  - $n \in \mathbb{N}^\star$: nombre de nœuds ;
  - $p \in [0, 1]$: probabilité de connexion entre 2 nœuds.

Modèle d'Erdös et Rényi

- Modèle le plus simple, introduit dans les années 1950.
- En général pour des graphes non dirigés.
- Modèle à deux paramètres :
  - $n \in \mathbb{N}^\star$: nombre de nœuds ;
  - $p \in [0, 1]$: probabilité de connexion entre 2 nœuds.

Graphe d'Erdös et Rényi

Graphe à n nœuds où la probabilité qu'il y ait une arête entre 2 nœuds est une loi de Bernoulli $B(p)$.

Propriété (évidente)

La variable aléatoire D_i donnant le degré du nœud i dans un graphe $G(n, p)$ suit une loi binomiale $\mathcal{B}(n-1, p)$.

Propriété (évidente)

La variable aléatoire D_i donnant le degré du nœud i dans un graphe $G(n, p)$ suit une loi binomiale $\mathcal{B}(n-1, p)$.

- La loi binomiale est une loi à queue légère (peu de valeurs extrêmes).

Propriété (évidente)

La variable aléatoire D_i donnant le degré du nœud i dans un graphe $G(n, p)$ suit une loi binomiale $\mathcal{B}(n-1, p)$.

- La loi binomiale est une loi à queue légère (peu de valeurs extrêmes).
- Or, très souvent, dans les réseaux réels, la distribution des degrés est plutôt à queue lourde : un petit nombre de nœuds ont un degré élevé.

Propriété (évidente)

La variable aléatoire D_i donnant le degré du nœud i dans un graphe $G(n, p)$ suit une loi binomiale $\mathcal{B}(n-1, p)$.

- La loi binomiale est une loi à queue légère (peu de valeurs extrêmes).
- Or, très souvent, dans les réseaux réels, la distribution des degrés est plutôt à queue lourde : un petit nombre de nœuds ont un degré élevé.

$\Longrightarrow$ modèle souvent un peu trop simple pour des graphes réels.

Le coin R

- On peut générer des graphes $G(n, p)$ avec la fonction sample_gnp.

Le coin R

- On peut générer des graphes $G(n, p)$ avec la fonction sample_gnp.

```
> set.seed(1234)
> G1 <- sample_gnp(n=20,p=0.2)
> plot(G1)
```

```
> set.seed(1234)
> G2 <- sample_gnp(n=20,p=0.6)
> plot(G2)
```

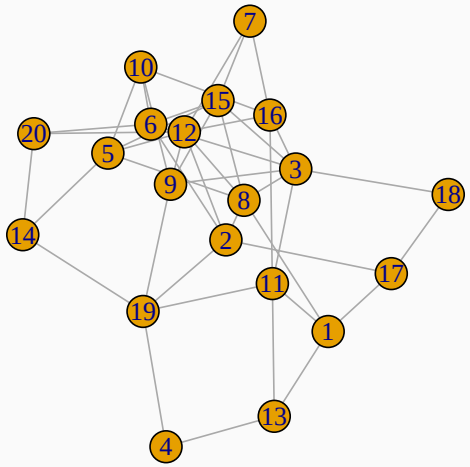

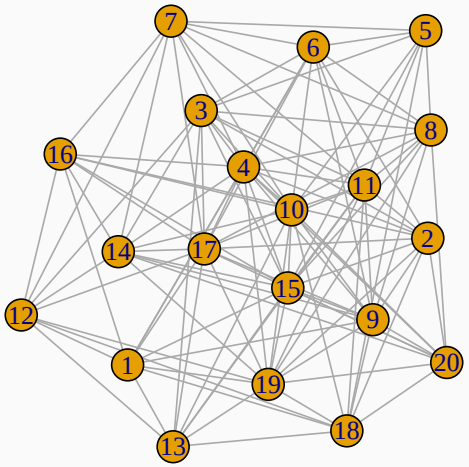

Stochastic Bloc Model (SBM)

Idée

- Existence de groupes de nœuds.

Stochastic Bloc Model (SBM)

Idée

- Existence de groupes de nœuds.
- Fortes connexions entre les nœuds d'un même groupe.

Stochastic Bloc Model (SBM)

Idée

- Existence de groupes de nœuds.
- Fortes connexions entre les nœuds d'un même groupe.
- Faibles connexions entre les nœuds de groupes différents.

Stochastic Bloc Model (SBM)

Idée

- Existence de groupes de nœuds.
- Fortes connexions entre les nœuds d'un même groupe.
- Faibles connexions entre les nœuds de groupes différents.

Modélisation

Représenter ces connexions à l'aide d'une matrice $K \times K$ où K est le nombre de groupes.

Graphe SBM

- Paramètres : K nombre de groupes, n nombre de nœuds, $\pi = (\pi_1, \ldots, \pi_K)$, $\Lambda = (\lambda_{k\ell})_{1 \leq k,\ell \leq K}$ matrice $K \times K$.

Graphe SBM

- Paramètres : K nombre de groupes, n nombre de nœuds, $\pi = (\pi_1, \ldots, \pi_K)$, $\Lambda = (\lambda_{k\ell})_{1 \leq k,\ell \leq K}$ matrice $K \times K$.
- $Z_1, \ldots, Z_n$ i.i.d. avec $Z_i \sim \mathcal{M}(n, \pi)$ (variable latente qui représente le groupe du nœud i).

Graphe SBM

- Paramètres : K nombre de groupes, n nombre de nœuds, $\pi = (\pi_1, \ldots, \pi_K)$, $\Lambda = (\lambda_{k\ell})_{1 \leq k,\ell \leq K}$ matrice $K \times K$.
- $Z_1, \ldots, Z_n$ i.i.d. avec $Z_i \sim \mathcal{M}(n, \pi)$ (variable latente qui représente le groupe du nœud i).
- Une arête entre les nœuds i et j est représentée par une variable aléatoire A_{ij} telle que

$$A_{ij} | (Z_i = k, Z_j = \ell) \sim B(\lambda_{k\ell}).$$

Graphe SBM

- Paramètres : K nombre de groupes, n nombre de nœuds, $\pi = (\pi_1, \ldots, \pi_K)$, $\Lambda = (\lambda_{k\ell})_{1 \leq k,\ell \leq K}$ matrice $K \times K$.
- $Z_1, \ldots, Z_n$ i.i.d. avec $Z_i \sim \mathcal{M}(n, \pi)$ (variable latente qui représente le groupe du nœud i).
- Une arête entre les nœuds i et j est représentée par une variable aléatoire A_{ij} telle que

$$A_{ij} | (Z_i = k, Z_j = \ell) \sim B(\lambda_{k\ell}).$$

Interprétation

La distribution des arêtes entre

- les nœuds d'un même groupe est la même.
- les nœuds de deux groupes différents est identique aussi.

Exemple

On peut générer des graphes SBM avec la fonction sample_sbm.

```
> set.seed(1234)
> n <- 40
> eff <- rmultinom(n=40,size=1,prob=c(0.3,0.4,0.3)) %>% apply(1,sum)
> eff
## [1] 10 19 11
> bern.mat <- matrix(c(0.9,0.05,0.05,0.05,0.8,0.05,0.05,0.05,0.7),ncol=3)
> G1 <- sample_sbm(n,bern.mat,eff)
> gr <- rep(1:3,eff)
> plot(G1,vertex.color=gr)
```

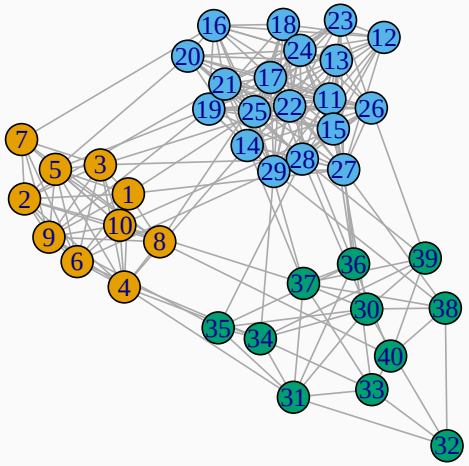

SBM et détection de communautés

Idée

Utiliser les SBM pour détecter des communautés (alternative aux techniques qui seront vues en section 5) en

SBM et détection de communautés

Idée

Utiliser les SBM pour détecter des communautés (alternative aux techniques qui seront vues en section 5) en

- estimant le nombre de groupes d'un SBM ;
- estimant les groupes de chaque nœud.

- Il existe différentes approches pour estimer ces quantités, notamment basées sur les modèles de mélange (voir [Daudin et al., 2008]).
- Par exemple les méthodes VEM (approche variationnelle de l'algorithme EM) pour π et Λ.
- et l'ICL (Integrated classification likelihood) pour le nombre de groupes K.

SBM et détection de communautés

Idée

Utiliser les SBM pour détecter des communautés (alternative aux techniques qui seront vues en section 5) en

- estimant le nombre de groupes d'un SBM ;
- estimant les groupes de chaque nœud.

- Il existe différentes approches pour estimer ces quantités, notamment basées sur les modèles de mélange (voir [Daudin et al., 2008]).
- Par exemple les méthodes VEM (approche variationnelle de l'algorithme EM) pour π et Λ.
- et l'ICL (Integrated classification likelihood) pour le nombre de groupes K.
- Sur R, on pourra utiliser BM_bernoulli du package blockmodels.

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

- Dans de nombreuses applications où on souhaite avoir une approche par graphe, ce dernier peut ne pas être spécifié.
- On dispose, de manière classique, d'individus $x_1, \ldots, x_n$ avec $x_i \in \mathbb{R}^p$.

- Dans de nombreuses applications où on souhaite avoir une approche par graphe, ce dernier peut ne pas être spécifié.
- On dispose, de manière classique, d'individus $x_1, \ldots, x_n$ avec $x_i \in \mathbb{R}^p$.

Objectifs

Définir un graphe $G = (V, E)$ où

1. les sommets sont les individus $V = \{1, \ldots, n\}$;
2. les arêtes sont définies à partir de la proximité ou la similarité entre les individus.

Un exemple

- On considère un sous-échantillon des iris de Fisher.

```
> data(iris)
> set.seed(12345)
> donnees <- iris[sample(nrow(iris),30),]
> head(donnees)
##     Sepal.Length Sepal.Width Petal.Length Petal.Width    Species
## 142          6.9         3.1          5.1         2.3  virginica
## 51           7.0         3.2          4.7         1.4 versicolor
## 58           4.9         2.4          3.3         1.0 versicolor
## 93           5.8         2.6          4.0         1.2 versicolor
## 75           6.4         2.9          4.3         1.3 versicolor
## 96           5.7         3.0          4.2         1.2 versicolor
```

Un exemple

- On considère un sous-échantillon des iris de Fisher.

```
> data(iris)
> set.seed(12345)
> donnees <- iris[sample(nrow(iris),30),]
> head(donnees)
##     Sepal.Length Sepal.Width Petal.Length Petal.Width    Species
## 142          6.9         3.1          5.1         2.3  virginica
## 51           7.0         3.2          4.7         1.4 versicolor
## 58           4.9         2.4          3.3         1.0 versicolor
## 93           5.8         2.6          4.0         1.2 versicolor
## 75           6.4         2.9          4.3         1.3 versicolor
## 96           5.7         3.0          4.2         1.2 versicolor
```

Objectif

Construire un graphe en utilisant uniquement les variables continues.

Matrice de distance ou similarité

- Les arêtes vont être définies à partir de la proximité-similarité entre individus.

Matrice de distance ou similarité

- Les arêtes vont être définies à partir de la proximité-similarité entre individus.
- Il faut donc définir une matrice de distance $D = (d_{ij}), 1 \leq i, j \leq n$ tel que d_{ij} est petit si i et j sont proches

Matrice de distance ou similarité

- Les arêtes vont être définies à partir de la proximité-similarité entre individus.
- Il faut donc définir une matrice de distance $D = (d_{ij}), 1 \leq i, j \leq n$ tel que d_{ij} est petit si i et j sont proches
- ou une matrice de similarité $S = (s_{ij}), 1 \leq i, j \leq n$ tel que s_{ij} est grand si i et j sont similaires

Exemple

- Sur les iris on peut calculer la distance euclidienne entre iris sur les 4 variables quantitatives.

```
> D <- as.matrix(dist(donnees[,-5]))
```

Exemple

- Sur les iris on peut calculer la distance euclidienne entre iris sur les 4 variables quantitatives.

```
> D <- as.matrix(dist(donnees[,-5]))
```

- Que l'on peut visualiser à l'aide d'un heatmap :

```
> heatmap(D)
```

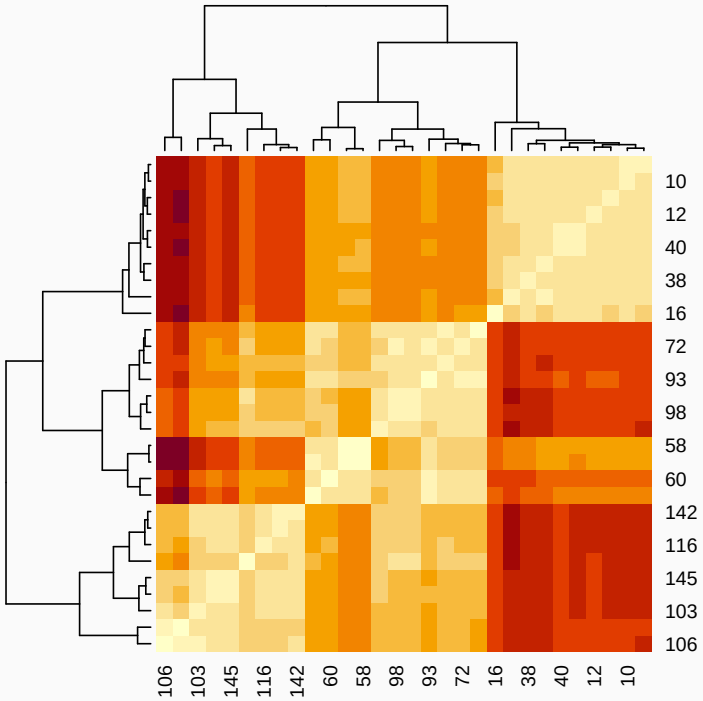

Neighborhood graph

- Une fois D ou S calculée, on définit des arêtes en fonction de la proximité entre individus.

Neighborhood graph

- Une fois D ou S calculée, on définit des arêtes en fonction de la proximité entre individus.

ε-neighborhood graph

Soit $\varepsilon > 0$, on appelle ε-neighborhood graph le graphe associé à la matrice d'adjacence

$$A_{ij} = \begin{cases} 1 & \text{si } d_{ij} \leq \varepsilon \\ 0 & \text{sinon.} \end{cases}$$

Neighborhood graph

- Une fois D ou S calculée, on définit des arêtes en fonction de la proximité entre individus.

ε-neighborhood graph

Soit $\varepsilon > 0$, on appelle ε-neighborhood graph le graphe associé à la matrice d'adjacence

$$A_{ij} = \begin{cases} 1 & \text{si } d_{ij} \leq \varepsilon \\ 0 & \text{sinon.} \end{cases}$$

Choix de ε

- Il influence le nombre d'arêtes : $\varepsilon \nearrow \Longrightarrow |E| \nearrow$.
- A faire en fonction de l'analyse du graphe (nombre de communautés par exemple...).

Graphe par plus proches voisins

- Idée : définir une arête entre i et j si i appartient aux $k$ppv de j et/ou j appartient aux $k$ppv de i.

Graphe par plus proches voisins

- Idée : définir une arête entre i et j si i appartient aux $k$ppv de j et/ou j appartient aux $k$ppv de i.

Graphes de plus proches voisins.

Soit $k \leq n$.

- graphe des k plus proches voisins : matrice d'adjacence

$$A_{ij} = \begin{cases} 1 & \text{si } i \text{ est parmi les } k\text{ppv de } j \text{ ou } j \text{ est parmi les } k\text{ppv de } i \\ 0 & \text{sinon.} \end{cases}$$

Graphe par plus proches voisins

- Idée : définir une arête entre i et j si i appartient aux $k$ppv de j et/ou j appartient aux $k$ppv de i.

Graphes de plus proches voisins.

Soit $k \leq n$.

- graphe des k plus proches voisins : matrice d'adjacence

$$A_{ij} = \begin{cases} 1 & \text{si } i \text{ est parmi les } k\text{ppv de } j \text{ ou } j \text{ est parmi les } k\text{ppv de } i \\ 0 & \text{sinon.} \end{cases}$$

- graphe des k plus proches voisins mutuels : matrice d'adjacence

$$A_{ij} = \begin{cases} 1 & \text{si } i \text{ est parmi les } k\text{ppv de } j \text{ et } j \text{ est parmi les } k\text{ppv de } i \\ 0 & \text{sinon.} \end{cases}$$

Remarques

- Définis ainsi les graphes par k ppv sont non orientés mais il est facile d'obtenir un graphe orienté pour les k plus proches voisins (non mutuels).

Remarques

- Définis ainsi les graphes par k ppv sont non orientés mais il est facile d'obtenir un graphe orienté pour les k plus proches voisins (non mutuels).
- Choix de k : il influence encore le nombre d'arêtes du graphe $k \nearrow \Longrightarrow |E| \nearrow$.

Remarques

- Définis ainsi les graphes par k ppv sont non orientés mais il est facile d'obtenir un graphe orienté pour les k plus proches voisins (non mutuels).
- Choix de k : il influence encore le nombre d'arêtes du graphe $k \nearrow \Longrightarrow |E| \nearrow$.
- Sur R, on peut utiliser la fonction nng du package cccd.

Le coin R

```
> library(cccd)
> gppv2 <- as.undirected(nng(dx=D,k=2,mutual=FALSE))
> gppv20 <- as.undirected(nng(dx=D,k=20,mutual=FALSE))
> plot(gppv2)
> plot(gppv20)
> ecount(gppv2)
## [1] 44
> ecount(gppv20)
## [1] 354
```

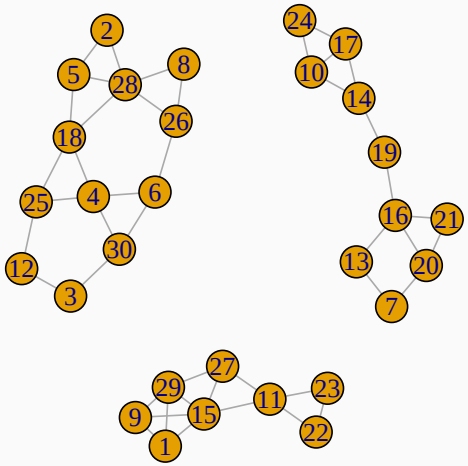

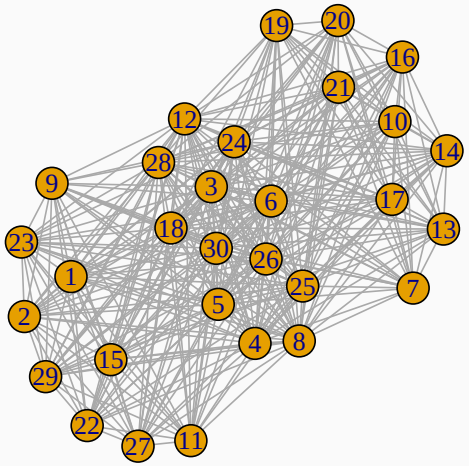

Remarque

Le graphe à 2 plus proches voisins permet d'identifier parfaitement les espèces.

```
> gppv2_bis <- gppv2
> V(gppv2_bis)$color <- donnees[,5]
> plot(gppv2_bis)
```

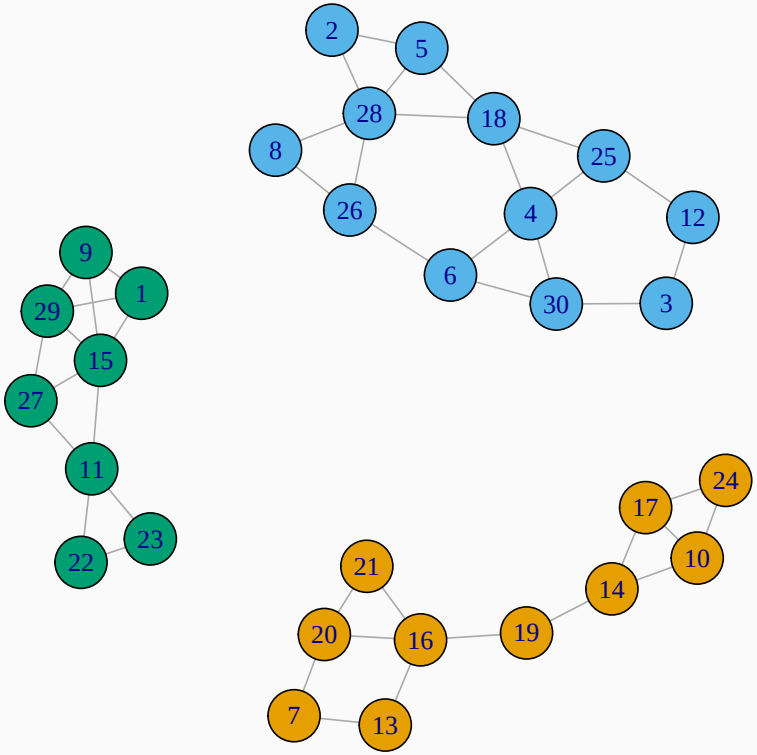

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

But

- Partitionner les nœuds du graphe en un nombre fini de groupes.
- Trouver des groupes de nœuds homogènes, des individus au comportement similaire.

But

- Partitionner les nœuds du graphe en un nombre fini de groupes.
- Trouver des groupes de nœuds homogènes, des individus au comportement similaire.

Idéal

- Beaucoup de connexions entre les nœuds d'une même communauté.
- Peu de connexions entre les nœuds de communautés différentes.

But

- Partitionner les nœuds du graphe en un nombre fini de groupes.
- Trouver des groupes de nœuds homogènes, des individus au comportement similaire.

Idéal

- Beaucoup de connexions entre les nœuds d'une même communauté.
- Peu de connexions entre les nœuds de communautés différentes.

Remarque

Thème très proche du clustering.

Comment ?

Différentes méthodes pour détecter des communautés :

- techniques basées sur la modularité.
- clustering spectral.
- méthodes probabilistes (modèles SBM).
- ...

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Idée

- Définir l'équivalent du node betweeness pour les arêtes.

Idée

- Définir l'équivalent du node betweeness pour les arêtes.
- Identifier des arêtes qui relient des "groupes",

Idée

- Définir l'équivalent du node betweeness pour les arêtes.
- Identifier des arêtes qui relient des "groupes", puis les supprimer.
- Critère élevé pour des arêtes qui relient des groupes.

Idée

- Définir l'équivalent du node betweeness pour les arêtes.
- Identifier des arêtes qui relient des "groupes", puis les supprimer.
- Critère élevé pour des arêtes qui relient des groupes.

Définition

L'edge betweeness d'une arête e est défini par

$$E_B(e) = \sum_{j,k,j\neq k} \frac{g_{jk}(e)}{g_{jk}}$$

où

- g_{jk} est le nombre de plus courts chemins entre j et k.
- $g_{jk}(e)$ est le nombre de plus courts chemins entre j et k qui empruntent l'arête e.

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(1,2)$		
$(1,3)$		
$(1,4)$		
$(2,3)$		
$(2,4)$		
$(3,4)$		

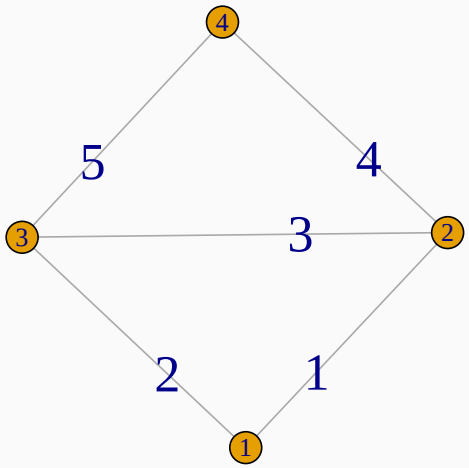

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(1,2)$	1	
$(1,3)$	1	
$(1,4)$	2	
$(2,3)$	1	
$(2,4)$	1	
$(3,4)$	1	

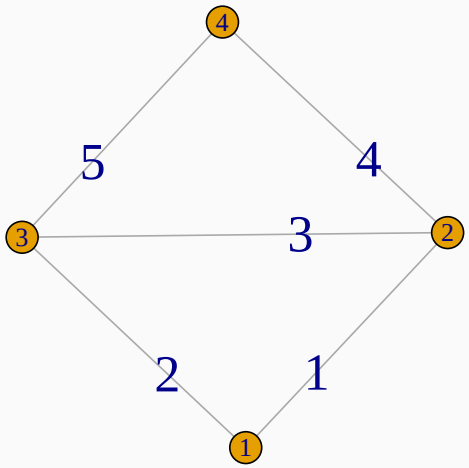

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(1,2)$	1	1
$(1,3)$	1	0
$(1,4)$	2	1
$(2,3)$	1	0
$(2,4)$	1	0
$(3,4)$	1	0

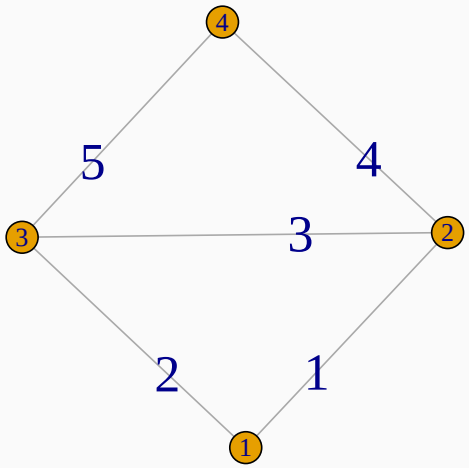

Exemple

(j,k)	g_{jk}	$g_{jk}(1)$
$(1,2)$	1	1
$(1,3)$	1	0
$(1,4)$	2	1
$(2,3)$	1	0
$(2,4)$	1	0
$(3,4)$	1	0

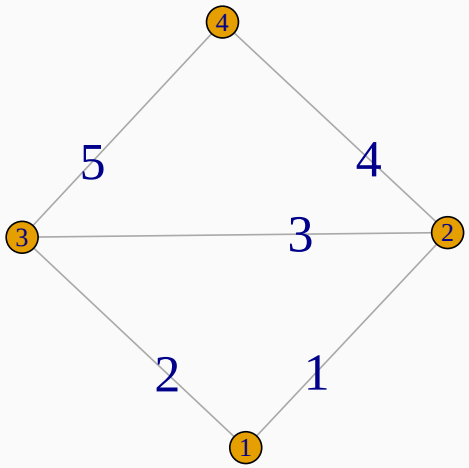

- Conclusion : $E_B(1) = 1.5$.

```
> edge_betweenness(G)
## [1] 1.5 1.5 1.0 1.5 1.5
```

EB pour clustering

- $E_b(e)$ élevé si e relie des groupes plutôt que des arêtes internes au groupe.

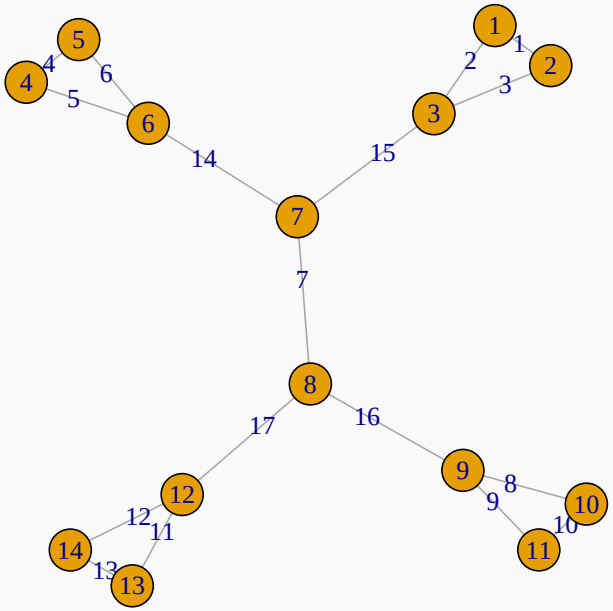


```
> edge_betweenness(G)
##  [1]  1 12 12  1 12 12 49 12 12  1 12 12  1 33 33 33 33
```

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.
2. Retirer l'arête avec le plus grand EB.

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.
2. Retirer l'arête avec le plus grand EB.
3. Recalculer l'EB du nouveau graphe.

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.
2. Retirer l'arête avec le plus grand EB.
3. Recalculer l'EB du nouveau graphe.
4. Retirer l'arête...

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.
2. Retirer l'arête avec le plus grand EB.
3. Recalculer l'EB du nouveau graphe.
4. Retirer l'arête...
5. Jusqu'à isoler tous les nœuds.

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.
2. Retirer l'arête avec le plus grand EB.
3. Recalculer l'EB du nouveau graphe.
4. Retirer l'arête...
5. Jusqu'à isoler tous les nœuds.

Remarque

- Processus similaire à la CAH.

Classification par EB

- Idée : enlever les arêtes à fort EB les unes après les autres.

Algorithme [Girvan and Newman, 2002]

1. Calculer l'EB de toutes les arêtes.
2. Retirer l'arête avec le plus grand EB.
3. Recalculer l'EB du nouveau graphe.
4. Retirer l'arête...
5. Jusqu'à isoler tous les nœuds.

Remarque

- Processus similaire à la CAH.
- On peut visualiser l'algorithme avec un dendrogramme.

Le dendrogramme

```
> clust.EB <- cluster_edge_betweenness(G)
> dendPlot(clust.EB)
```

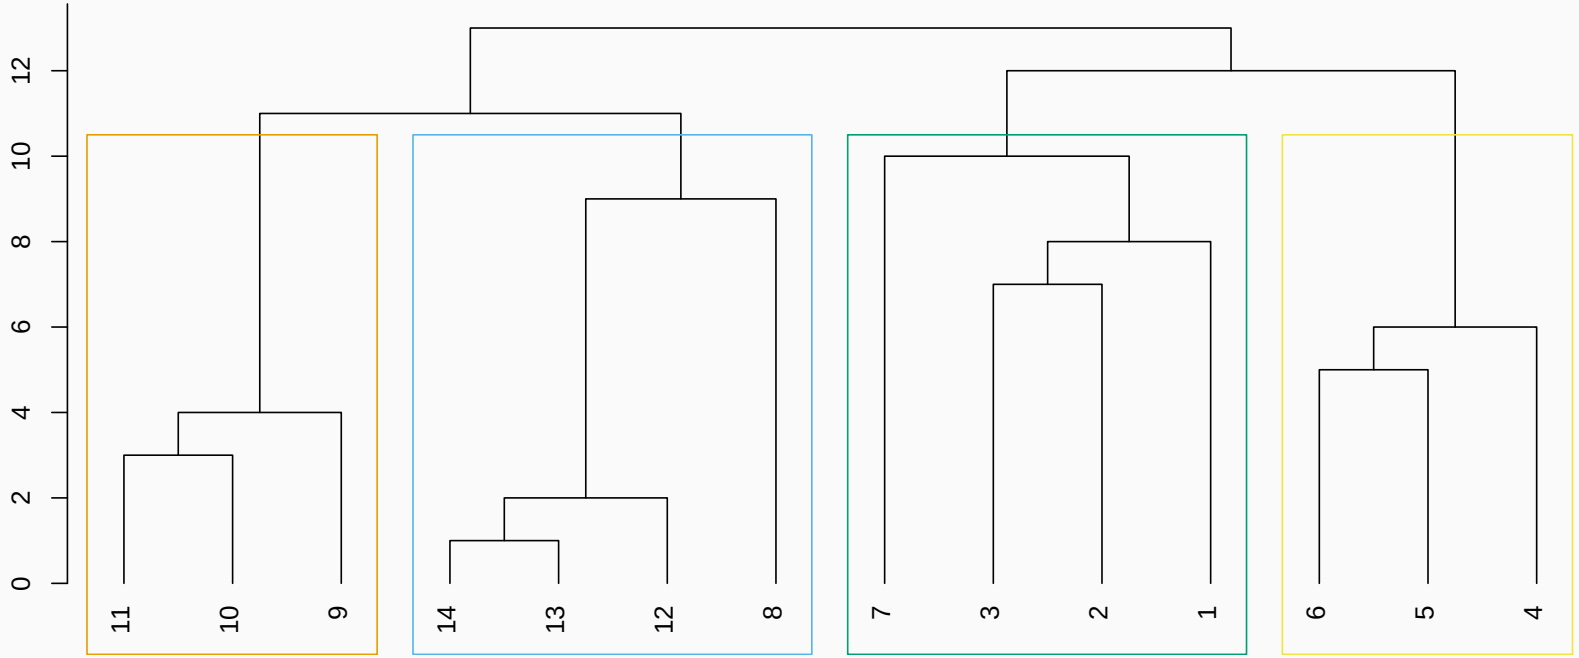

Le dendrogramme

```
> clust.EB <- cluster_edge_betweenness(G)
> dendPlot(clust.EB)
```

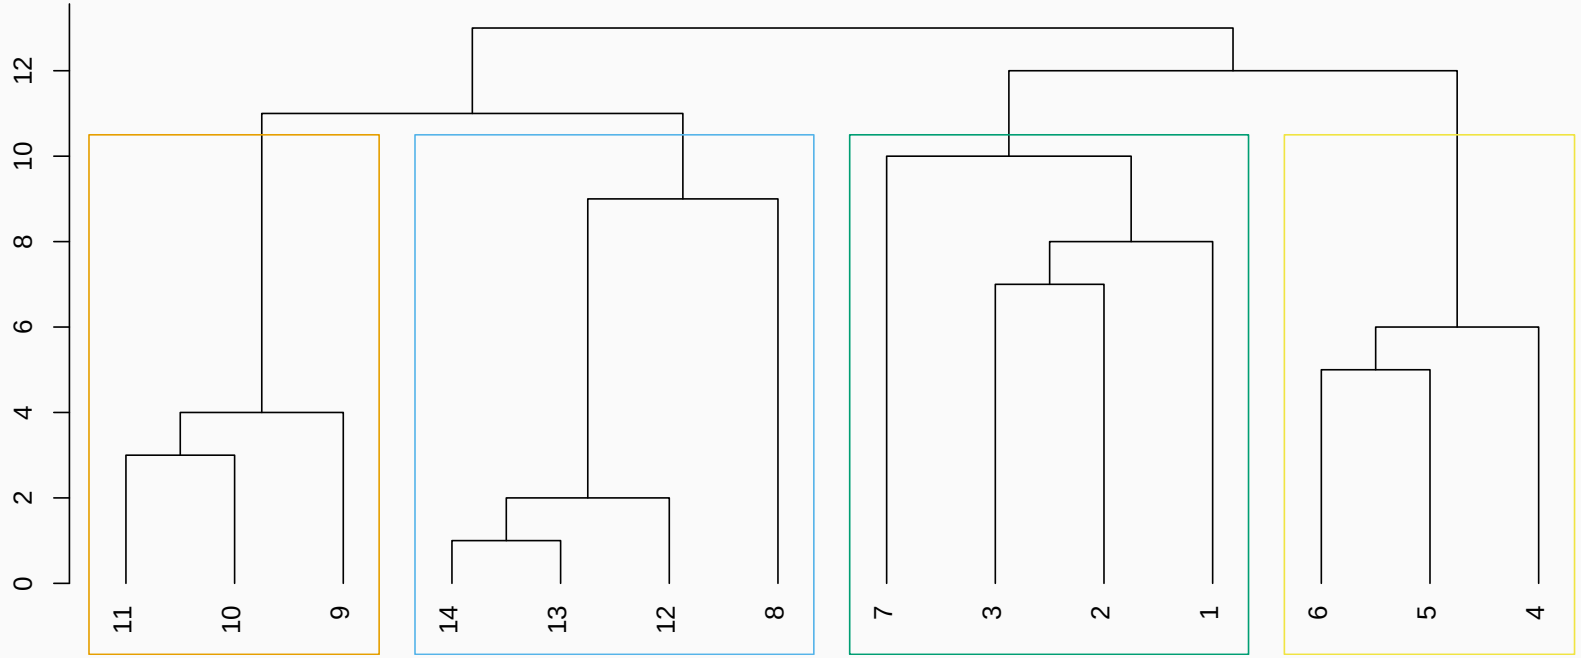

Question

Où couper le dendrogramme pour obtenir les groupes ?

Couper le dendrogramme

- On se donne un critère qui mesure la qualité d'une partition associée à une coupure.
- On choisit la partition qui optimise le critère choisi.

Couper le dendrogramme

- On se donne un critère qui mesure la qualité d'une partition associée à une coupure.
- On choisit la partition qui optimise le critère choisi.
- Critère usuel : la modularité

```
> clust.EB$modularity %>% round(3)
##  [1] -0.074 -0.022  0.074  0.126  0.223  0.272  0.372  0.420  0.521  0.543
## [11]  0.566  0.503  0.441  0.000
```

Couper le dendrogramme

- On se donne un critère qui mesure la qualité d'une partition associée à une coupure.
- On choisit la partition qui optimise le critère choisi.
- Critère usuel : la modularité

```
> clust.EB$modularity %>% round(3)
##  [1] -0.074 -0.022  0.074  0.126  0.223  0.272  0.372  0.420  0.521  0.543
## [11]  0.566  0.503  0.441  0.000
```

Conclusion

On retiendra une partition en 4 groupes.

Visualisation des groupes

```
> plot(G,vertex.color=clust.EB$membership)
```

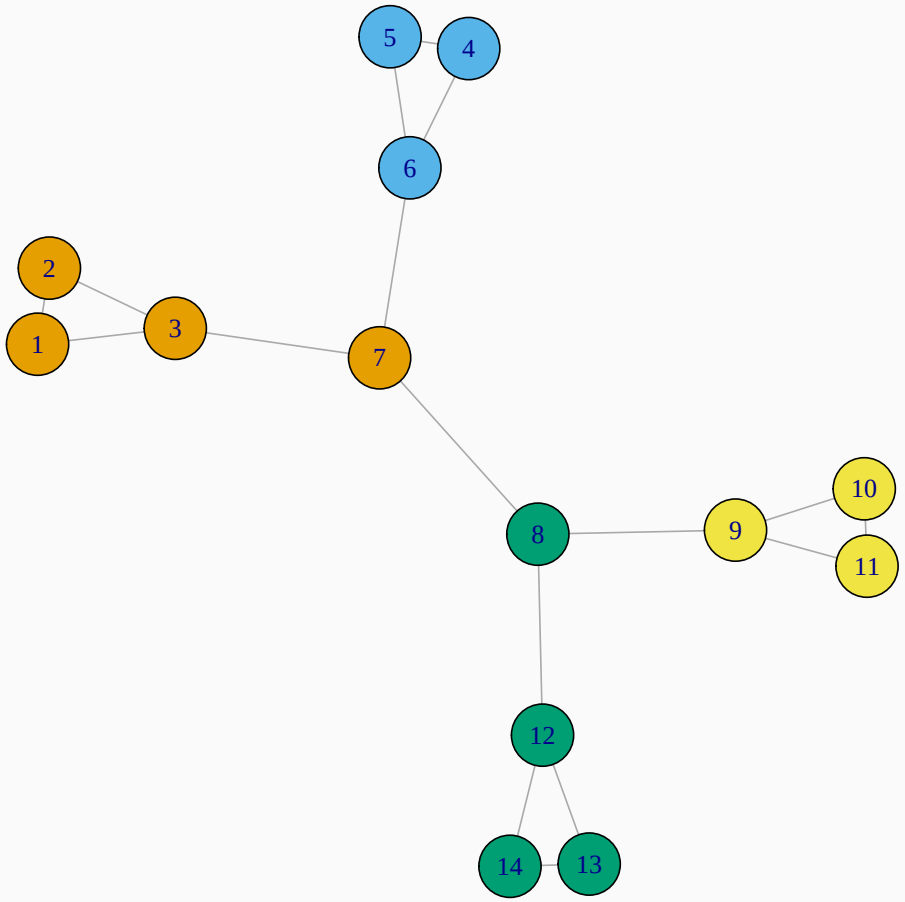

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

- Rappel : $G = (V, E)$ un graphe, A sa matrice d'adjacence.
- On cherche une partition de V l'ensemble des nœuds en K groupes ou communautés $\mathcal{C}_1, \ldots, \mathcal{C}_K$.

- Rappel : $G = (V, E)$ un graphe, A sa matrice d'adjacence.
- On cherche une partition de V l'ensemble des nœuds en K groupes ou communautés $\mathcal{C}_1, \ldots, \mathcal{C}_K$.

Idée

1. Se donner un critère qui mesure la performance d'une partition.
2. Choisir la partition qui optimise le critère choisi.

- Rappel : $G = (V, E)$ un graphe, A sa matrice d'adjacence.
- On cherche une partition de V l'ensemble des nœuds en K groupes ou communautés $\mathcal{C}_1, \ldots, \mathcal{C}_K$.

Idée

1. Se donner un critère qui mesure la performance d'une partition.
2. Choisir la partition qui optimise le critère choisi.

Modularité

- Un des critères les plus utilisés.
- Idée : comparer la performance de la partition sur le graphe à sa performance sur un graphe aléatoire.

- Soit $\mathcal{C} = \{\mathcal{C}_1, \ldots, \mathcal{C}_K\}$ une partition des nœuds de $G = (V, E)$.

Modularité de $\mathcal{C}$

$$\mathcal{M}(\mathcal{C}) = \frac{1}{2m} \sum_{1 \leq i,j \leq n} (A_{ij} - P_{ij}) \delta(\mathcal{C}(i), \mathcal{C}(j))$$

où

- $m = |E|$.
- $\delta(\mathcal{C}(i), \mathcal{C}(j)) = 1$ si i et j sont dans le même élément de la partition, 0 sinon
- P_{ij} représente l'espérance du nombre d'arêtes entre i et j sous un modèle nul (graphe aléatoire) à définir.

- Soit $\mathcal{C} = \{\mathcal{C}_1, \ldots, \mathcal{C}_K\}$ une partition des nœuds de $G = (V, E)$.

Modularité de $\mathcal{C}$

$$\mathcal{M}(\mathcal{C}) = \frac{1}{2m} \sum_{1 \leq i,j \leq n} (A_{ij} - P_{ij}) \delta(\mathcal{C}(i), \mathcal{C}(j))$$

où

- $m = |E|$.
- $\delta(\mathcal{C}(i), \mathcal{C}(j)) = 1$ si i et j sont dans le même élément de la partition, 0 sinon
- P_{ij} représente l'espérance du nombre d'arêtes entre i et j sous un modèle nul (graphe aléatoire) à définir.

Interprétation

- $-1 \leq \mathcal{M}(\mathcal{C}) \leq 1$;
- $\mathcal{M}(\mathcal{C}) \nearrow$ plus d'arêtes dans les communautés que le modèle nul (bonnes communautés) et réciproquement lorsque $\mathcal{M}(\mathcal{C}) \searrow$.

Le modèle nul

- Il peut être spécifier de plusieurs façons (voir [Fortunato, 2010]).

Le modèle nul

- Il peut être spécifier de plusieurs façons (voir [Fortunato, 2010]).
- Première approche : les m arêtes sont distribuées uniformément entre les paires de nœuds :

$$P_{ij} = \frac{2m}{n(n-1)}, \quad 1 \leq i, j \leq n.$$

Le modèle nul

- Il peut être spécifier de plusieurs façons (voir [Fortunato, 2010]).
- Première approche : les m arêtes sont distribuées uniformément entre les paires de nœuds :

$$P_{ij} = \frac{2m}{n(n-1)}, \quad 1 \leq i, j \leq n.$$

- Seconde approche : générer aléatoirement les arêtes en conservant les degrés de centralité des nœuds :

$$P_{ij} = \frac{d_i d_j}{2m}, \quad 1 \leq i, j \leq n.$$

On a alors

$$\mathcal{M}(\mathcal{C}) = \frac{1}{2m} \sum_{1 \leq i,j \leq n} \left(A_{ij} - \frac{d_i d_j}{2m} \right) \delta(\mathcal{C}(i), \mathcal{C}(j))$$

- C'est souvent la seconde approche qui est utilisée.
- Le terme
$$A_{ij} - \frac{d_i d_j}{2m}$$
correspond à la différence de lien entre le graphe considéré et un graphe aléatoire dont la contraine est la conservation des degrés de sommets.

- C'est souvent la seconde approche qui est utilisée.
- Le terme
$$A_{ij} - \frac{d_i d_j}{2m}$$
correspond à la différence de lien entre le graphe considéré et un graphe aléatoire dont la contraine est la conservation des degrés de sommets.
- Si on a beaucoup d'arêtes connectés dans les communautés alors A_{ij} sera souvent plus grand que $\frac{d_i d_j}{2m}$

- C'est souvent la seconde approche qui est utilisée.
- Le terme
$$A_{ij} - \frac{d_i d_j}{2m}$$
correspond à la différence de lien entre le graphe considéré et un graphe aléatoire dont la contraine est la conservation des degrés de sommets.
- Si on a beaucoup d'arêtes connectés dans les communautés alors A_{ij} sera souvent plus grand que $\frac{d_i d_j}{2m} \Longrightarrow \mathcal{M}(\mathcal{C}) \nearrow$.

- C'est souvent la seconde approche qui est utilisée.
- Le terme
$$A_{ij} - \frac{d_i d_j}{2m}$$
correspond à la différence de lien entre le graphe considéré et un graphe aléatoire dont la contraine est la conservation des degrés de sommets.
- Si on a beaucoup d'arêtes connectés dans les communautés alors A_{ij} sera souvent plus grand que $\frac{d_i d_j}{2m} \Longrightarrow \mathcal{M}(\mathcal{C}) \nearrow$.
- Sous R, on utilise la fonction modularity.

Le coin R

- On considère les 2 partitions suivantes pour le même graphe.

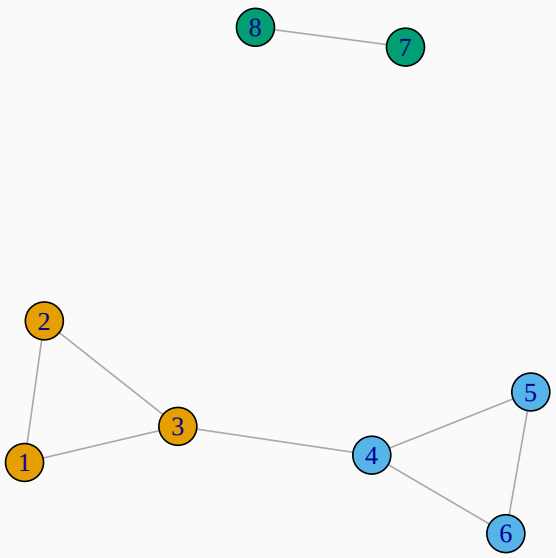

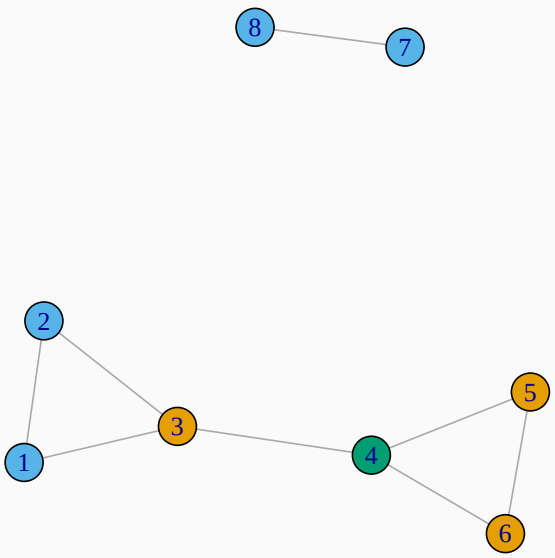

Le coin R

- On considère les 2 partitions suivantes pour le même graphe.

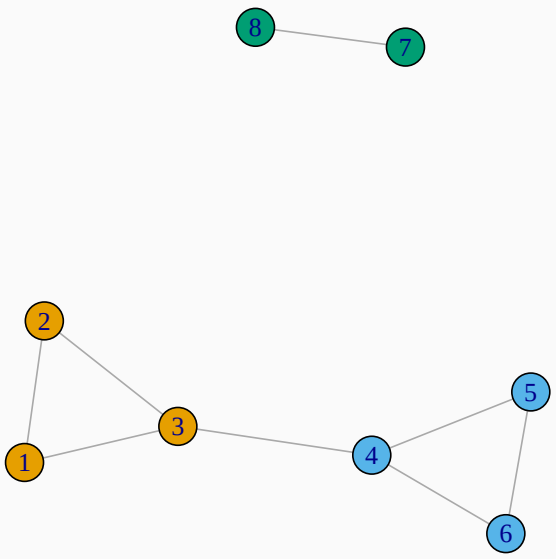

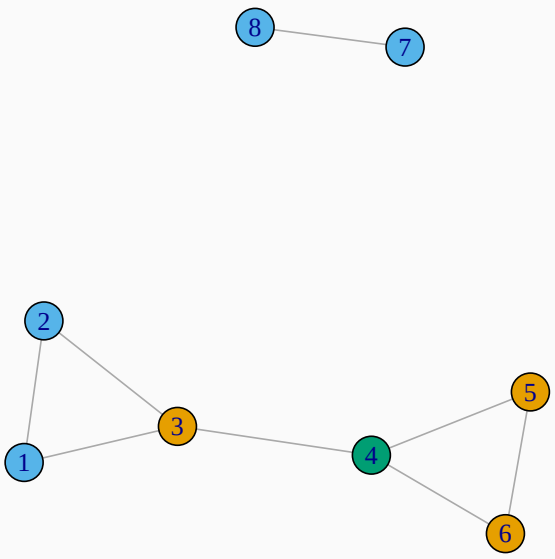

- On obtient les modularités avec

```
> modularity(G,cl1)
## [1] 0.4765625
> modularity(G,cl2)
## [1] 0.0078125
```

Maximisation de la modularité

- Idée : Considérer toutes les partitions et choisir celle qui maximise la modularité.

Maximisation de la modularité

- Idée : Considérer toutes les partitions et choisir celle qui maximise la modularité.

Approche exhaustive

1. $\mathcal{V}$: ensemble des partitions des nœuds de $G = (V, E)$.
2. Pour chaque $\mathcal{C} \in \mathcal{V}$ calculer $\mathcal{M}(\mathcal{C})$.
3. Renvoyer

$$\operatorname*{argmax}_{\mathcal{C} \in \mathcal{V}} \mathcal{M}(\mathcal{C}).$$

Maximisation de la modularité

- Idée : Considérer toutes les partitions et choisir celle qui maximise la modularité.

Approche exhaustive

1. $\mathcal{V}$: ensemble des partitions des nœuds de $G = (V, E)$.
2. Pour chaque $\mathcal{C} \in \mathcal{V}$ calculer $\mathcal{M}(\mathcal{C})$.
3. Renvoyer

$$\operatorname*{argmax}_{\mathcal{C} \in \mathcal{V}} \mathcal{M}(\mathcal{C}).$$

- Sur R on utilise cluster_optimal.

Le coin R

```
> plot(G1)
```

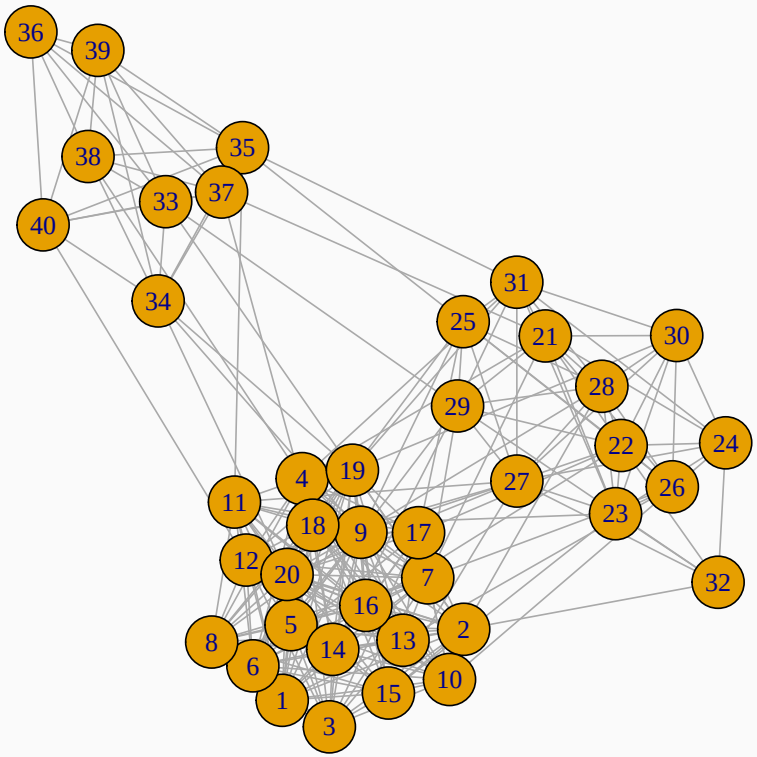

Le coin R

```
> cl.exh <- cluster_optimal(G1)
> V(G1)$color <- membership(cl.exh)
> G1$palette <- categorical_pal(length(cl.exh))
> plot(G1)
```

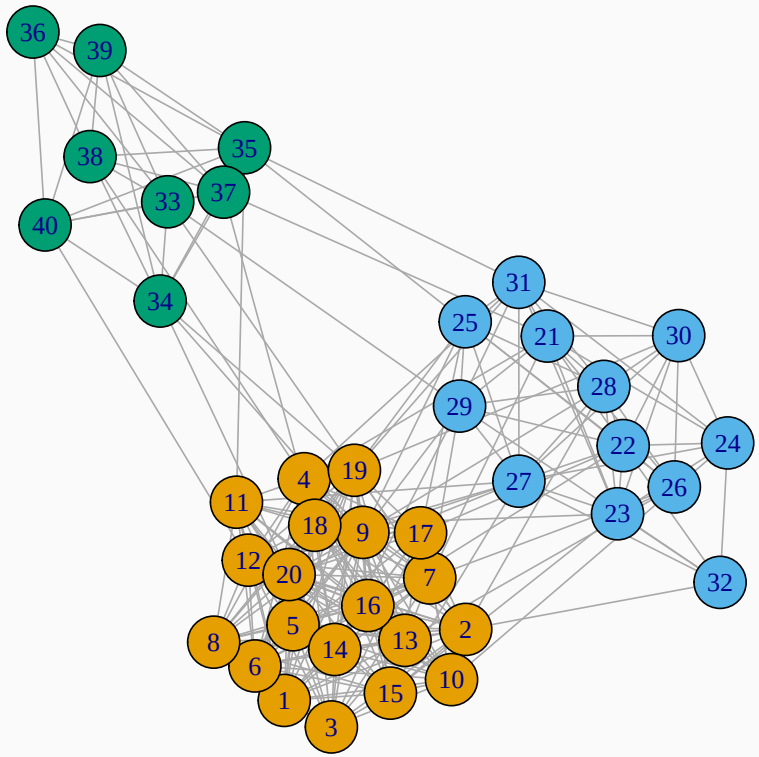

Complexité

- Problème NP complet.

Complexité

- Problème NP complet.
- Si $|V|$ est "grand", impossible dans un temps raisonnable.

Complexité

- Problème NP complet.
- Si $|V|$ est "grand", impossible dans un temps raisonnable.
- Solution : utiliser des algorithmes itératifs qui vont converger vers des maxima locaux.

La méthode de Louvain

- Proposée par des chercheurs français qui se sont retrouvés à Louvain [Blondel et al., 2008].
- Elle repose sur deux phases distinctes, répétées itérativement.
- On pourra consulter l'url suivante pour plus de détails :

  http://cedric.cnam.fr/vertigo/Cours/RCP216/coursFouilleGraphesReseauxSociaux2.html

Passe 1 - phase 1, itération 1

- Chaque nœud forme une communauté.

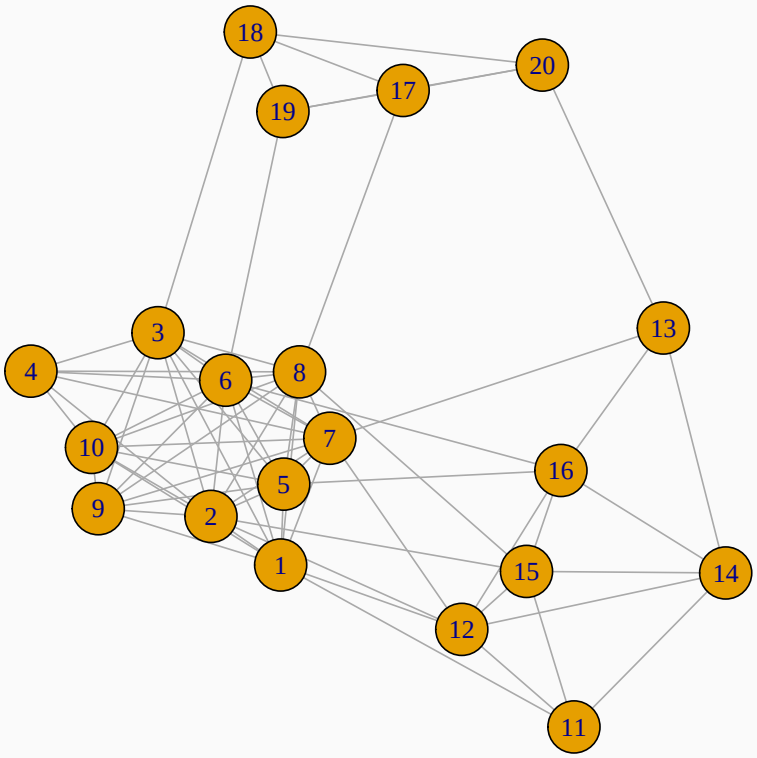

- Pour chaque nœud i, on place i dans la communauté de chacun de ses voisins j.
- Calcul du gain de modularité.
- On place i dans la communauté où le gain est maximum.

- Pour chaque nœud i, on place i dans la communauté de chacun de ses voisins j.
- Calcul du gain de modularité.
- On place i dans la communauté où le gain est maximum.

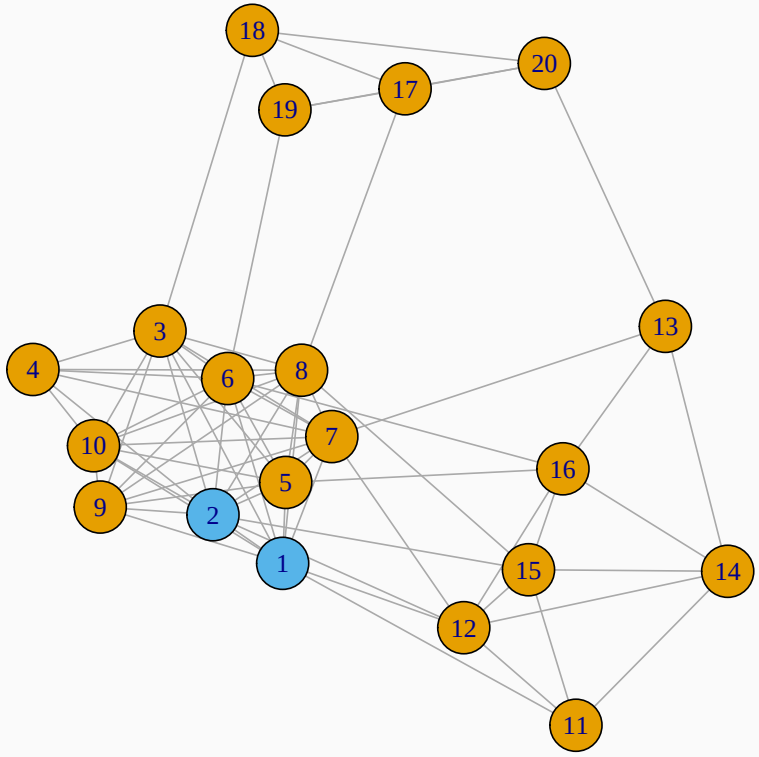

- Même procédé pour tous les nœuds suivants.

- Même procédé pour tous les nœuds suivants.

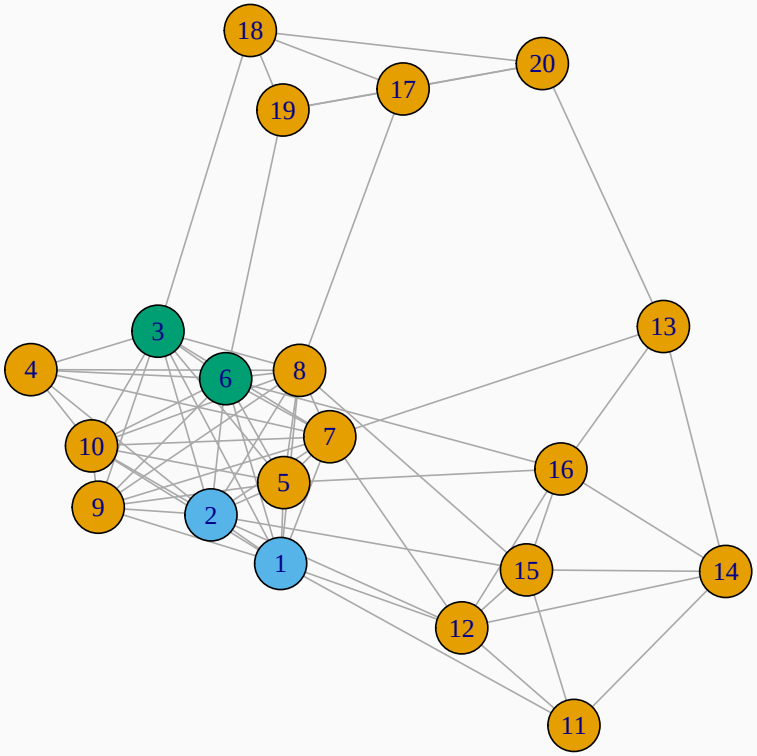

- Même procédé pour tous les nœuds suivants.

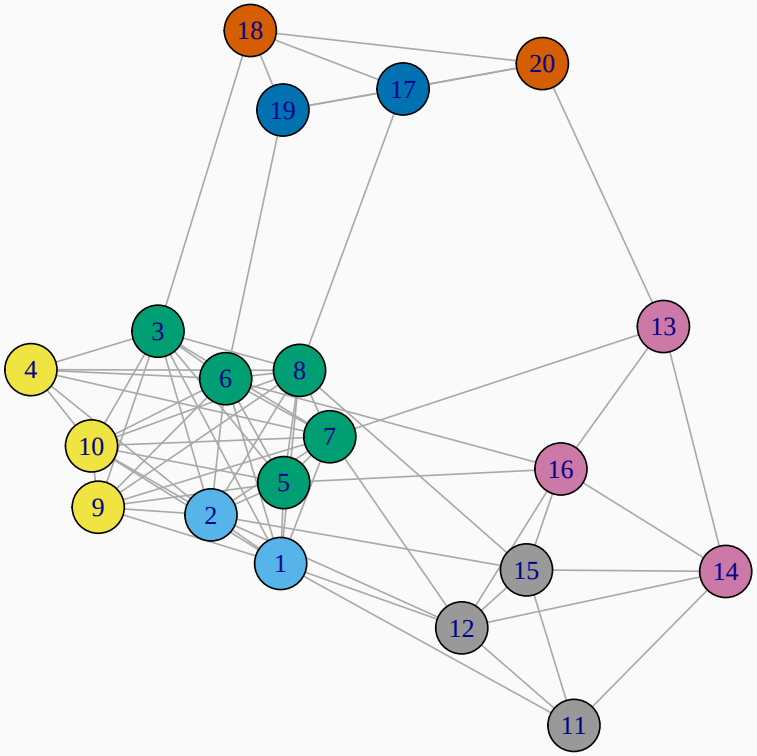

- Même procédé pour tous les nœuds suivants.

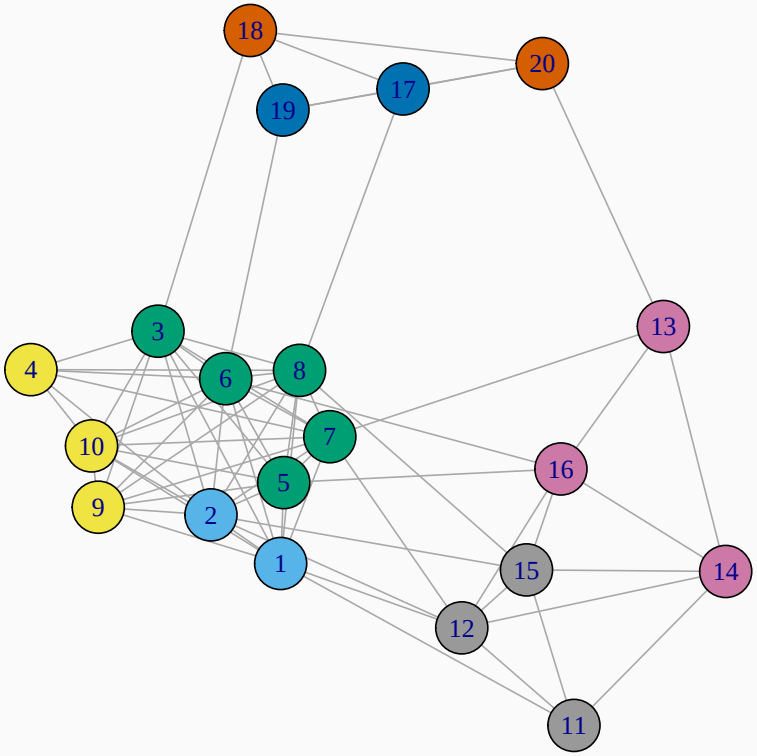

Fin de l'itération 1

Itération 2, ...

- L'itération 1 est répétée sur ce nouveau graphe...
- et ainsi de suite jusqu'à ce qu'il n'y ait plus d'amélioration.
- On obtient un maximum local de la modularité.

Itération 2, ...

- L'itération 1 est répétée sur ce nouveau graphe...
- et ainsi de suite jusqu'à ce qu'il n'y ait plus d'amélioration.
- On obtient un maximum local de la modularité.

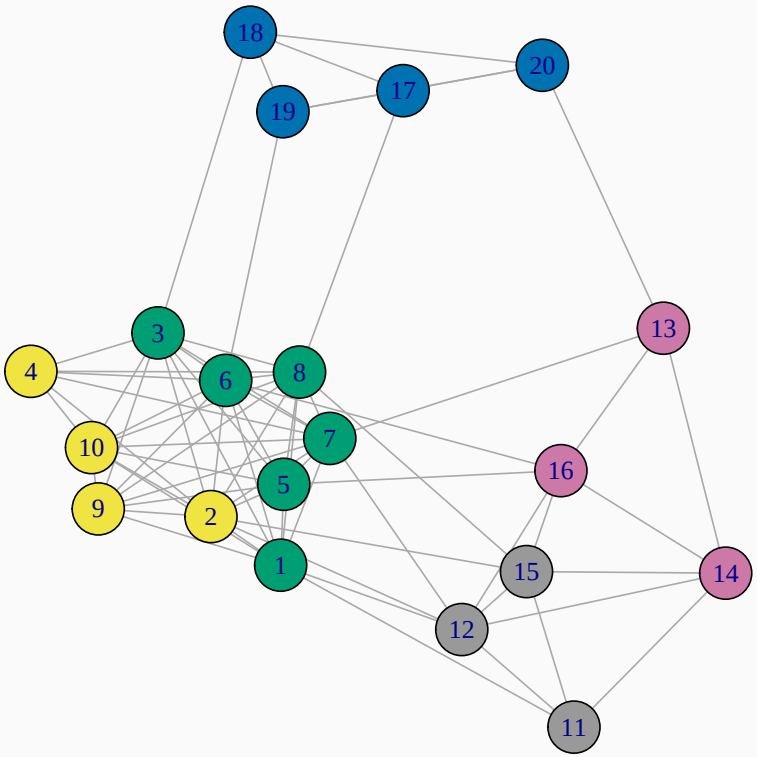

Fin de la phase 1

- A la fin de la phase 1, on obtient un graphe valué $G1 = (V1, E1)$

Fin de la phase 1

- A la fin de la phase 1, on obtient un graphe valué $G1 = (V1, E1)$
- muni de communautés $\mathcal{C}_1 = \{C_{1,1}, \ldots, C_{1,p_1}\}$.

Fin de la phase 1

- A la fin de la phase 1, on obtient un graphe valué $G1 = (V1, E1)$
- muni de communautés $\mathcal{C}_1 = \{C_{1,1}, \ldots, C_{1,p_1}\}$.

Sur l'exemple

On a 5 communautés.

Passe 1 - phase 2

Construction d'un nouveau graphe

- 1 nœud = 1 communauté.
- Arêtes valuées : le poids correspond au nombre de liens entre les nœuds de chaque communauté.

Passe 1 - phase 2

Construction d'un nouveau graphe

- 1 nœud = 1 communauté.
- Arêtes valuées : le poids correspond au nombre de liens entre les nœuds de chaque communauté.

- Ce nouveau graphe peut s'obtenir en calculant sa matrice d'adjacence.

Passe 1 - phase 2

Construction d'un nouveau graphe

- 1 nœud = 1 communauté.
- Arêtes valuées : le poids correspond au nombre de liens entre les nœuds de chaque communauté.

- Ce nouveau graphe peut s'obtenir en calculant sa matrice d'adjacence.
- Sur l'exemple, on a

```
> A
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    5    0    0    2   22
## [2,]    0    6    1    0    3
## [3,]    0    1    3    5    3
## [4,]    2    0    5    3    4
## [5,]   22    3    3    4   15
```

Obtention du nouveau graphe

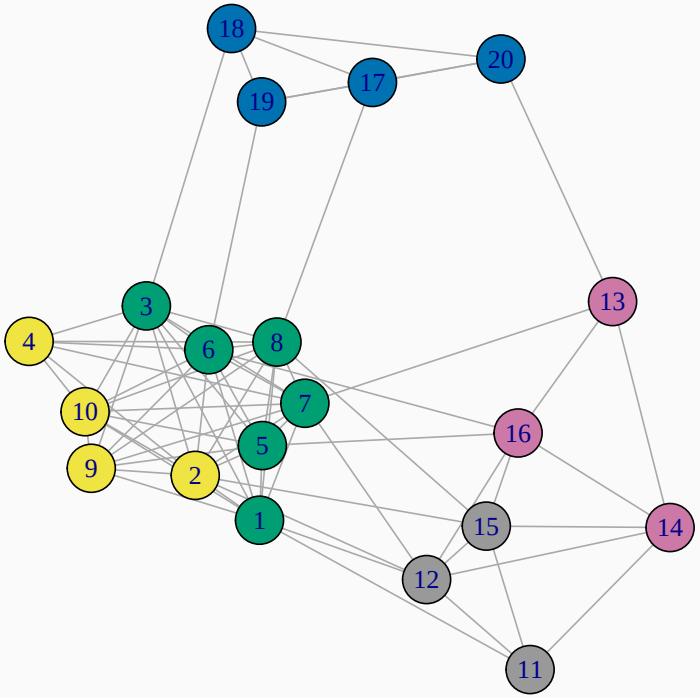

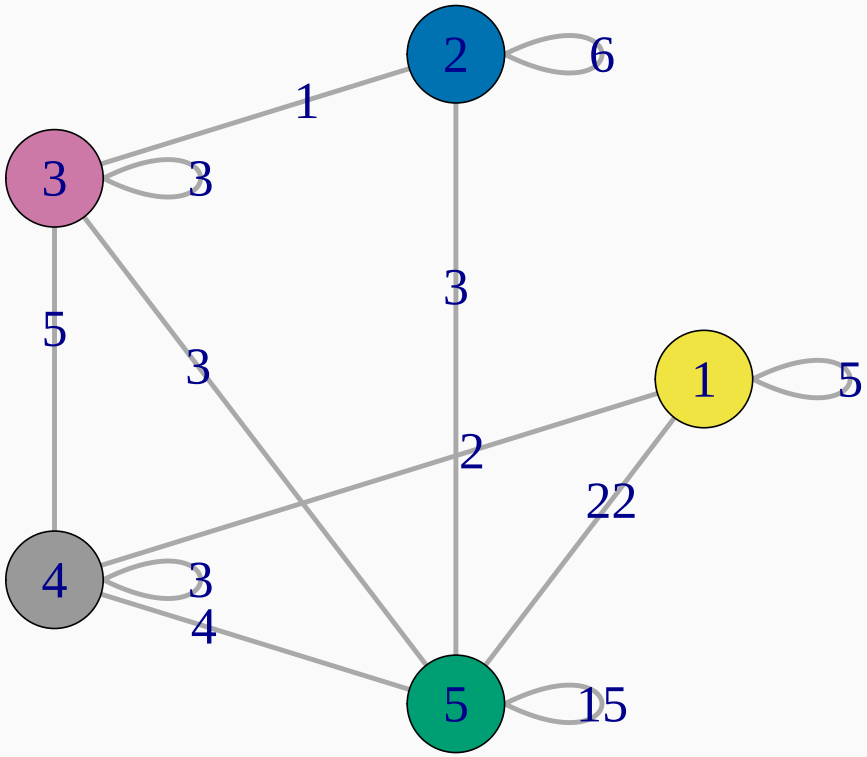

Obtention du nouveau graphe

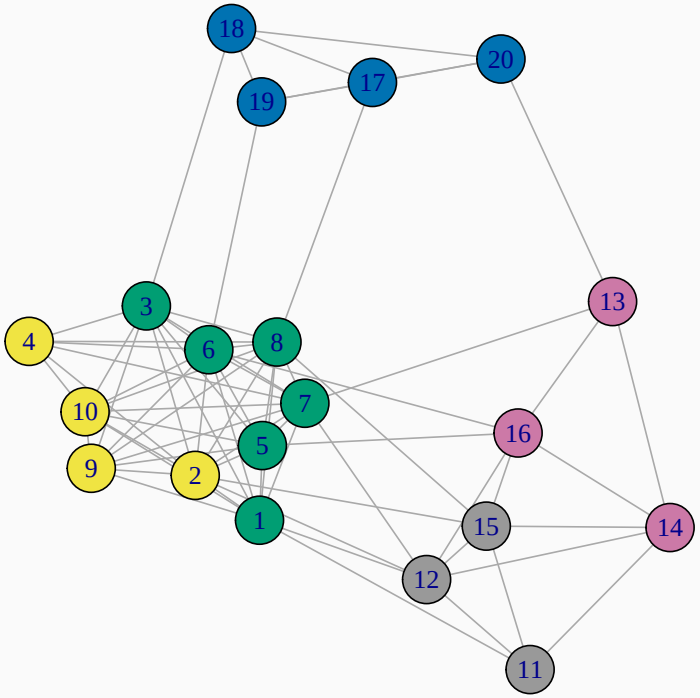

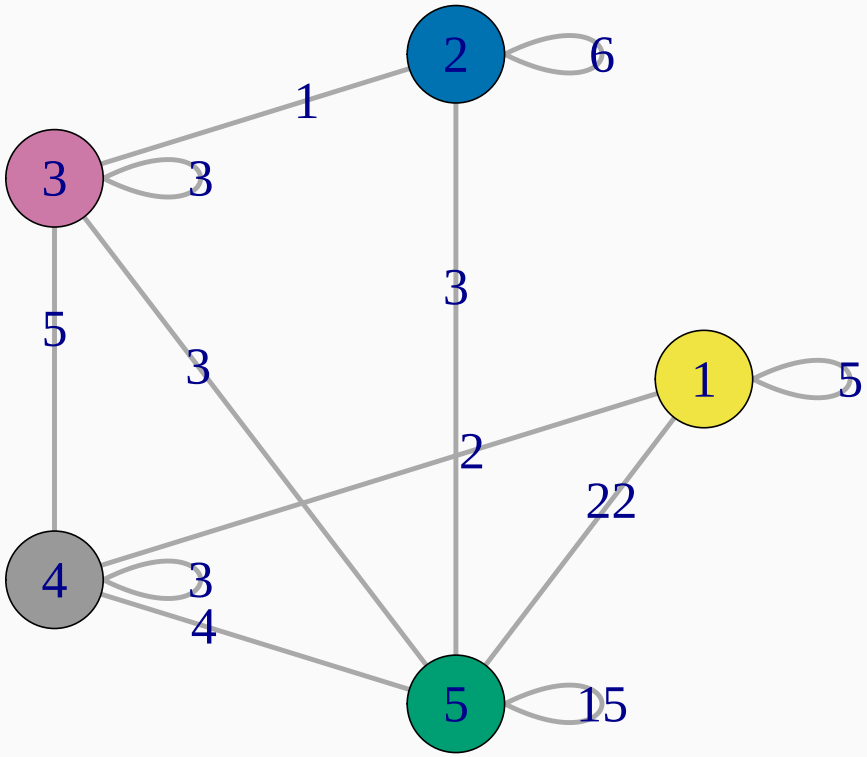

Fin de la phase 2 et de la passe 1

- La passe suivante consiste à ré-appliquer les deux phases au graphe obtenu en fin de pass1.

- La passe suivante consiste à ré-appliquer les deux phases au graphe obtenu en fin de pass1.
- Les passes sont répétées jusqu'à atteindre un maximum de modularité.

- La passe suivante consiste à ré-appliquer les deux phases au graphe obtenu en fin de pass1.
- Les passes sont répétées jusqu'à atteindre un maximum de modularité.
- Sur R, on utilise cluster_louvain.

```
> cl.louv <- cluster_louvain(g)
> V(g)$color <- cl.louv$membership
> plot(g)
```

Représentation des "communautés Louvain"

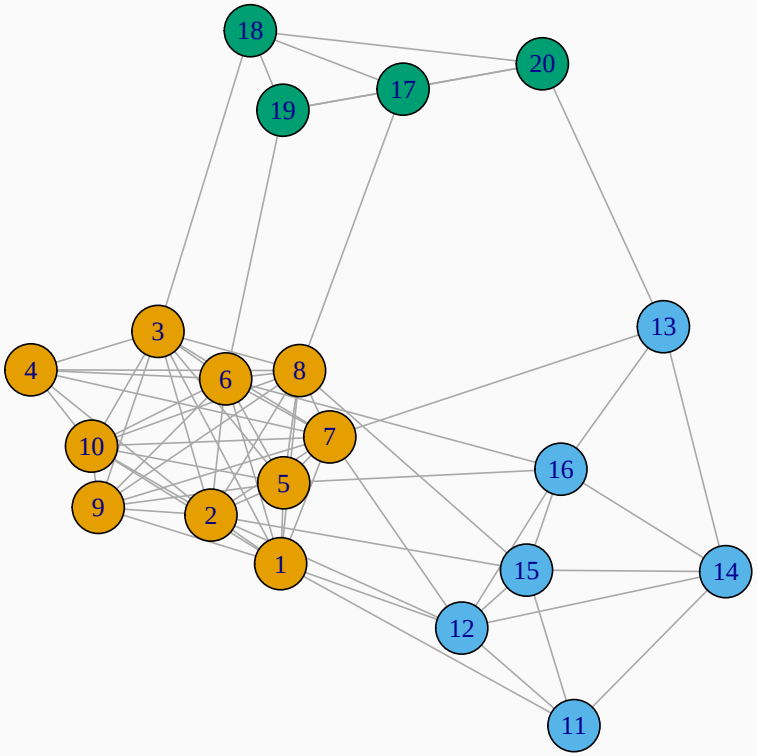

Quelques remarques

- Le nombre de communautés diminue à chaque passe.

Quelques remarques

- Le nombre de communautés diminue à chaque passe.
- Nombre de passes généralement faible (moins de 10).

Quelques remarques

- Le nombre de communautés diminue à chaque passe.
- Nombre de passes généralement faible (moins de 10).
- Nœuds numérotés au hasard au début de la première passe $\Longrightarrow$ algorithme aléatoire.

Quelques remarques

- Le nombre de communautés diminue à chaque passe.
- Nombre de passes généralement faible (moins de 10).
- Nœuds numérotés au hasard au début de la première passe $\Longrightarrow$ algorithme aléatoire.
- Il existe d'autres procédures itératives que l'algorithme de Louvain.

Autres méthodes

```
> cl1 <- cluster_edge_betweenness(g)
> cl2 <- fastgreedy.community(g)
> cl3 <- cluster_walktrap(g)
```

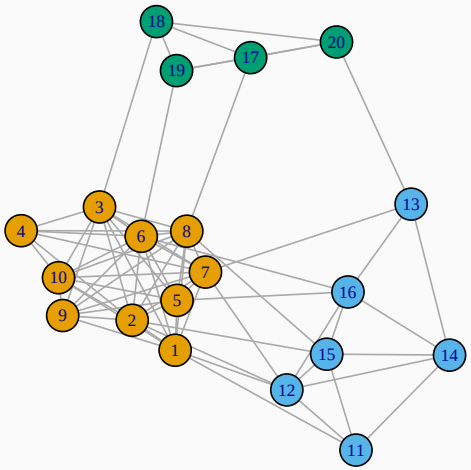

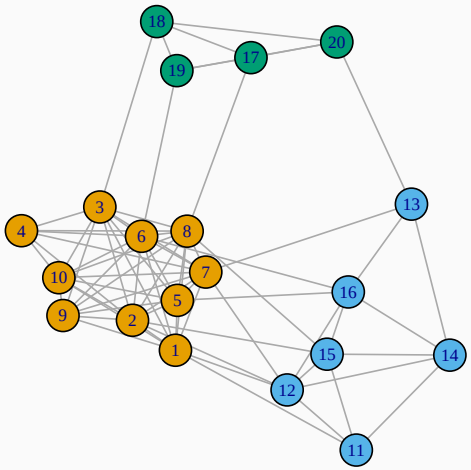

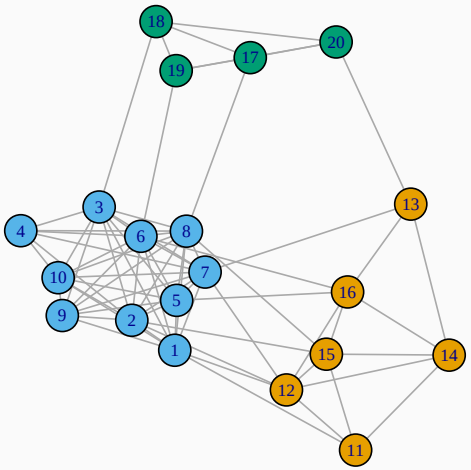

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

- Cadre identique : $G = (V, E)$ un graphe et on veut trouver une partition de V en clusters ou communautés.

- Cadre identique : $G = (V, E)$ un graphe et on veut trouver une partition de V en clusters ou communautés.
- Approche basée sur la décomposition spectrale du Laplacien du graphe.

- Cadre identique : $G = (V, E)$ un graphe et on veut trouver une partition de V en clusters ou communautés.
- Approche basée sur la décomposition spectrale du Laplacien du graphe.
- Approche utilisée dans un cadre plus large :
  - Problème : clustering sur un jeu de données standards $n \times p$;
  - L'approche peut être appliquée à une matrice de similarité.

- Cadre identique : $G = (V, E)$ un graphe et on veut trouver une partition de V en clusters ou communautés.
- Approche basée sur la décomposition spectrale du Laplacien du graphe.
- Approche utilisée dans un cadre plus large :
  - Problème : clustering sur un jeu de données standards $n \times p$;
  - L'approche peut être appliquée à une matrice de similarité.
- On pourra consulter [von Luxburg, 2017] dont cette partie est fortement inspirée.

Notations

- $G = (V, E)$ un graphe non dirigé valué avec $n = |V|$.
- $w_{ij} \geq 0$ poids de l'arête entre i et j et $W = (w_{ij})_{1 \leq i, i \leq n}$ la matrice d'adjacence.
- $d_i = \sum_{j \neq i} w_{ij}$ degré du nœud i et $D = \mathrm{diag}(d_i)_{1 \leq i \leq n}$ la matrice des degrés.

Notations

- $G = (V, E)$ un graphe non dirigé valué avec $n = |V|$.
- $w_{ij} \geq 0$ poids de l'arête entre i et j et $W = (w_{ij})_{1 \leq i, i \leq n}$ la matrice d'adjacence.
- $d_i = \sum_{j \neq i} w_{ij}$ degré du nœud i et $D = \mathrm{diag}(d_i)_{1 \leq i \leq n}$ la matrice des degrés.

Laplacien non normalisé

Le Laplacien non normalisé de G est la matrice $n \times n$ définie par :

$$L = D - W.$$

Quelques propriétés

Les deux propositions suivantes sont fondamentales pour l'algorithme de clustering spectral.

Proposition 1

1. Pour tout vecteur $f \in \mathbb{R}^n$ on a

$$f'Lf = \frac{1}{2} \sum_{1 \leq i,j \leq n} w_{ij}(f_i - f_j)^2.$$

2. L est symétrique et semi définie positive.

Quelques propriétés

Les deux propositions suivantes sont fondamentales pour l'algorithme de clustering spectral.

Proposition 1

1. Pour tout vecteur $f \in \mathbb{R}^n$ on a
$$f'Lf = \frac{1}{2} \sum_{1 \leq i,j \leq n} w_{ij}(f_i - f_j)^2.$$
2. L est symétrique et semi définie positive.
3. La plus petite valeur propre de L est 0, le vecteur propre correspondant est $\mathbf{1}_n$.
4. L a n valeurs propres non nulle $0 = \lambda_1 \leq \lambda_2 \leq \ldots \leq \lambda_n$.

Valeurs propre et nombre de compo. connexes

Proposition 2

Soit G un graphe non dirigé. Alors

1. le degrés de multiplicité k de la valeur propre 0 de L est égal au nombre de composantes connexes $A_1, \ldots, A_k$ dans G.

Valeurs propre et nombre de compo. connexes

Proposition 2

Soit G un graphe non dirigé. Alors

1. le degrés de multiplicité k de la valeur propre 0 de L est égal au nombre de composantes connexes $A_1, \ldots, A_k$ dans G.
2. l'espace propre associé à la valeur propre 0 est engendré par les vecteurs d'indicatrices $\mathbf{1}_{A_1}, \ldots, \mathbf{1}_{A_k}$.

Valeurs propre et nombre de compo. connexes

Proposition 2

Soit G un graphe non dirigé. Alors

1. le degrés de multiplicité k de la valeur propre 0 de L est égal au nombre de composantes connexes $A_1, \ldots, A_k$ dans G.
2. l'espace propre associé à la valeur propre 0 est engendré par les vecteurs d'indicatrices $\mathbf{1}_{A_1}, \ldots, \mathbf{1}_{A_k}$.

Conséquence importante

Le spectre de L permet d'identifier les composantes connexes de G..

- En pratique : 1 communauté n'est pas forcément égale à une composante connexe.
- On peut par exemple vouloir extraire des communautés dans un graphe à une composante connexe.

- En pratique : 1 communauté n'est pas forcément égale à une composante connexe.
- On peut par exemple vouloir extraire des communautés dans un graphe à une composante connexe.

Idée

Considérer les k plus petites valeurs propres du Laplacien.

Spectral clustering non normalisé

Algorithme

Entrées : un graphe non dirigé G, k le nombre de clusters.

1. Calculer le Laplacien non normalisé L de G.

Spectral clustering non normalisé

Algorithme

Entrées : un graphe non dirigé G, k le nombre de clusters.

1. Calculer le Laplacien non normalisé L de G.
2. Calculer les k premiers vecteurs propres $u_1, \ldots, u_k$ de G.
3. On note U la matrice $n \times k$ qui contient les u_k et y_i la i^{e} ligne de U.

Spectral clustering non normalisé

Algorithme

Entrées : un graphe non dirigé G, k le nombre de clusters.

1. Calculer le Laplacien non normalisé L de G.
2. Calculer les k premiers vecteurs propres $u_1, \ldots, u_k$ de G.
3. On note U la matrice $n \times k$ qui contient les u_k et y_i la i^{e} ligne de U.
4. Faire un k-means avec les points $y_i, i = 1, \ldots, n \Longrightarrow A_1, \ldots, A_k$.

Sortie : clusters $C_1, \ldots, C_k$ avec

$$C_j = \{i | y_i \in A_j\}.$$

Remarque

- Si G ne possède pas k composantes connexes alors U n'est pas composé que de 1 et de 0.
- On ne peut donc pas extraire directement les composantes à cette étape.

Remarque

- Si G ne possède pas k composantes connexes alors U n'est pas composé que de 1 et de 0.
- On ne peut donc pas extraire directement les composantes à cette étape.
- Mais

Remarque

- Si G ne possède pas k composantes connexes alors U n'est pas composé que de 1 et de 0.
- On ne peut donc pas extraire directement les composantes à cette étape.
- Mais si il existe (presque) k composantes, alors les $y_i \in \mathbb{R}^k$ risquent de se rapprocher de cette configuration 0-1.

Remarque

- Si G ne possède pas k composantes connexes alors U n'est pas composé que de 1 et de 0.
- On ne peut donc pas extraire directement les composantes à cette étape.
- Mais si il existe (presque) k composantes, alors les $y_i \in \mathbb{R}^k$ risquent de se rapprocher de cette configuration 0-1.
- C'est pourquoi on fait un k-means en 4.

- Il existe plusieurs versions d'algorithme de clustering spectral.
- Les plus utilisées s'appliquent à une version normalisée du Laplacien, par exemple :

$$L_{\text{norm}} = I - D^{-1/2} W D^{-1/2}.$$

- Les propriétés de L_{norm} sont proches de celles de L. On a par exemple la propriété suivante.

- Il existe plusieurs versions d'algorithme de clustering spectral.
- Les plus utilisées s'appliquent à une version normalisée du Laplacien, par exemple :

$$L_{\text{norm}} = I - D^{-1/2} W D^{-1/2}.$$

- Les propriétés de L_{norm} sont proches de celles de L. On a par exemple la propriété suivante.

Proposition 3

Soit G un graphe non dirigé. Alors

1. le degrés de multiplicité k de la valeur propre 0 de L_{norm} est égal au nombre de composantes connexes $A_1, \ldots, A_k$ dans G.

- Il existe plusieurs versions d'algorithme de clustering spectral.
- Les plus utilisées s'appliquent à une version normalisée du Laplacien, par exemple :

$$L_{\text{norm}} = I - D^{-1/2} W D^{-1/2}.$$

- Les propriétés de L_{norm} sont proches de celles de L. On a par exemple la propriété suivante.

Proposition 3

Soit G un graphe non dirigé. Alors

1. le degrés de multiplicité k de la valeur propre 0 de L_{norm} est égal au nombre de composantes connexes $A_1, \ldots, A_k$ dans G.
2. l'espace propre associé à la valeur propre 0 est engendré par les vecteurs d'indicatrices $D^{1/2}\mathbf{1}_{A_1}, \ldots, D^{1/2}\mathbf{1}_{A_k}$.

Clustering spectral normalisé

- On déduit de cette propriété la version la plus courante de clustering spectral du à [Ng et al., 2002].

Algorithme

Entrées : un graphe non dirigé G, k le nombre de clusters.

1. Calculer le Laplacien normalisé L_{norm} de G.

Clustering spectral normalisé

- On déduit de cette propriété la version la plus courante de clustering spectral du à [Ng et al., 2002].

Algorithme

Entrées : un graphe non dirigé G, k le nombre de clusters.

1. Calculer le Laplacien normalisé L_{norm} de G.
2. Calculer les k premiers vecteurs propres $u_1, \ldots, u_k$ de G. On note U la matrice $n \times k$ qui les contient.
3. Calculer T en normalisant les lignes de U : $t_{ij} = u_{ij}/(\sum_\ell u_{i\ell}^2)^{1/2}$.

Clustering spectral normalisé

- On déduit de cette propriété la version la plus courante de clustering spectral du à [Ng et al., 2002].

Algorithme

Entrées : un graphe non dirigé G, k le nombre de clusters.

1. Calculer le Laplacien normalisé L_{norm} de G.
2. Calculer les k premiers vecteurs propres $u_1, \ldots, u_k$ de G. On note U la matrice $n \times k$ qui les contient.
3. Calculer T en normalisant les lignes de U : $t_{ij} = u_{ij}/(\sum_\ell u_{i\ell}^2)^{1/2}$.
4. Faire un k-means avec les points $y_i, i = 1, \ldots, n$ (i^{e} ligne de T) $\Longrightarrow$ $A_1, \ldots, A_k$.

Sortie : clusters $C_1, \ldots, C_k$ avec

$$C_j = \{i | y_i \in A_j\}.$$

Remarques

- Algorithme quasi similaire au clustering spectral non normalisé.
- Une étape de normalisation en plus.
- Cette étape se justifie par la théorie de la perturbation du spectre d'une matrice.
- On pourra consulter [von Luxburg, 2017] pour des justifications.

Choix de k

- Comme souvent en clustering, cet algorithme nécessite de connaître le nombre de groupes.

Choix de k

- Comme souvent en clustering, cet algorithme nécessite de connaître le nombre de groupes.
- Utilisation de connaissances métier pour ce choix
- ou

Choix de k

- Comme souvent en clustering, cet algorithme nécessite de connaître le nombre de groupes.
- Utilisation de connaissances métier pour ce choix
- ou étude des valeurs propres du Laplacien.

Généralisation

Remarque importante

- L'algorithme n'utilise pas nécessairement la structure du graphe.

Généralisation

Remarque importante

- L'algorithme n'utilise pas nécessairement la structure du graphe.
- Il est entièrement basé sur la matrice (d'adjacence) W des poids qui contient des arêtes.

Généralisation

Remarque importante

- L'algorithme n'utilise pas nécessairement la structure du graphe.
- Il est entièrement basé sur la matrice (d'adjacence) W des poids qui contient des arêtes.
- Cette matrice peut également être vue comme une matrice de similarité.

Généralisation

Remarque importante

- L'algorithme n'utilise pas nécessairement la structure du graphe.
- Il est entièrement basé sur la matrice (d'adjacence) W des poids qui contient des arêtes.
- Cette matrice peut également être vue comme une matrice de similarité.

Conséquence

- On peut donc généraliser cet algorithme à n'importe quel problème où on possède une matrice de similarité.
- Exemple : problème de clustering standard sur des données $n \times p$ (il "suffit" de construire une marice de similarité).

Clustering spectral sur un tableau de données

- Données : tableau $n \times p$ n individus, p variables.
- Problème : classification non supervisée des n individus.

Clustering spectral sur un tableau de données

- Données : tableau $n \times p$ n individus, p variables.
- Problème : classification non supervisée des n individus.
- Méthodes classiques : k-means, CAH...

Clustering spectral sur un tableau de données

- Données : tableau $n \times p$ n individus, p variables.
- Problème : classification non supervisée des n individus.
- Méthodes classiques : k-means, CAH...

Alternative : clustering spectral

1. construire un graphe de similarité ;
2. lancer l'algorithme de clustering spectral sur ce graphe (ou plutôt sur sa matrice de similarité.

Construction du graphe de similarités

- On peut utiliser les techniques vues dans la section 4 : ε-neighborhood graph ou plus proches voisins (mutuels ou non).

Construction du graphe de similarités

- On peut utiliser les techniques vues dans la section 4 : ε-neighborhood graph ou plus proches voisins (mutuels ou non).
- De façon plus générale, la matrice de similarités s'obtient souvent à partir d'un noyau K :

$$\begin{aligned} K : \mathbb{R}^p \times \mathbb{R}^p &\to \mathbb{R} \\ (x, y) &\mapsto \langle \Phi(x), \Phi(y) \rangle_{\mathcal{H}} \end{aligned}$$

où $\Phi : \mathbb{R}^p \to \mathcal{H}$ est une fonction qui plonge les observations dans un espace de Hilbert $\mathcal{H}$ appelé feature space.

Exemples de noyau

- Linéaire (vanilladot) : $K(x, y) = \langle x, y \rangle$.
- Gaussien (rfbdot) : $K(x, y) = \exp(-\sigma \|x - y\|^2)$.
- Polynomial (polydot) : $K(x, y) = (\text{scale}\langle x, y \rangle + \text{offset})^{\text{degree}}$.
- ...

Exemples de noyau

- Linéaire (vanilladot) : $K(x, y) = \langle x, y \rangle$.
- Gaussien (rfbdot) : $K(x, y) = \exp(-\sigma \|x - y\|^2)$.
- Polynomial (polydot) : $K(x, y) = (\text{scale}\langle x, y \rangle + \text{offset})^{\text{degree}}$.
- ...

Références

On pourra trouver dans exemples de noyau dans [Karatzoglou et al., 2004].

Matrice de similarités avec un noyau

- Etant données n observations $x_i \in \mathbb{R}^p$ et un noyau K
- on peut construire une matrice de similarité, par exemple pour un noyau Gaussien :

$$w_{ij} = \begin{cases} \exp(-\sigma \|x_i - x_j\|^2) & \text{si } i \neq j \\ 0 & \text{sinon.} \end{cases}$$

Matrice de similarités avec un noyau

- Etant données n observations $x_i \in \mathbb{R}^p$ et un noyau K
- on peut construire une matrice de similarité, par exemple pour un noyau Gaussien :

$$w_{ij} = \begin{cases} \exp(-\sigma \|x_i - x_j\|^2) & \text{si } i \neq j \\ 0 & \text{sinon.} \end{cases}$$

Clustering spectral

Le clustering spectral consiste à appliquer l'algorithme vu précédemment en calculant le Laplacien normalisé à partir de cette matrice de similarités (voir [Ng et al., 2002, Arias-Castro, 2011]).

Clustering spectral sur des données $n \times p$

Algorithme

Entrées : tableau de données $n \times p$, K un noyau, k le nombre de clusters.

1. Calculer la matrice de similarités W sur les données avec le noyau K.
2. Calculer le Laplacien normalisé L_{norm} à partir de W.

Clustering spectral sur des données $n \times p$

Algorithme

Entrées : tableau de données $n \times p$, K un noyau, k le nombre de clusters.

1. Calculer la matrice de similarités W sur les données avec le noyau K.
2. Calculer le Laplacien normalisé L_{norm} à partir de W.
3. Calculer les k premiers vecteurs propres $u_1, \ldots, u_k$ de G. On note U la matrice $n \times k$ qui les contient.
4. Calculer T en normalisant les lignes de U : $t_{ij} = u_{ij}/(\sum_\ell u_{i\ell}^2)^{1/2}$.
5. Faire un k-means avec les points $y_i, i = 1, \ldots, n$ (i^{e} ligne de T) $\Longrightarrow$ $A_1, \ldots, A_k$.

Sortie : clusters $C_1, \ldots, C_k$ avec

$$C_j = \{i | y_i \in A_j\}.$$

Le coin R

- La fonction specc du package kernlab permet de faire le clustering spectral.

Le coin R

- La fonction specc du package kernlab permet de faire le clustering spectral.
- Exemple : données spirals

```
> library(kernlab)
> data(spirals)
> spirals1 <- data.frame(spirals)
> head(spirals1)
##           X1          X2
## 1  0.8123568 -0.98712687
## 2 -0.2675890 -0.32552004
## 3  0.3739746 -0.01293652
## 4  0.2576481  0.04130805
## 5 -0.8472613  0.32939461
## 6  0.4097649  0.03205686
```

Visualisation du nuage de points

```
> ggplot(spirals1)+aes(x=X1,y=X2)+geom_point()+theme_classic()
```

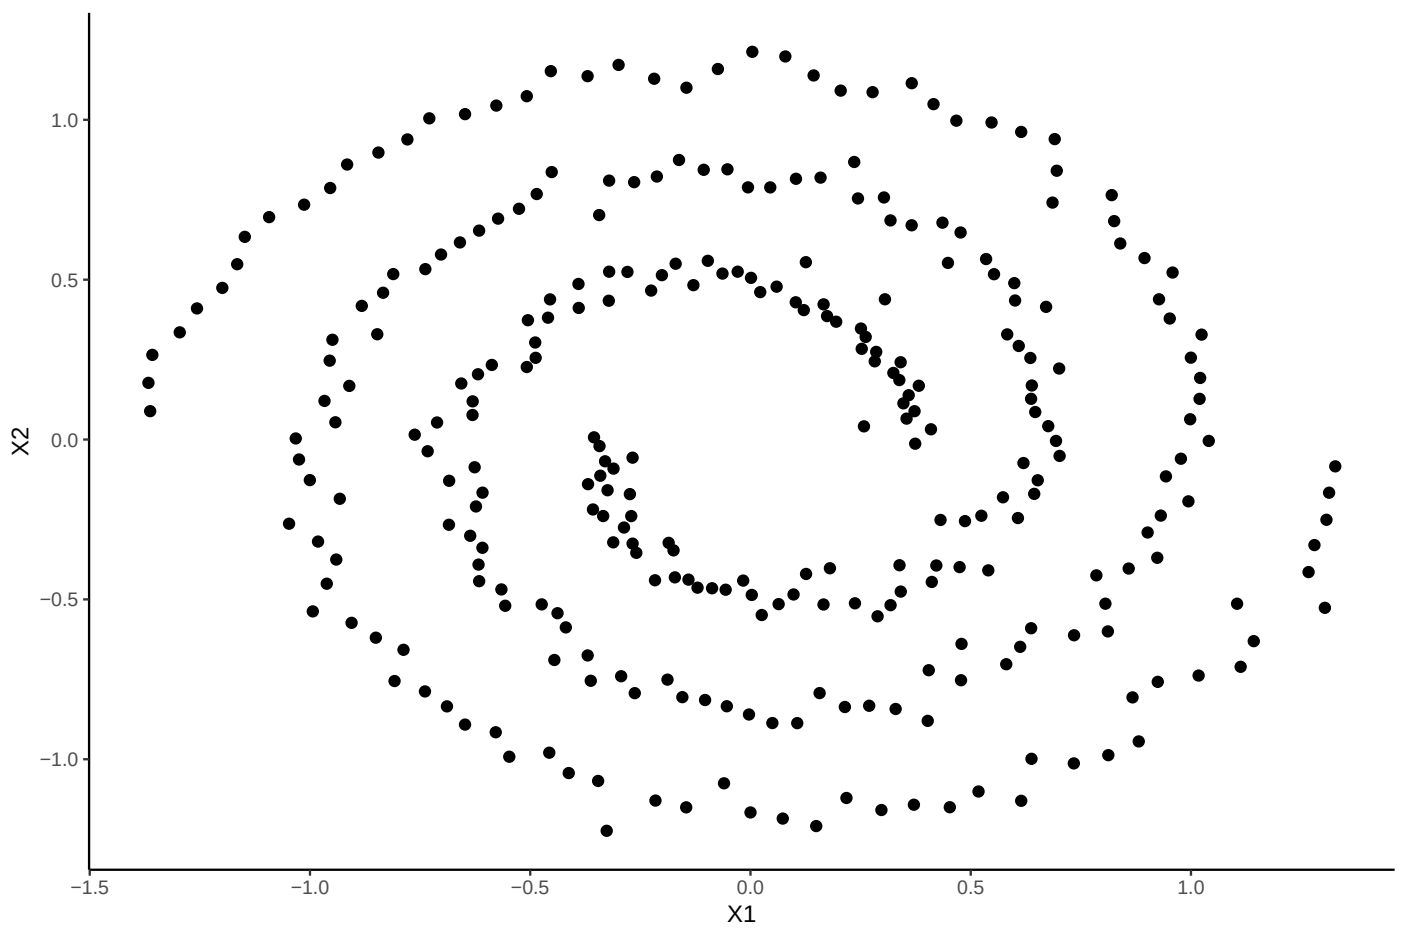

Le clustering spectral

```
> groupe <- specc(spirals,centers=2,kernel="rbfdot")
> head(groupe)
## [1] 2 2 1 1 2 1
> spirals1 <- spirals1 %>% mutate(groupe=as.factor(groupe))
> ggplot(spirals1)+aes(x=X1,y=X2,color=groupe)+geom_point(size=2)+theme_classic()
```

Le clustering spectral

```
> groupe <- specc(spirals,centers=2,kernel="rbfdot")
> head(groupe)
## [1] 2 2 1 1 2 1
> spirals1 <- spirals1 %>% mutate(groupe=as.factor(groupe))
> ggplot(spirals1)+aes(x=X1,y=X2,color=groupe)+geom_point(size=2)+theme_classic()
```

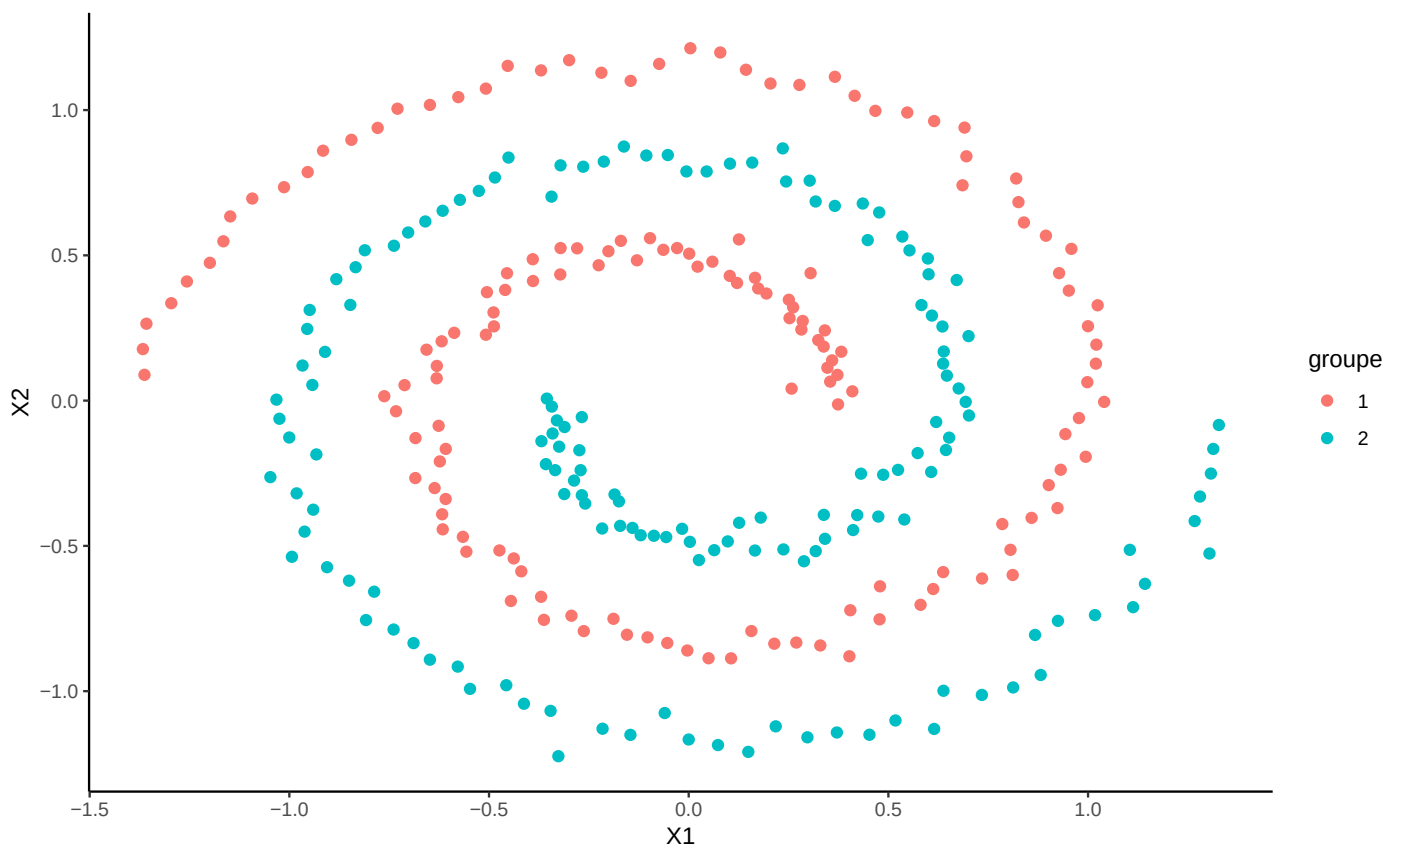

Introduction
Définitions - vocabulaire sur les graphes
Statistiques descriptives sur les graphes
Caractéristiques générales
Importance des nœuds
Modèles et construction de graphes
Quelques modèles de graphes
Construire un graphe
Détection de communautés
L'edge betweeness
La modularité
Clustering spectral
Bibliographie

Arias-Castro, E. (2011).
Clustering based on pairwise distances when the data is of mixed dimensions.
IEEE Transaction on Information Theory, 57(3) :1692–1706.

Bahoken, F., Beauguitte, L., and Lhomme, S. (2013).
La visualisation des réseaux. Principes, enjeux et perspectives.
halshs-00839905.

Blondel, V. D., Guillaume, J., Lambiotte, R., and Lefebvre, E. (2008).
Fast unfolding of communities in large networks.
Journal of Statistical Mechanics : Theory and Experiment.

Daudin, J.-J., Picard, F., and Robin, S. (2008).
A mixture model for random graphs.
Statistics and computing, 18 :173–183.

Fortunato, S. (2010).
Community detection in graphs.
Physics report, 486 :75–174.

Girvan, M. and Newman, M. E. J. (2002).
Community structure in social and biological networks.
Proc. Natl. Acad. Sci., pages 7821–7826.

Karatzoglou, A., Hornik, K., Smola, A., and Zeileis, A. (2004).
kernlab – an s4 package for kernel methods in r.
Journal of Statitstical Software, 11(9).

Ng, A., Jordan, M., and Weiss, Y. (2002).
On spectral clustering analysis.
In *Advances in Neural Information Processing Systems (NIPS)*,, volume 14, pages 849–856.

von Luxburg, U. (2017).
A tutorial on spectral clustering.
Statistics and computing, 17 :395–416.