Statistique en grande dimension - partie non supervisée

Laurent Rouvière

9 novembre 2022

Table des matières

1 Partitionnement : les k-means **3**

2 Méthodes hiérarchiques **8**

2.1 La Classification Ascendante Hiérarchique 12

2.2 Mesures de dissemblances 12

2.3 Compléments 19

3 Références **20**

Présentation

Définition

Action de *répartir en classes*, en catégories, des choses, des objets, ayant des caractères communs afin notamment d'en faciliter l'étude.

Nombreuses applications

- Astronomie : classification d'étoiles
- Médecine : diagnostic de maladies à partir d'observation cliniques
- Géographie : délimitation de zones homogènes
- Marketing : détermination de segments de marchés (groupes de consommateurs ayant les mêmes habitudes)

- Réseaux sociaux : extraction de communautés
- ...

Documents/supports

MOOC de François Husson

- disponible ici https://husson.github.io/MOOC_AnaDo/classif.html
- vidéos - Quiz - Supports

Objectifs divers

- Beaucoup de groupes avec peu d'individus à l'intérieur (réduire n)
- Peu de groupes avec beaucoup d'individus à l'intérieur (extraire des profils que l'on interprète par la suite).

Conséquence

Les algorithmes seront proches mais pas calibrés de la même façon.

Modélisation statistique

- n observations $x_1, \ldots, x_n$ à valeurs dans $\mathbb{R}^d$.

Le problème

Trouver une partition de $\{x_1, \ldots, x_n\}$: on cherche donc $\mathcal{C}_1, \ldots, \mathcal{C}_K$ tels que

$$\bigcup_{k=1}^{K} \mathcal{C}_k = \{x_1, \ldots, x_n\} \quad \text{et} \quad \mathcal{C}_k \cap \mathcal{C}_{k'} = \emptyset \quad \text{si} \quad k \neq k'.$$

Chaque élément de la partition $\mathcal{C}_k$ est appelé cluster.

- Notions de ressemblance, *similarité*, *hiérarchie*.
- Choix du *nombre de classes* K.

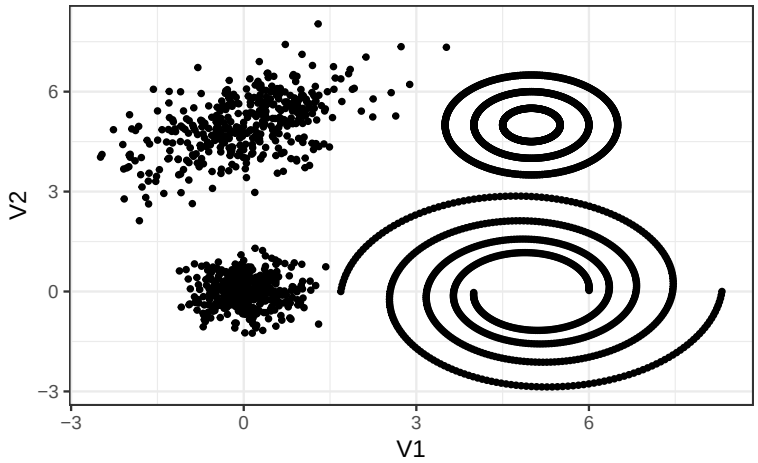

Un exemple jouet

4 types d'algorithmes

1. Méthodes de *partitionnement* (k-means)
2. Méthodes *hiérarchiques* (CAH)
3. Algorithmes basés sur les *densités* (DBSCAN)
4. Approches basées sur les *graphes* (clustering spectral)

1 Partitionnement : les k-means

Le critère des k-means

- *Idée* : Définir les clusters $\mathcal{C}_k$ à partir de représentants c_k.
- Nombre de groupes K *fixé*.

Le critère des k-means

On cherche la partition $\mathcal{C}$ et les représentants c qui minimise le critère

$$g(\mathcal{C}, c) = \sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} \|x_i - c_k\|^2.$$

- **Impossible** de trouver $(\mathcal{C}^\star, c^\star)$ qui minimise $g(\mathcal{C}, c)$.

Équivalences, (Bock 2008)

1. Quand on *fixe une partition* $\mathcal{C}^*$, les meilleurs représentants sont les moyennes $\widehat{c} = (\bar{x}_{\mathcal{C}_1}, \ldots, \bar{x}_{\mathcal{C}_K})$

$$\forall c \quad g(\mathcal{C}^*, c) \geq g(\mathcal{C}^*, \widehat{c})$$

2. Quand on *fixe des représentants* c, la meilleure partition $\widehat{\mathcal{C}} = \{\widehat{\mathcal{C}}_1, \ldots, \widehat{\mathcal{C}}_K\}$ est celle de la distance minimale (partition de Voronoi) définie par

$$\widehat{\mathcal{C}}_k = \{i \in \{1, \ldots, n\} \text{ tels que } \|x_i - c_k\|^2 = \min_j \|x_i - c_j\|^2\}$$

Elle réalise le minimum à représentants fixés:

$$\forall \mathcal{C} \quad g(\mathcal{C}, c) \geq g(\widehat{\mathcal{C}}, c)$$

Idée

Construire les centres et la partition de manière *récursive*.

Comment ?

En utilisant un algorithme :

- Lloyd (1982)
- Forgy (1965)
- MacQueen (1967)
- Hartigan et Wong (1979)

on pourra consulter https://towardsdatascience.com/three-versions-of-k-means-cf939b65f4ea.

Lloyd (1982)

1. **Initialisation** : choix de k points au hasard comme centroïde.
2. **Affectation** de chaque observation au centroïde le plus proche.
3. **Mise à jour** des centroïdes.

Exemple

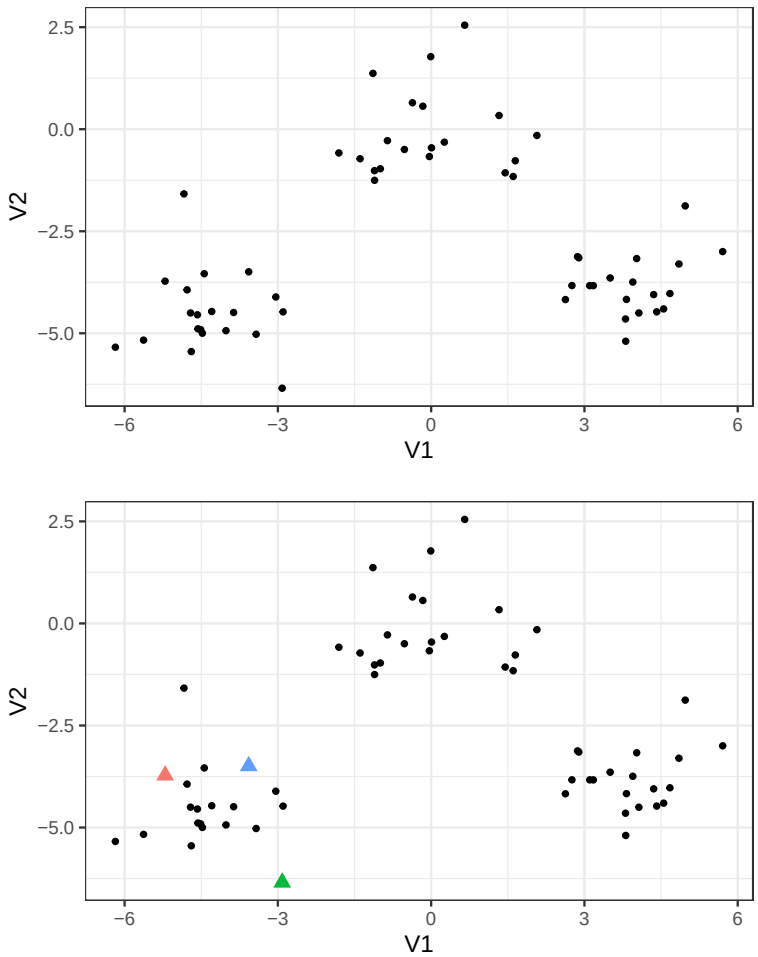

Hartigan et Wong (1979)

1. **Initialisation** : choix de K points au hasard comme centroïde

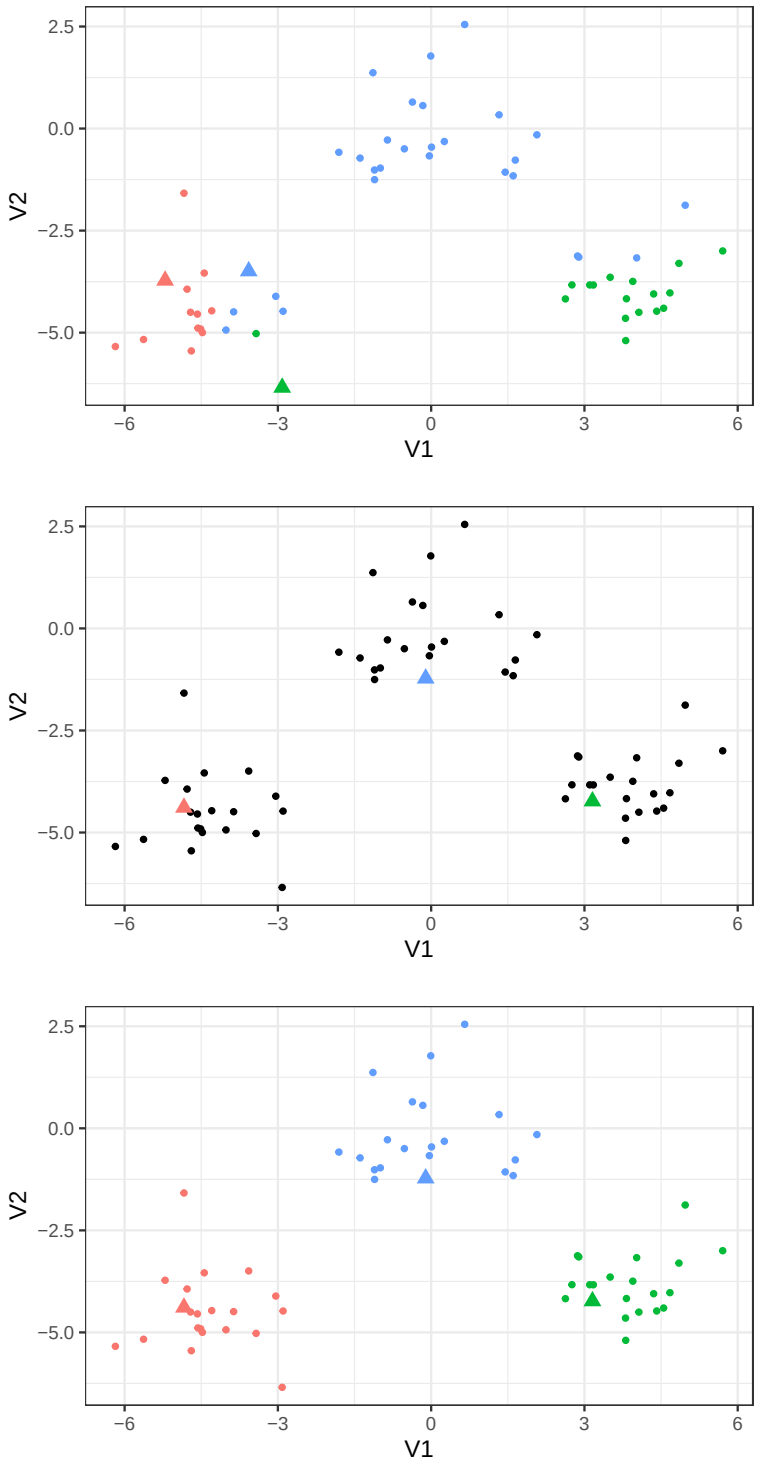
2.5
0.0
−2.5
−5.0
V2
−6
−3
0
3
6
V1
2.5
0.0
−2.5
−5.0
V2
−6
−3
0
3
6
V1
2.5
0.0
−2.5
−5.0
V2
−6
−3
0
3
6
V1

2. Pour $i = 1, \ldots, n$
   a. Pour $k = 1, \ldots, K$
      - Affecter x_i à c_k
      - calculer $\alpha_k = \sum_{i=1}^{n} \|x_i - c_{k,i}\|^2$
   b. Affecter x_i au centroïde qui minimise α_k
   c. Mettre à jour les centroïdes
3. Répéter 2 jusqu'à convergence

Remarque

Généralement recommandé avec *plusieurs initialisations*.

Le coin R

```
> res <- kmeans(tbl[,2:3],centers = 3,
+               algorithm = "Hartigan-Wong",nstart=100)
> centres <- res$centers |> as_tibble() |> mutate(groupes=as.factor(1:3))
> tbl |> mutate(groupes=as.factor(res$cluster)) |> ggplot()+
+   aes(x=V1,y=V2,color=groupes)+geom_point() +
+   geom_point(data=centres,shape=17,size=2)
```

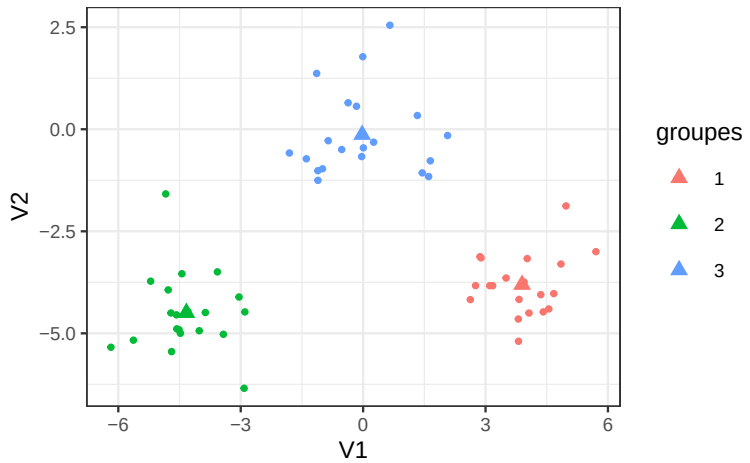

Bilan

Avantages

- Facile à mettre en œuvre
- Faible complexité $O(n)$

Inconvénients

- Clusters “sphériques”.
- Choix de k.
- Choix de la distance (grande dimension ?).

2 Méthodes hiérarchiques

Objectif

Créer une suite de partitions emboitées en partant de la partition la plus fine (n classes) jusqu'à obtenir une seule classe.

Le processus hiérarchique

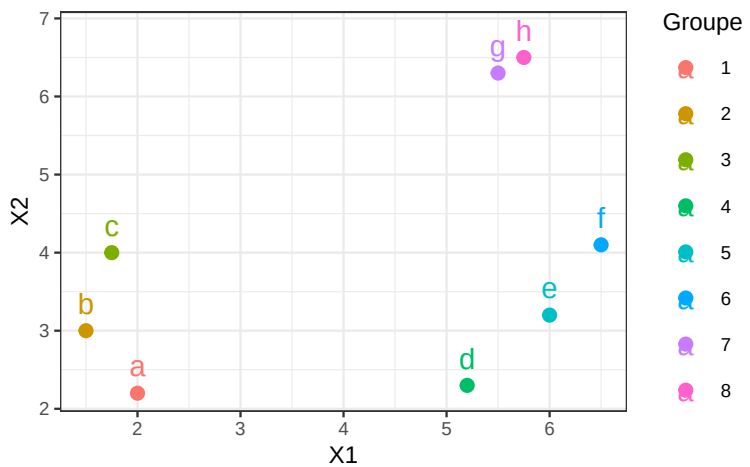

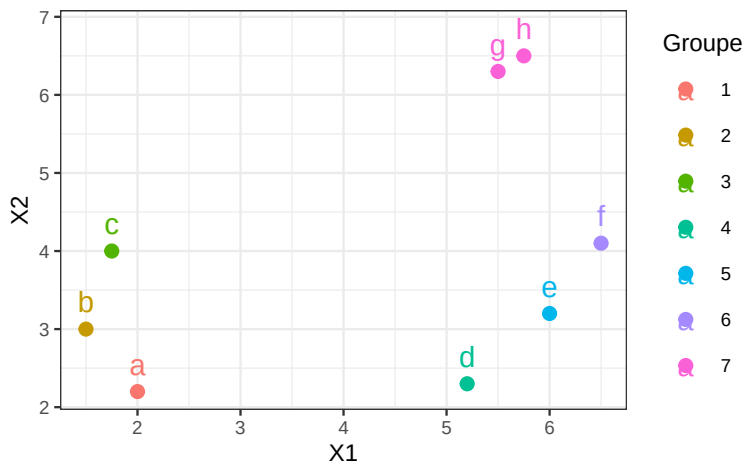
X2
X1
Groupe
1
2
3
4
5
6
7
a
b
c
d
e
f
g
h

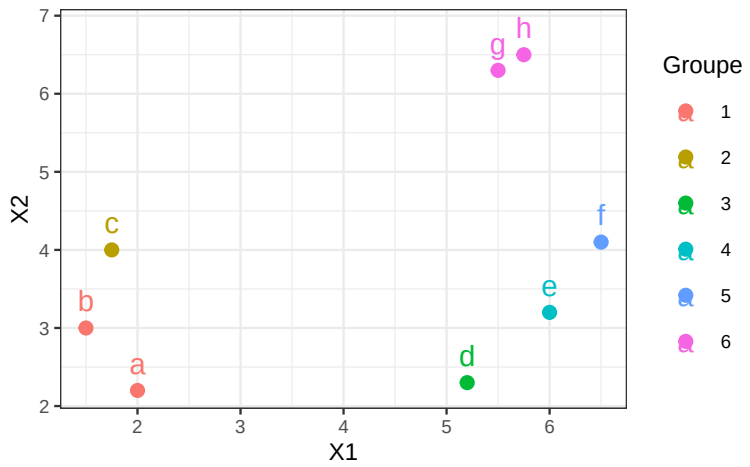
X2
X1
Groupe
1
2
3
4
5
6
a
b
c
d
e
f
g
h

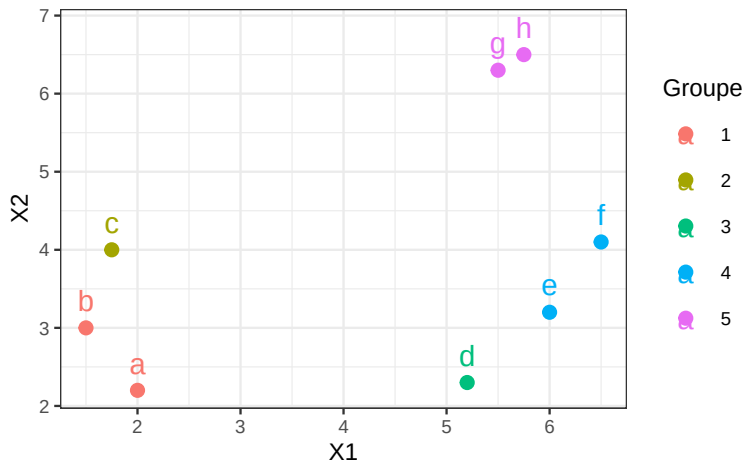
X2
X1
Groupe
1
2
3
4
5
a
b
c
d
e
f
g
h

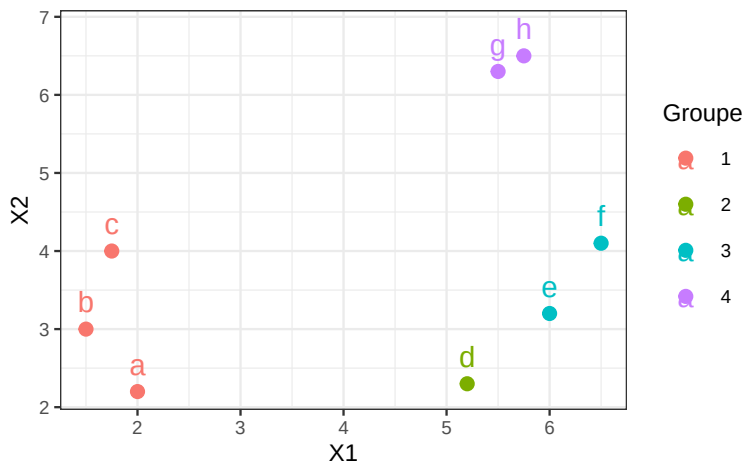
X2
X1
Groupe
1
2
3
4
a
b
c
d
e
f
g
h

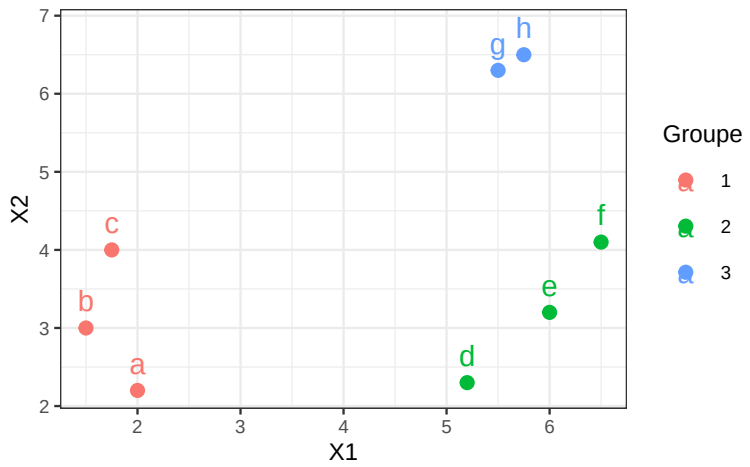
X2
X1
Groupe
1
2
3
a
b
c
d
e
f
g
h

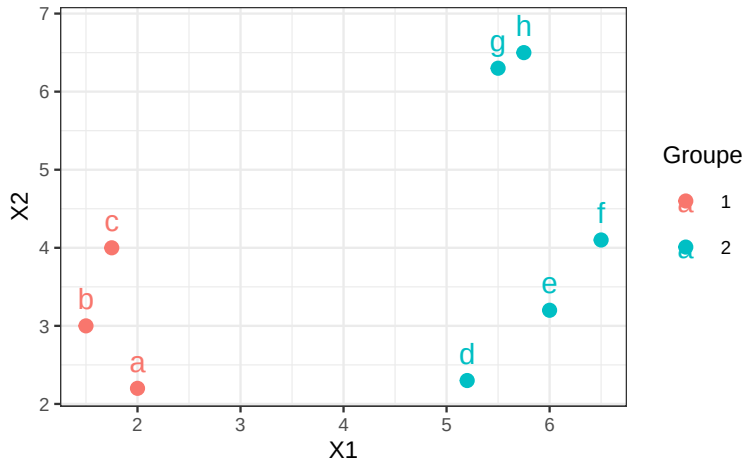
X2
X1
Groupe
1
2
a
b
c
d
e
f
g
h

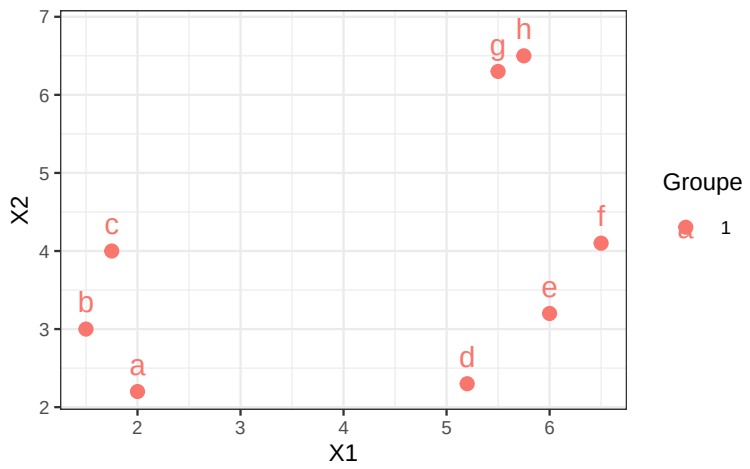
X2
X1
Groupe
1
a
b
c
d
e
f
g
h

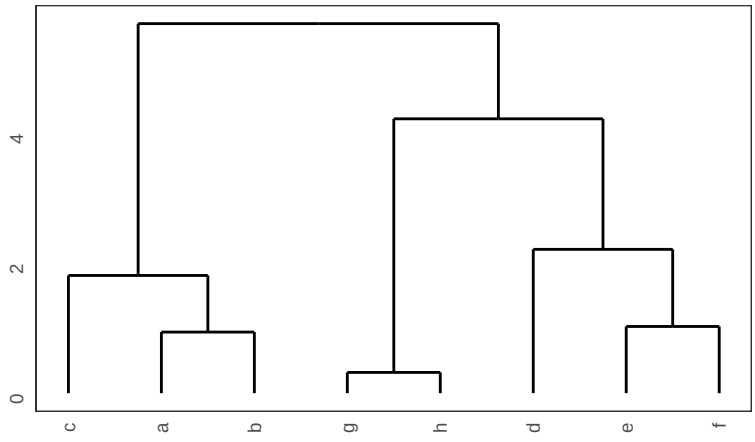
c
a
b
g
h
d
e
f

Visualisation

2.1 La Classification Ascendante Hiérarchique

L'algorithme CAH

Algorithme

Entrées : données, distance (entre individus et clusters d'individus)

1. Calculer une matrice de *distances entre individus*.
2. Chaque observation forme 1 singleton.
3. *Agréger* les deux objets les plus proches.
4. Mettre à *jour la matrice de distances*.
5. Itérer jusqu'à obtenir *un seul groupe*.

Sorties : une suite de partitions emboîtées.

De quoi a t-on besoin ?

Pas grand chose... il suffit de savoir calculer des *distances* et/ou *indicateurs de similarités* entre

- des observations. On notera d une telle distance
- des groupes d'observations, *i.e.* entre clusters. On notera Δ une telle distance.

2.2 Mesures de dissemblances

Saut minimum

- Également appelé *minimu linkage* ou *single linkage*.

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \min_{x_i \in \mathcal{C}_i, x_j \in \mathcal{C}_j} d(x_i, x_j)$$

Commentaires

- Groupes généralement "étirés".
- "Le voisin de mon voisin est mon voisin".

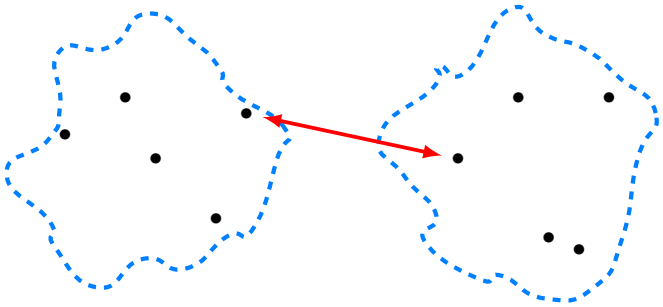

Saut maximum

- Également appelé *complete linkage*.

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \max_{x_i \in \mathcal{C}_i, x_j \in \mathcal{C}_j} d(x_i, x_j)$$

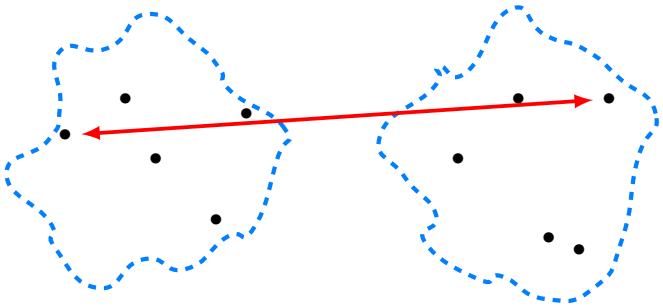

Commentaires

Groupes généralement "compacts".

Saut moyen (average linkage)

Moyenne de toutes les distances entre deux objets des deux groupes :

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum_{x_i \in \mathcal{C}_i, x_j \in \mathcal{C}_j} d(x_i, x_j)$$

Commentaires

Intermédiaires entre le min et le max...

Lien de Ward

Idée

Se baser sur l'inertie :

$$\begin{aligned}\mathcal{I}_{\text{tot}} =& \frac{1}{n}\sum_{i=1}^{n} d^2(x_i - \bar{x}) \\ =& \frac{1}{n}\sum_{k=1}^{K}\sum_{i\in\mathcal{C}_k} d^2(x_i, \bar{x}_{\mathcal{C}_k}) + \frac{1}{n}\sum_{k=1}^{K} n_k d^2(\bar{x}_{\mathcal{C}_k}, \bar{x}) \\ =& \mathcal{I}_{\text{intra}} + \mathcal{I}_{\text{inter}}\end{aligned}$$

en minimisant $\mathcal{I}_{\text{intra}}$ et/ou maximisant $\mathcal{I}_{\text{inter}}$.

Cas extrêmes

- $K = n \Longrightarrow \mathcal{I}_{\text{intra}} = 0$ et $\mathcal{I}_{\text{inter}} = \mathcal{I}_{\text{tot}}$.
- $K = 1 \Longrightarrow \mathcal{I}_{\text{intra}} = \mathcal{I}_{\text{tot}}$ et $\mathcal{I}_{\text{inter}} = 0$.

Lien de Ward

Assembler les clusters de manière à minimiser la perte de $\mathcal{I}_{\text{inter}} \iff$ minimiser le lien de Ward :

$$\Delta(\mathcal{C}_i, \mathcal{C}_j) = \frac{|\mathcal{C}_i|\,|\mathcal{C}_j|}{|\mathcal{C}_i| + |\mathcal{C}_j|} d^2(\bar{x}_{\mathcal{C}_i}, \bar{x}_{\mathcal{C}_j})$$

Commentaires

- Bien adapté à la distance euclidienne
- liens forts avec l'ACP.

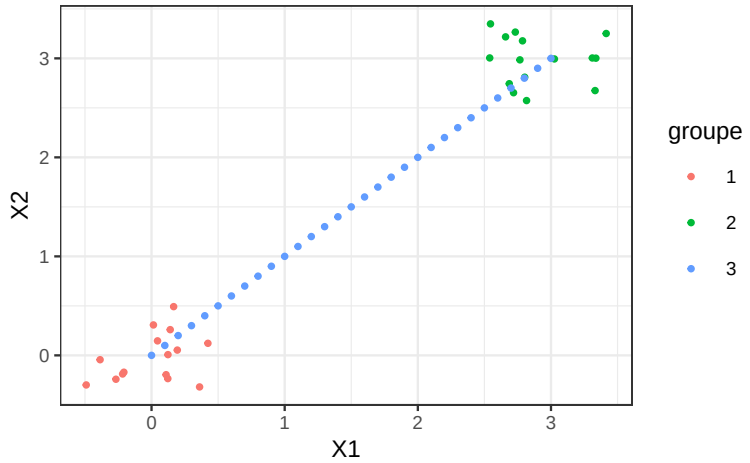

Exemple

```
> class1 <- hclust(D,method = "single")
> ggdendrogram(class1)
```

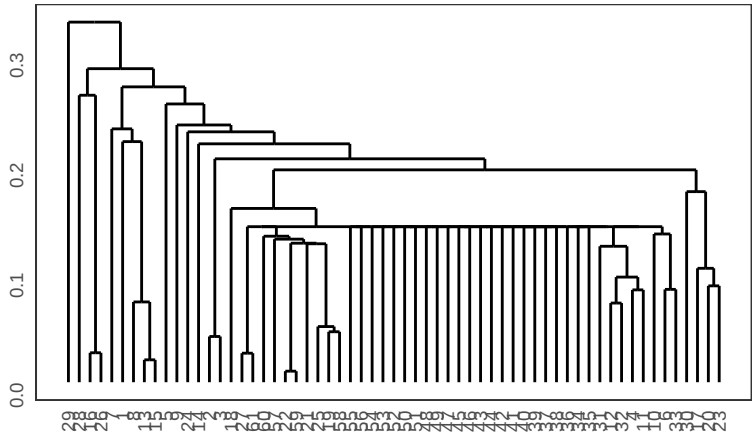


```
> class2 <- hclust(D,method = "ward")
> ggdendrogram(class2)
```

```
> G1 <- cutree(class1,k = 2)
```

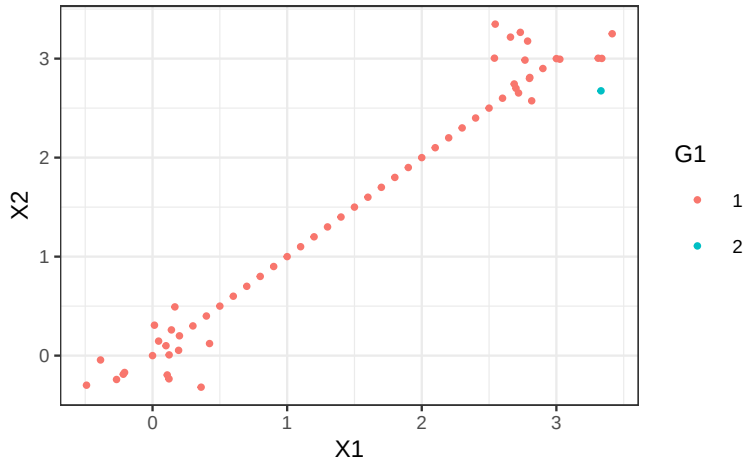


```
> G2 <- cutree(class2,k =2)
```

Choix du nombre de classes

- Toujours *difficile*... On se base généralement sur la *perte d'inertie inter* obtenue en agrégeant les clusters :

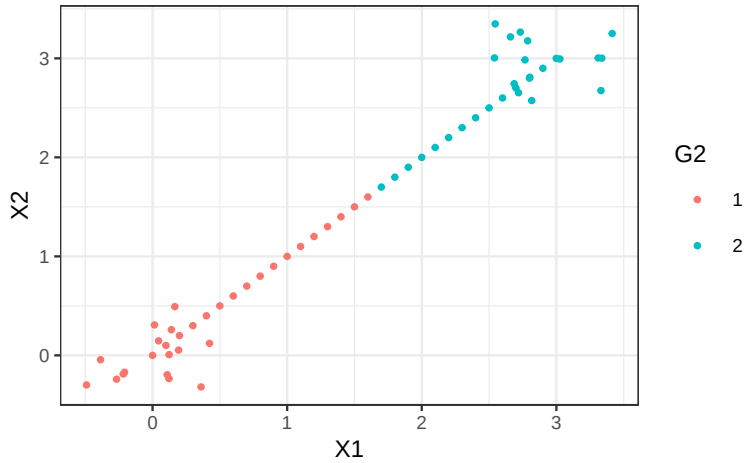


```
> tibble(perte=rev(class2$height),x=1:60,
+        col=as.factor(c(1:3,rep(4,57)))) |>
+   ggplot()+aes(x=x,y=perte,fill=col)+
+   geom_bar(stat = "identity",show.legend = FALSE)
```

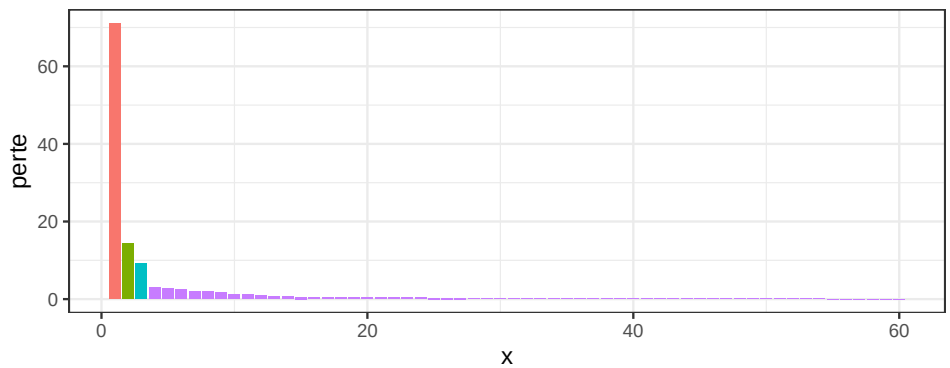

Le coin R : hclust

```
> DD <- dist(tbl)
> classif <- hclust(DD,method = "ward.D2")
> library(ggdendro)
> ggdendrogram(classif,labels = FALSE)
```

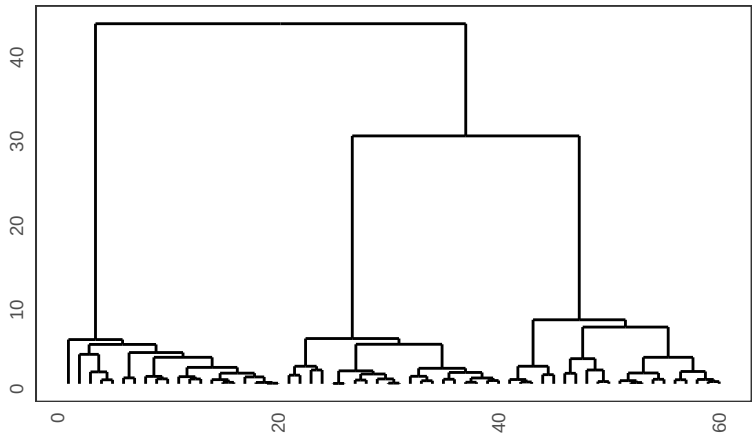

Le coin R : agnes de cluster

```
> library(cluster)
> classif1 <- agnes(DD,method = "ward")
> plot(classif1,which.plots=2)
```

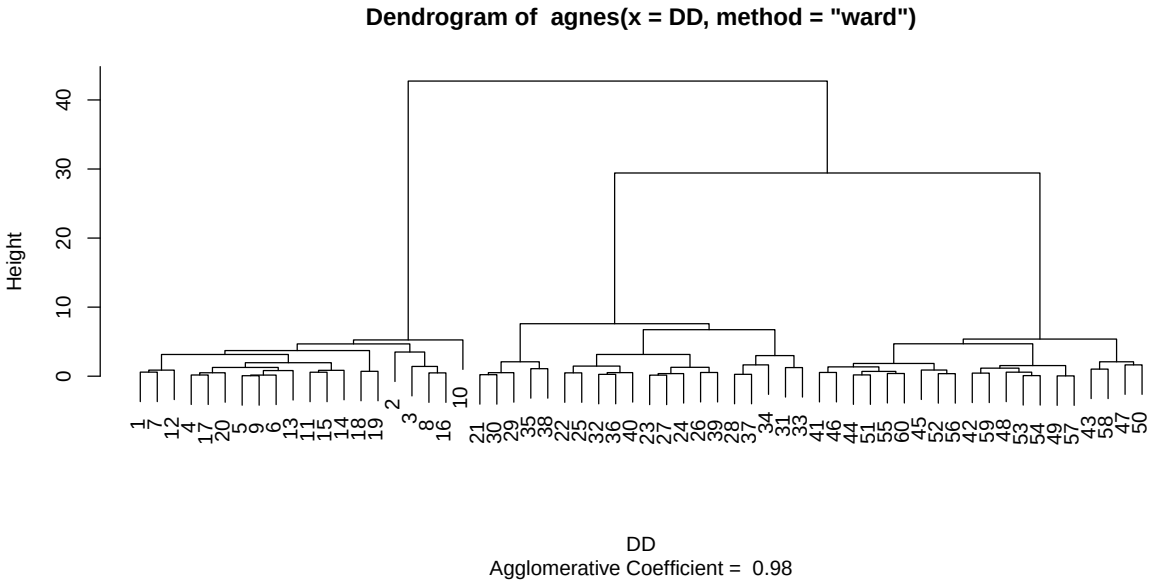

Bilan

Avantages

- Pas besoin de connaître le nombre de classes a priori
- Visualisation dendrogramme

Inconvénients

- Coupure du dendrogramme pas toujours simple
- Complexité algorithmique élevée lorsque n est grand $\Longrightarrow O(n^3)$.

2.3 Compléments

n grand $\Longrightarrow$ Classification mixte

- La CAH est souvent trop couteuse en temps de calcule lorsque n est grand.

Classification Mixte

1. Faire un k-means sur les données avec k grand (par exemple $k = 1000$)
2. Lancer la CAH sur les centroïdes obtenus dans le k-means (en prenant en considération les effectifs des clusters)

- Sur **R** on peut utiliser la fonction `HCPC` du package **FactoMineR**.

Exemple

```
> dim(tbl)
[1] 70000     2
> aa <- dist(tbl)
Error: vecteurs de mémoire épuisés (limite atteinte ?)
```

```
> library(FactoMineR)
> classif <- HCPC(tbl,kk=100,nb.clust = 5,
+                 description = FALSE,graph = FALSE)
> summary(classif$data.clust)
       V1                V2          clust
 Min.   :-3.8960   Min.   :-2.9089   1: 9968
 1st Qu.: 0.7978   1st Qu.: 0.2049   2: 8851
 Median : 4.4625   Median : 4.0371   3:11027
 Mean   : 3.5691   Mean   : 2.8530   4: 9986
 3rd Qu.: 5.4406   3rd Qu.: 5.1447   5:30168
 Max.   : 8.3466   Max.   : 8.6905
```

d grand

- CAH et k-means reposent sur des *distances entre individus*.
- Les distances standards ne sont *pas forcément pertinentes en grande dimension*.

Réduction de dimension

- Souvent pertinent d'effectuer une analyse factorielle au préalable(ACP-ACM...) pour réduire la dimension.
- On fait ensuite le k-means et/ou la CAH sur les premiers axes de l'analyse factorielle.
- Sur R : fonction `HCPC` de **FactoMineR**.

Fastcluster et flashClust

Packages qui proposent d'*autres algorithmes* pour le calcul de la CAH.

```
> tbl1 <- tbl |> slice(sample(70000,10000));D <- dist(tbl1)
> system.time(aa <- stats::hclust(D,method = "ward.D2"))
utilisateur     système      écoulé
      2.608       0.219       2.867
> system.time(bb <- fastcluster::hclust(D,method="ward.D2"))
utilisateur     système      écoulé
      1.293       0.114       1.461
> system.time(cc <- flashClust::flashClust(D,method="ward"))
utilisateur     système      écoulé
      3.739       0.227       4.024
```

3 Références

Bock, Hans-Hermann. 2008. « Origins and extensions of the k-means algorithm in cluster analysis ». *Electronic journal for history of probability and statistics* 4: 1-18.

Forgy, E. W. 1965. « Cluster analysis of multivariate data: efficiency vs interpretability of classifications ». *Biometrics* 21: 768-69.

Hartigan, J. A., et M. A. Wong. 1979. « Algorithm AS 136: A K-means clustering algorithm ». *Applied Statistics* 28: 100-108.

Lloyd, S. P. 1982. « Least squares quantization in PCM ». *IEEE Transactions on Information Theory* 28: 128-37.

MacQueen, J. 1967. « Some methods for classification and analysis of multivariate observations ». In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, édité par L. M. Le Cam & J. Neyman, 28:281-97. Berkeley.